creative commons

COMMONS DEED

저작자표시 2.0 대한민국

이용자는 아래의 조건을 따르는 경우에 한하여 자유롭게

- 이 저작물을 복제, 배포, 전송, 전시, 공연 및 방송할 수 있습니다.
- 이차적 저작물을 작성할 수 있습니다.
- 이 저작물을 영리 목적으로 이용할 수 있습니다.

다음과 같은 조건을 따라야 합니다:

저작자표시. 귀하는 원저작자를 표시하여야 합니다.

- 귀하는, 이 저작물의 재이용이나 배포의 경우, 이 저작물에 적용된 이용허락조건을 명확하게 나타내어야 합니다.
- 저작권자로부터 별도의 허가를 받으면 이러한 조건들은 적용되지 않습니다.

저작권법에 따른 이용자의 권리는 위의 내용에 의하여 영향을 받지 않습니다.

이것은 이용허락규약(Legal Code)을 이해하기 쉽게 요약한 것입니다.

Disclaimer

dCollection

碩士學位 請求論文

指導敎授 鞠 太 茸

딥러닝 기반 Wi-Fi와 지구자기장을 이용한 실내 측위

成均館大學校 一般大學院

DMC 工學科

金 相 佑

SUNG KYUN KWAN UNIVERSITY

碩士學位 請求論文

指導敎授 鞠 太 茸

딥러닝 기반 Wi-Fi와 지구자기장을 이용한 실내 측위

Deep learning-based indoor positioning using Wi-Fi and geomagnetic field

成均館大學校 一般大學院

DMC 工學科

金 相 佑

SUNGKYUNKWAN UNIVERSITY

碩士學位 請求論文

指導敎授 鞠 太 茸

딥러닝 기반 Wi-Fi와 지구자기장을 이용한 실내 측위

Deep learning-based indoor positioning using Wi-Fi and geomagnetic field

이 論文을 工學 碩士學位請求論文으로 提出합니다.

2022 年 4 月　日

成均館大學校 一般大學院

DMC 工學科

金 相 佑

SUNG KYUN KWAN UNIVERSITY

이 論文을 金相佑의 工學
碩士學位 論文으로 認定함.

2022 年 6 月　　日

審査委員長

審査委員

審査委員

SUNG KYUN KWAN UNIVERSITY

목차

목차 i
표 목차 iii
그림 목차 iii

제1장 서 론 1
제1절 연구 배경 1
제2절 연구 동향 2
제3절 연구 내용 6

제2장 실내 측위 요소기술 및 측위 기법 8
제1절 측위 요소 기술 8
1. 무선통신기반 요소 기술 8
가. WLAN 8
나. BLE 9
다. UWB 9
2. 관성측정장치기반 요소 기술 9
가. 가속도 + 지자기 융합 기반 9
나. 지자기 10
제2절 측위 기법 11
1. 삼각측량법 11
2. 핑거프린트 12
3. 보행자 추측항법 14

제3장 WLAN기반 측위 방법 15

SUNG KYUN KWAN UNIVERSITY

제1절 WLAN RSSI 신호 특성 15
제2절 RSSI 신호 감쇠 모델 16
제3절 RSSI 핑거프린팅 측위 방법 18
1. 핑거프린트 오프라인 단계 19
2. 핑거프린트 맵 재구성 단계 21
3. 핑거프린트 온라인 단계 23

제4장 지구자기장 기반 측위 방법 26
제1절 자기장 신호 특성 26
제2절 자기장 세기 핑거프린팅 측위 방법 29

제5장 실내 측위 시스템 설계 32
제1절 서버 클라이언트 측위 모델 32
1. 서버 클라이언트 구조 32
2. 데이터 프로토콜과 데이터 베이스 34
3. 측위 모델 35
가. WLAN RSSI를 활용한 CNN 측위 모델 35
나. 자기장 세기를 활용한 RNN 측위 모델 36
다. 통합 측위 모델 38

제6장 실내 측위 실험 결과 39
제1절 테스트 베드 환경 39
제2절 실험 결과 42
1. 실험 환경 43
2. CNN 측위 모델 학습 및 테스트 결과 44
3. RNN 측위 모델 학습 및 테스트 결과 45

SUNG KYUN KWAN UNIVERSITY

4. 통합 측위 모델 테스트 결과 47
제7장 결 론 49
참 고 문 헌 50
Abstract 53

표목차

표 1. 거리 변화에 따른 RSSI 측정 결과 17
표 2. WLAN RSSI 핑거프린트 맵 예시 20
표 3. 자기장 세기 수집 결과 28
표 4. 생성된 경로 결과 30
표 5. 서버-클라이언트 프로토콜 34
표 6. 핑거프린트 맵 데이터 베이스 34
표 7. 실험 환경 43
표 8. 합성곱 신경망 하이퍼 파라미터 설정 43
표 9. 순환 신경망 하이퍼 파라미터 설정 44
표 10. 합성곱 신경망 결과 45
표 11. 순환 신경망 결과 46
표 12. 개선된 측위 모델 성능 결과 48

그림목차

그림 1. 실내 측위 연구 동향 3
그림 2. 보행 시 Z축 가속도 변화 10
그림 3. AP 좌표 기준 삼각측량법 11
그림 4. 핑거프린트 기반 매핑 및 추정 단계 13
그림 5. 고정 상태에서 WLAN RSS 변동 15

SUNG KYUN KWAN UNIVERSITY

그림 6. 실내에서의 다중경로 전파 16
그림 7. RSSI 거리 환산모델 - 실측 RSSI 데이터 비교 18
그림 8. 오프라인 단계 데이터 수집 모습 19
그림 9. 맵 슬라이딩 실시 예 22
그림 10. k-최근접 이웃 분류기 23
그림 11. WLAN RSSI 입력 신경망 24
그림 12. 합성곱 신경망 25
그림 13. 실내에서의 자기장 분포 26
그림 14. 고정 상태에서 자기장 세기 변동 27
그림 15. 시간 변화에 따른 자기장 분포 변화 28
그림 16. 핑거프린트 맵 기반 무작위 경로 생성 예시 30
그림 17. 자기장 세기 입력 순환 신경망 31
그림 18. 측위모델 시스템 구조 33
그림 19. CNN 기반 RSSI 입력 측위 모델 36
그림 20. RNN 기반 자기장 세기 입력 측위 모델 37
그림 21. 점진적 측위 모델 38
그림 22. 광장 공간 포함 테스트 베드 39
그림 23. 복도형 공간 포함 테스트 베드 39
그림 24. 테스트 베드 좌표 계획 40
그림 25. 실내 공간의 자기장 분포 결과 41
그림 26. 자기장 세기에 따른 샘플 분포 42
그림 27. 합성곱 신경망 훈련 오차 45
그림 28. 순환 신경망 훈련 오차 46
그림 29. 300개 은닉 노드, 3개의 은닉 층 RNN 측위 모델의 걸음 수에 따른 평균 오차 47
그림 30. 측위 모델 성능 비교 48

SUNG KYUN KWAN UNIVERSITY

논문요약

딥러닝 기반 Wi-Fi와 지구자기장을 이용한 실내 측위

실내 측위 시스템(IPS : Indoor Positioning System)은 스마트 폰 혹은 Tag 등 스마트 디바이스의 위치를 측정하여 제공하는 시스템이다. 실내 측위 시스템은 위치 기반 서비스에서 중요한 성능인 위치 정밀도와 밀접한 연관이 있다. 실외에서는 GPS(Global Positioning System)를 활용하여 10m 이내의 오차범위의 기술로 실외 위치 기반 서비스에 효과적으로 사용되고 있으나 실내에서는 더욱 정확한 위치 추정에 대한 연구가 필요하다. 실내 측위 시스템의 정밀한 위치 추정은 위치 기반 서비스의 확장성에 큰 도움이 된다.

본 논문에서는 오프라인 모드에서 Wi-Fi 및 지자기 핑거프린트 맵을 구축하고 측위 모드에서 핑거프린트 맵을 기반으로 사용자의 위치를 추정하는 딥러닝 모델에 대해 연구한다. Wi-Fi와 지자기는 추가적인 인프라 구축이 필요하지 않기 때문에 저비용으로 높은 위치 추정 효과를 얻을 수 있다. 본 논문에서는 기반 기술의 특성을 분석하여 문제점을 제시하고 특성에 따라 2 단계 실내 측위 모델을 제안한다. 첫 번째, 실내 특정 위치에서 측정된 WLAN RSSI Feature를 입력으로 하는 CNN 측위 모델에서 실내에서의 영역을 추정한다. 두 번째, 첫 번째 단계에서 추정된 영역을 기반으로 사용자의 이동에 따라 생성되는 고유 시퀀스를 입력으로 하는 순환 신경망 (Recurrent neural network, RNN) 에서 사용자를 트래킹하여 이동 경로를 추정한다. 사전 영역 추정으로 인해 초기 위치 추정 오차의 개선 여부를 실험한다.

제안된 딥러닝 기반의 실내 측위 시스템의 평가를 위해 성균관대학교 자연과학캠퍼스 산학협력센터 7층을 테스트 베드로 선정하였다. 테스트 베드는 긴 복도와 엘리베이터 앞 작은 광장을 포함한다. WLAN RSSI Feature를 입력으로 하는 CNN 측위 모델에서 평균 1.34m, 자기장 세기 기반의 RNN 측위 모델에서 2.18m의

SUNGKYUNKWAN UNIVERSITY

평균 오차 결과를 얻었다. 본 논문에서 제안하는 개선된 모델은 RNN만 적용된 모델 대비 초기 10 걸음 오차가 42% 수준으로 감소시키는 성능을 보였다.

주제어 : Finger printing, Tracking, Wi-Fi, Geomagnetic, Indoor positioning system

SUNG KYUN KWAN UNIVERSITY

제1장 서 론

제1절 연구배경

각종 센서가 탑재된 스마트 기기의 사용이 대중화되었고 이를 활용한 다양한 위치기반 서비스(Location-Based Services, LBS)가 보급되어 사용자에게 새로운 경험을 선사하고 있다. 실외에서는 GPS(Global Positioning System)를 기반 GNSS(Global Navigation Satellite System)을 통한 10m 이내의 오차범위의 기술로 다양한 서비스가 활성화되어 있다. 대표적인 위치기반 서비스로는 네비게이션이 있으며 다양한 서비스에서 위치정보 제공 목적으로 사용되고 있다. 한편 실내에서도 새로운 경험을 요구하는 사용자가 늘어나고 있고, 최근 COVID-19 pandemic으로 인해 실내에 머무르는 시간이 증가함에 따라 실내 위치 인식 시스템의 수요가 급증하고 있다. 하지만 실내에서는 GPS 신호를 안정적으로 수신할 수 없어 GNSS와 같은 대표적인 측위 시스템이 보급되지 못하였기 때문에 관련 측위 기술에 대한 연구가 활발히 진행되고 있다.

측위 기술로는 전파인 WLAN(Wireless Local Area Network), UWB(Ultra Wide Band), RFID, BLE(Bluetooth Low Energy)와 가시광, 적외선과 같은 광파를 이용한 방법, 지구 자기장을 이용한 방법 및 관성 측정 장치를 이용한 방법이 대표적이다. 측위 기술이 가진 특성과 여러 물체와 벽으로 구분되어 있는 실내환경의 NLOS(Non-Line-Of-Sight) 특징으로 인해 요구되는 위치 정확도를 달성하기 위해서는 목적에 맞는 최적 측위 모델의 적용이 중요하다. 실내 위치 기반 서비스의 중요한 품질속성인 측위 정확도, 인프라 구축 비용, Database 구축 비용, 실시간 측위를 위한 응답성 중 각 위치 기반 서비스의 품질속성 우선순위에 따라 적절한 측위 기술과 측위 기법의 선택 및 조합이 필요하다.

SUNGKYUNKWAN UNIVERSITY

공장 자동화 시스템과 같이 측위 대상이 한정적이거나 목표로 하는 공간에서 LOS(Line-Of-Sight) 환경을 보장할 수 있다면 UWB, 블루투스 비콘 모듈의 설치로 효과적인 측위 성능을 기대할 수 있다. 하지만 쇼핑몰, 대형 마트 혹은 병원과 같은 실내의 넓은 공간에서 불특정 다수의 사용자를 대상으로 하는 위치 기반 서비스에서는 추가적인 인프라 구축 비용이 많이 들기 때문에 건물 내에 구축되어 있는 인프라를 최대한 활용할 수 있는 측위 모델이 필요하다.

제2절 연구동향

위치 기반 서비스는 목적에 맞는 성능 및 요구사항을 정의하고 실내 측위 시스템(Indoor Positioning System, IPS)은 WLAN, UWB, RFID, BLE, 자기장 및 관성 측정 장치 정보를 활용하여 서비스의 목적에 맞는 성능을 제공한다. 본 절에서는 실내 측위 시스템의 연구동향을 설명한다.

좁은 실내에서 가장 높은 우선순위를 가진 실내 측위 시스템의 성능은 측위 정확도라고 할 수 있다. 높은 측위 정확도는 위치기반 서비스의 확장성에 영향을 끼친다. 초광대역(Ultra Wide Band , UWB) 기술이 적용된 애플의 에어 태그나 삼성의 스마트 태그 플러스는 높은 측위 정확도 성능을 기반으로 좁은 실내에서도 태그의 방향과 거리 정보를 제공하여 새로운 경험을 선사하고 있다. 그리고 공항, 대형 마트, 쇼핑몰과 같은 넓은 공간에서 다양한 스마트 디바이스를 지닌 사용자를 대상으로 하는 실내 항법 서비스는 적은 인프라 구축 비용으로 다수의 사용자에게 서비스를 제공하는 것을 목적으로 한다.

[그림1]의 최근 실내 측위 분야의 논문 출판 비율을 보면 저비용으로 높은 측위 정확도를 목표로 하는 트렌드가 나타난다.

SUNG KYUN KWAN UNIVERSITY

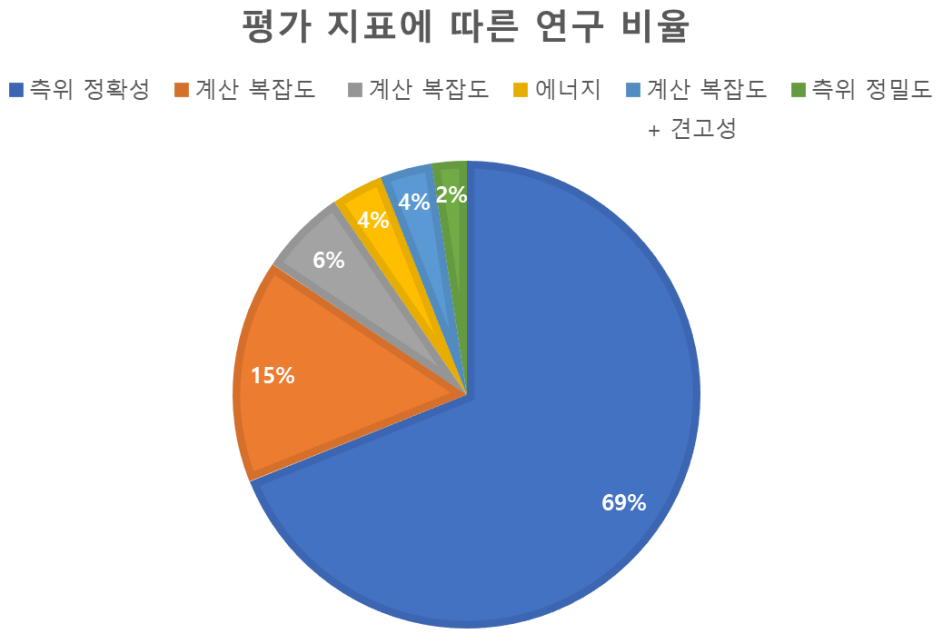

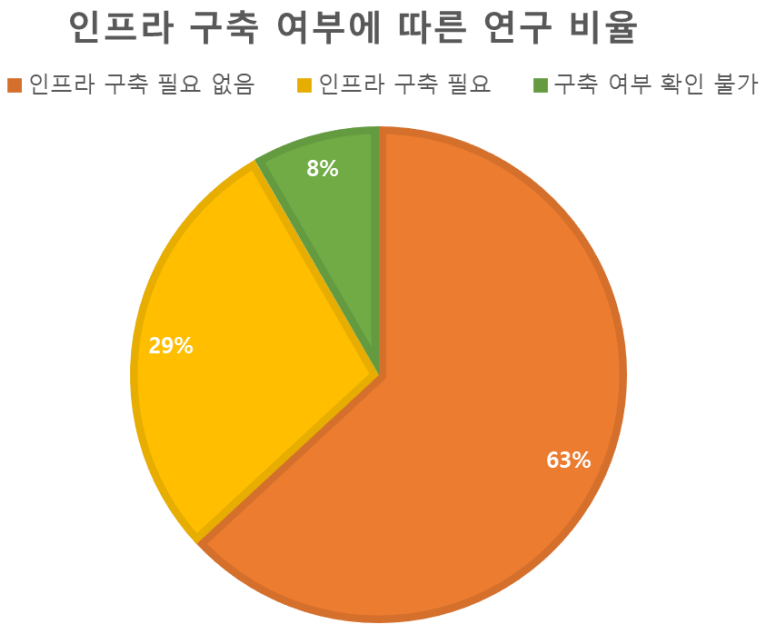

그림 1 실내 측위 연구 동향

SUNG KYUN KWAN UNIVERSITY

실내 측위 분야에 주로 사용되는 기술로는 대부분의 스마트기기에 탑재되어 있어 접근성이 좋고 실시간 위치 측위가 가능하다는 점에서 장점이 뚜렷한 IMU(Inertial Measurement Unit)를 기반으로 보행자의 위치를 추정하는 기술이 많이 연구되고 선택되고 있다. 보행자 추측 항법(PDR, Pedestrian Dead Reckoning)이라고 불리는 이 기술은 관성 측정 장치를 활용한 추정방법으로 별도의 설치 장비 없이 실시간 측위가 가능하지만 측정 오차가 누적되는 특성 때문에 오차를 보정해줘야 하는 문제점이 있다.

RF(Radio Frequency) 기반의 무선신호도 보편적으로 많이 선택되는 실내 측위 기술 중 하나이다. 측위 보정기법에 따라 높은 정밀도를 얻을 수 있는 UWB는 LOS 환경의 넓은 실내에서 높은 정확도를 요구하는 공장자동화 목적으로 사용되기 용이하지만, 넓은 대역폭을 사용하여 레거시 시스템에 전파 간섭을 일으킬 수 있고 밀집된 NLOS 환경에서는 정확도가 떨어진다. BLE 비콘은 이미 상용화되어 서비스 영역을 넓혀가고 있는 기술로 3m 내외의 정확도를 얻을 수 있고 스마트 기기에 탑재되어 있는 이점이 있어 보편적으로 사용되고 있는 기술이지만 UWB와 마찬가지로 측위 시스템을 구축하는 비용이 든다. Wi-Fi의 경우 다른 무선통신 기반 측위 기술에 비해 정확도는 5m 내외로 낮지만 실내 공간에 설치되어 있는 AP(Access Point) 인프라를 활용함으로써 측위 시스템 구축 비용을 들이지 않을 수 있다는 장점이 있다. 이런 뚜렷한 장점으로 인해 Wi-Fi 기반 실내 측위 방법 연구가 활발하게 진행되었다. Joaquín 은 Wi-Fi data를 공개하고 KNN(K-Nearest Neighbor) 기반 추정 방법으로 측위 성능의 Baseline을 제시하여 여러 연구자들이 측정비용을 줄이고 연구에 집중하여 더 나은 방법론을 제안할 수 있도록 하였다.[1] 공개된 Wi-Fi 데이터셋에 대해 Multi-building, Multi-floor, Location의 classification에 적합하고 확장 가능한 Deep Neural Networks(DNN) 구조에 대한 연구가 진행되었다.[7] 또한 Wi-Fi data set에 대해 RSS 단일 벡터가 아닌 시계열 RSS 벡터를 이미지로 재구성하여 합성곱 신경망(Convolution Neural Network, CNN)의 입력으로 위치를 추정한 연구도 진행되었고 향상된 정확도 결과를 도출하였다.[8]

이러한 무선통신 신호 기반의 측위 기술은 RSSI(Received Signal Strength

SUNG KYUN KWAN UNIVERSITY

Indicator)의 세기를 기반으로 다양한 측위 기법을 통해 위치를 추정할 수 있다. 비콘은 지속적으로 식별 ID와 신호의 세기를 포함한 RF 신호를 Broadcasting 하고 이를 수신한 단말기에서 삼각측량(Triangulation) 기법, 핑거프린팅(Finger printing) 기법과 같은 측위 추정 기법을 사용하여 위치를 추정한다. 삼각 측량은 대표적인 위치 추정 기법으로 3개 이상의 AP로부터 RSSI 값을 측정하고 그 측정 값을 거리로 환산하는 기법이다. 그러나 실내공간에서는 벽과 구조물, 인체와 같은 장애물로 인해 신호의 감쇠, 반사, 굴절 등의 다중경로전파(Multipath Propagation) 현상 때문에 실내 추정기법으로 사용하기 어렵다. 반면에 핑거프린팅 기법은 실내 공간을 작은 공간으로 나누고 각 공간에서 RSSI를 수집하고 이를 라디오 맵 형태로 저장하여 데이터 베이스화 한다. 이후에 사용자 위치에서 수신된 RSSI 값을 구축 된 라디오 맵과 비교하여 위치를 결정하는 기법이다. 핑거프린팅 기법은 사전 수집 단계에서 많은 시간과 노력이 필요하지만 사전에 신호의 왜곡이나 감쇠를 미리 수집하여 라디오 맵으로 구성하기 때문에 실내 측위 추정기법으로 사용하기 용이하다. 실내에 설치되어 있는 다수의 AP로부터 얻는 RSSI는 높은 차원의 이미지 피처를 얻을 수 있기 때문에 측위 기법으로는 이미지 분류에 강력한 기계학습 패러다임인 합성곱 신경망(Convolution Neural Network, CNN)이 주로 선정된다. 하지만 무선통신 기반 실내 측위 기술은 신호의 불안정한 특성 때문에 여전히 정확도 향상에 한계가 있다는 단점이 있다.

반면 안정적인 신호를 얻을 수 있는 실내 측위 기술로는 지구자기장이 있다. 지구자기장은 지구의 자전축 회전으로 인하여 자연적으로 발생하는 자기장이다. 실내에서 자기장에 영향을 줄 수 있는 건물의 철 구조물에 의해 변형되어 공간마다 고유한 자기장 패턴을 형성한다. 자기장은 Wi-Fi와 같은 무선신호에 비해 안정적인 세기를 유지하기 때문에 안정적인 측위 정확도를 확보할 수 있는 반면 자기장은 차원이 낮은 데이터 이기 때문에 공간좌표로 바로 전환할 수 없다는 문제가 있다. 이러한 문제점은 자기장 데이터를 시퀀스화 하면서 해결된다. 실내에서의 연속적인 사용자의 움직임은 고유한 자기장 시퀀스를 생성해낸다. 시간에 따라 변화하는 데이터 시퀀스를 학습하고 인식하는데 효과적인 순환 신경망 (Recurrent neural network, RNN)은 자기장

SUNG KYUN KWAN UNIVERSITY

시퀀스를 통해 이동 경로를 추정하는데 주로 사용된다.

이러한 Wi-Fi, 자기장 데이터의 특성에 대한 이해를 기반으로 각 측위 기술을 융합하여 정확도를 보완하고 안정적인 결과를 얻고자 하는 연구가 진행되어 왔다. 따라서 이 연구에서는 강력한 기계학습 패러다임인 합성곱 신경망(Convolution Neural Network, CNN)과 순환 신경망 (Recurrent neural network, RNN)을 통해 Wi-Fi, 자기장 데이터를 새로운 핑거프린팅 기반으로 효과적인 조합이 가능한지 조사한다. 이때, 핑거프린팅 이미지에 neural network를 적용할 때의 주요한 문제인 Wi-Fi, 자기장 데이터의 이질성 이슈에 대한 영향을 회피 하기 위해 각 데이터를 1단계 실내 영역 추정 후, 위치 tracking하는 2단계 계층구조를 채택하고 실내 측위 시스템의 정확도와 효율성을 개선한 알고리즘을 제안한다.

제3절 연구 내용

본 논문에서는 앞서 2절에서 밝힌 바와 같이 WLAN, 자기장 데이터의 특성에 대해서 조사하고 신호 세기 기반 측위 기법을 적용하고 실험한다. 기존의 WLAN 기반 RSSI를 활용하여 핑거프린팅 측위 기법이 적용된 측위 시스템들은 정확도 향상을 위한 연구가 활발히 진행되어 왔다.[1] [2] [7] 앞선 연구에서 각 표본 위치의 신호 세기 패턴을 더욱 잘 표현하기 위하여 시계열 WLAN RSSI 데이터 재구성을 통해 데이터의 차원을 높이면 정확도 향상의 결과로 나타났다.[8] 하지만 위치를 추정하는 단계에서 시계열 데이터를 구축하기에는 실시간성이 떨어진다는 단점이 있다. 자기장 데이터의 경우 데이터 샘플링 시간이 비교적 짧기 때문에 WLAN의 단점을 보완할 수 있는 반면 데이터의 낮은 차원 특성으로 인해 바로 위치로 변환할 수 없다는 단점이 있다.

따라서 본 논문에서는 신호 세기 기반 측위 기법이 지니는 단점을 파악하고 딥러닝 기반 개선된 측위 기법을 제안하고자 한다. 제안된 기법은 핑거프린팅 측위 방법이 적용된 서버-클라이언트 구조로 구현된다. 각 표본 위치에서 신호 세기를 수집하는

SUNG KYUN KWAN UNIVERSITY

오프라인 단계에서는 먼저 테스트 베드의 좌표 정밀도를 계획한다. 클라이언트로는 높은 보급률을 가진 안드로이드 OS 기반의 스마트 폰을 선정하여 WLAN, 자기장 데이터를 수집하고 핑거프린트 맵을 구축한다. 훈련 단계에서는 합성곱 신경망 측위 모델에 수집된 WLAN 데이터를 효과적으로 재구성하고 이를 평가하여 효과를 검증한다.

본 논문의 구성은 다음과 같다. 2장. '실내 측위 요소 기술 및 측위 기법'에서는 실내 측위에 이용되는 기술들의 특징과 측위를 구현하는 측위 기법들에 대해 조사하고 각 측위 요소기술과 기법의 장점과 단점에 대해 나타낸다. 3장 'WLAN 기반 측위 방법'에서는 WLAN RSSI의 신호 특성과 측위 기법에 대하여 기술되고, 4장 '지구자기장 기반 측위 방법' 에서는 실내에 분포하는 자기장의 특성 및 측위에 대해 논한다. 5장에서는 실내 측위 모델의 설계 및 구현에 대해 기술하고 6장에서 측위 모델의 실험 결과 내용을 나타낸다. 마지막으로 7장에서 결론에 대해 기술한다.

SUNG KYUN KWAN UNIVERSITY

제2장 실내 측위 요소 기술 및 측위 기법

측위를 하기 위해서 base가 되는 요소기술, 기술의 특성에 맞는 측정 기술, 위치를 추정하는 측위 기법의 선택이 중요하다. 요구사항 및 환경에 따라 매우 다양한 기술과 기법의 조합으로 실내 위치 추정이 가능하다. 2장에서는 대표적인 요소 기술과 측위 기법을 소개한다.

제1절 측위 요소 기술

실내 측위 기술 관련 연구에 대하여 크게 2가지로 나누어 소개한다. RF(Radio Frequency)의 세기나 응답속도를 이용한 무선통신 기반 측위 기술과 관성 측정 장치(IMU, Inertia Measurement Unit)을 이용한 관성센서 기반의 측위 기술을 소개한다.

1. 무선통신 기반 요소 기술

가. WLAN

가장 널리 사용되고 있는 측위 기술 중 하나인 WLAN 은 AP 로부터 broad casting 된 RF 신호가 단말기에 수신되었을 때, 신호의 세기를 활용한다. AP 와 단말기간 거리를 추정하여 위치를 결정하거나 신호의 세기를 미리 저장하여 라디오 맵으로 구성하고 저장된 정보와 비교하여 위치를 추정한다. WLAN 기반의 측위 시스템의 대표적인 측위 방법으로는 RF 신호의 세기를 기반으로 NNSS(Nearest Neighbor in Signal Space)를 이용하여 위치를 추정하는 방법이 있다. 이와 같은 WLAN 기반 측위 시스템은 이미 설치된 AP 를 활용하여 스마트 기기에서 측위 데이터를 취득할 수 있다는 점에서 추가 인프라가 불필요하다는 장점이 있다.

SUNG KYUN KWAN UNIVERSITY

나. BLE(Bluetooth Low Energy)

BLE 도 대부분의 스마트 기기에서 지원하고 있어 다양한 연구와 실험이 진행되고 있다. 이미 다양한 상용 블루투스 비콘이 출시되면서 실내 공간에서 다양한 위치에 부착되어 사용자에게 서비스가 제공되고 있고 서비스 영역도 다각화 될 것으로 기대된다. BLE 는 가격이 저렴하고 일정 공간내에서 보다 정밀한 측위가 가능하다는 장점이 있으나 NLOS(None Line-Of-Sight) 환경에서 측위 정확도에 영향을 주고 넓은 실내 공간에서 다수의 비콘을 설치해야 한다는 한계가 있다.

다. UWB(Ultra-Wideband)

UWB 는 기존의 스펙트럼에 비해 수 GHz 이상의 넓은 주파수 대역에 걸쳐 낮은 전력으로 대용량의 정보를 전송하는 무선통신 기술이다. 임펄스 라디오(Impulse Radio)방식으로 변조를 하지 않고 1ns 이하의 짧은 임펄스 신호를 무선으로 송수신하는 방식이다. UWB 기반 측위는 TDoA(Time Difference of Arrival) 측위 알고리즘을 사용하여 위치를 추정한다. 수 ms 레벨의 Time stamp 로 도달 시간을 측정하고 측위에 활용하기 때문에, LOS(Line-Of-Sight) 환경에서는 훌륭한 측위 정밀도를 얻을 수 있으나 장애물로 인한 다중경로(Multi-Path)환경 에서는 큰 오차가 발생할 수 있다. 또한 고가의 Anchor 를 다수 설치해야 하는 설치 비용문제가 있다.

2. 관성 측정 장치 기반 요소 기술

가. 가속도 + 지자기 융합 기반

관성 측정 장치(IMU)의 가속도계 지자기계를 융합한 측위 방법은 PDR (Pedestrian Dead Reckoning) 로 알려져 있다. [그림 2] 와 같이 가속도계를 통한 Step 검출, 방향 추정, 보폭 추정의 과정을 거쳐 위치를 추정하고 이를 누적하는 측위 기법으로 IMU 가 탑재된 스마트 기기의 가속도계, 지자기계를 활용하여 위치 변화를 추정하기 때문에 별도의 추가 인프라가 필요 없고, 실시간 측위가 가능하다는 장점이 있으나 오차가 누적되는 특성으로 인해 다른 측위 기술과의 융합으로 보정이 필요하다.

SUNGKYUNKWAN UNIVERSITY

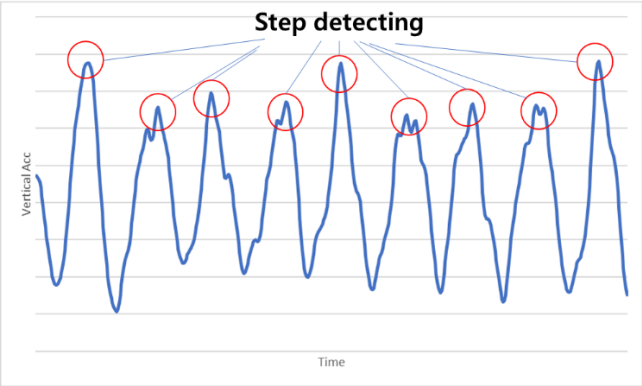

그림 2 보행 시 Z축 가속도 변화

나. 지자기 (Geo-magnetism)

지구상 어디에서나 자기장이 형성되며 대체로 20~70uT 정도의 크기로 존재하고 국내는 약 50uT 정도이다. 자기장은 실내 공간의 철골구조물이나 전자 장비로 인해 왜곡되고 이로 인해 공간마다 고유의 자기장 패턴을 가지게 된다. 이러한 자기장 패턴은 실내 공간에서 위치를 구분할 수 있는 기반이 된다. 자기장 신호는 무선전파 신호 대비 안정적인 특성을 갖는다. 정지상태에서 변화가 심한 RF, 초음파 신호에 대비하여 안정적인 신호를 얻을 수 있다. 자기장 기반 실내 측위 기법으로는 안정적으로 유사한 패턴의 세기를 신호 특성을 기반으로 핑거프린팅 방식이 사용된다. 특정 위치에서 하나의 자기장 벡터만을 얻을 수 있기 때문에 데이터의 차원이 낮아 실내 공간 좌표에 바로 매칭할 수 없다. 따라서 자기장의 변화 트렌드를 매핑하거나 다른 측위 기술과의 융합으로 향상된 측위 정확도를 얻을 수 있다. 자기장 세기를 활용한 핑거프린팅 기반 측위는 향상된 정확도를 위해 사전 핑거프린팅 작업에 시간과 노력이 드는 반면 별도의 추가 인프라가 필요 없다는 장점이 있다.

자기장의 안정적인 신호 특성으로 목표 물체의 위치 이동에 따른 자기장 변화도 비교적 안정적으로 얻을 수 있기 때문에 순환 신경망 모델을 활용하여 목표 물체의 이동 경로를 추적하여 1m 이내의 정확도를 달성한 연구도 있다.[6] 하지만 자기장 신호는 차원이 낮기 때문에 연속적인 이동이 없으면 위치를 추정하기 어렵다는 단점이 있다.

SUNGKYUNKWAN UNIVERSITY

제2절 측위 기법

실내 측위 기법은 측위 기술 인프라로부터 수신된 신호를 통해 정확한 측위 결과를 얻기 위한 기법으로 무선통신 기술에 적용되는 삼각측량(Triangulation), 핑거프린트(Finger Print) 기법이 있고 관성 센서 기반 기술에서 사용되는 PDR(Pedestrian Dead Reckoning) 기법이 있다. 여기서는 삼각측량 기법, 핑거프린트 기법, PDR 기법을 소개한다.

1. 삼각 측량법

삼각 측량법은 평면상에서 이동하는 개체의 실시간 위치를 추정하는 데 가장 보편적으로 사용된다. 이를 위해서 최소 3개 이상의 기준점이 필요하며 일반적으로 무선통신 기술에서 AP 가 기준이 된다. 각 기준점을 AP1, AP2, AP3이라고 하고 좌표를 (x1,y1), (x2,y2), (x3,y3) 로 정의하고 측위 대상 노드를 (x,y)라고 하면 아래 [그림3]과 같이 표현할 수 있다.

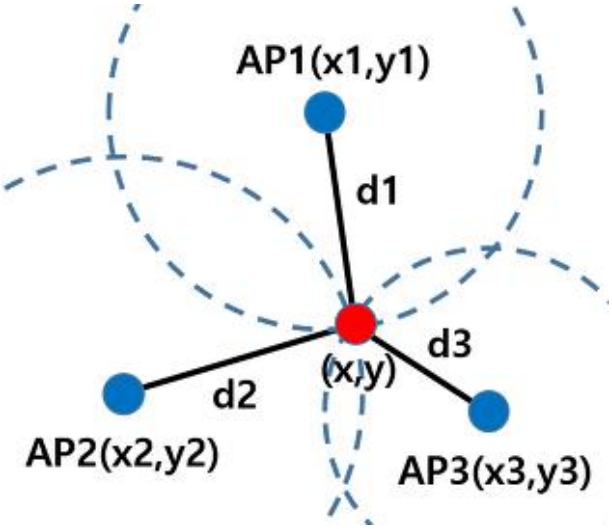

그림 3 AP 좌표 기준 삼각측량법

SUNG KYUN KWAN UNIVERSITY

따라서 각 기준점과 측위 대상과의 거리는 다음과 같이 계산될 수 있다.

$$
\begin{aligned}
d1^2 &= (x - x1)^2 + (y - y1)^2 \\
d2^2 &= (x - x2)^2 + (y - y2)^2 \\
d3^2 &= (x - x3)^2 + (y - y3)^2
\end{aligned}
\tag{1}
$$

여기서 거리 d 는 RSSI 의 신호의 세기, ToA(Time of Arrival), TDoA (Time Difference of Arrival)방식 들을 이용하여 구할 수 있다. ToA 방식은 송신기에서 송신된 신호가 수신기에 도달되는 시간을 인식하여 거리를 측정하는 방식인데 송신기와 수신기의 정확한 시간 동기화가 요구되는 단점이 있다. 신호의 왜곡이나 감쇠가 발생하기 쉬운 실내 NLOS(Non-Line-Of-Sight) 환경에서는 측위 정확도가 떨어지는 단점이 있다.

2. 핑거프린트

핑거프린트 방법은 수집된 정보 기반으로 현재 수집된 정보를 비교하여 확률적으로 위치를 추정하는 기법이다. 주로 공간마다 고유한 정보를 가질 수 있는 Wi-Fi, 비콘의 RSSI 신호의 세기나 실내 공간의 고유한 자기장 크기를 핑거프린트 이미지로 매핑하고 저장하여 측위 추정 정보로 활용한다. 핑거프린트 맵은 Zigbee, Bluetooth, Wi-Fi 다수 sensor data 를 채널로 구성할 수 있다.[10] 핑거프린트 기법은 [그림 4]와 같이 사전에 핑거프린트 이미지로 매핑하는 오프라인 단계(Offline phase)와 현재 수집된 정보를 기반으로 위치를 추정하는 온라인 단계(Online phase)로 나누어 진다.

오프라인 단계에서는 실내 공간을 작은 공간으로 나누고 각 공간에서 AP 로부터 수신된 RSSI 의 신호 세기와 ID, 실제 위치정보를 저장한다. 자기장 기반의 측위 시스템에서는 자기장의 크기와 위치 정보를 저장한다. 각 공간은 작게 분할하여 저장하면 좌표 정밀도가 상승되어 측위 모델의 성능에 따라 더욱 향상된 정확도를 기대할 수 있다.

SUNGKYUNKWAN UNIVERSITY

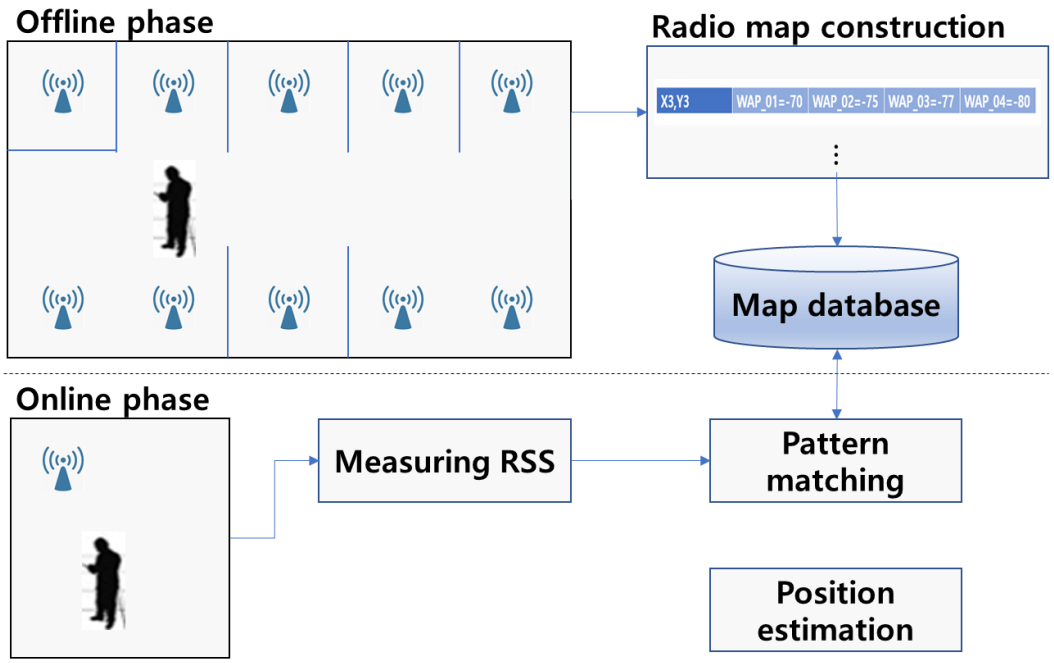

그림 4 핑거프린트 기반 매핑 및 추정 단계

온라인 단계는 현재 수집된 정보 기반으로 측위를 추정하는 단계이다. 추정 알고리즘으로는 대표적으로 k-최근접 이웃 분류기 (k-Nearest Neighbors, k-NN) 알고리즘이 있다. 오프라인 단계에서 구성된 라디오 맵에서 실측되고 있는 현재 정보에 근접한 k 개의 참조위치를 기반으로 현재 위치를 결정한다. k-최근접 이웃 분류기는 하이퍼 파라미터인 k 의 값과 이웃 간 거리측정 도구 및 유사도 측정 방법에 따라 성능의 차이가 있기 때문에 실험 결과에 따라 최적의 도구를 적용할 필요가 있다. [2]

Wi-Fi data set 에 대해 RSS 단일 벡터가 아닌 시계열 RSS vector 를 feature map 으로 만들어 합성곱 신경망의 입력으로 위치를 추정하면 단일 벡터로 측위 하였을 경우보다 더욱 향상된 정확도를 얻을 수 있다. [8] 핑거프린트 맵 구축을 위한 데이터 수집 단계에서 시간차를 두고 RSS 값을 수집하고 핑거프린트 이미지를 재구성함으로써 각 샘플 위치에 대해 더욱 상세하게 표현되어 진다.

SUNG KYUN KWAN UNIVERSITY

Support Vector Machine(SVM)도 추정 기법으로 사용될 수 있다. SVM은 주로 기계학습, 통계분석에 사용되는 정확도가 높은 접근방식으로 데이터 분류 문제에 활용된다. 오프라인 단계에서 RSSI 측정을 통해 위치 추정 문제에 사용되며 커널을 적용하여 위치 분류목표에 수렴함이 보장된다.

3. 보행자 추측 항법(Pedestrian Dead Reckoning , PDR)

추측 항법이란, 관성센서 기반으로 이동 방향 및 거리를 계산하고 실시간으로 위치를 추정하는 기법이다. 이를 기반으로 스마트 기기에 탑재된 관성 센서를 활용하여 보행자의 위치를 추정해 나가는 보행자용 추측 항법은 실내에서 사용자의 위치를 추정하는데 유용하다. PDR은 스마트 기기의 파지 및 팔의 흔들림에 따라 생길 수 있는 오차를 줄이기 위하여 걸음 수 측정(Step counting), 보폭 추정(Step length estimation), 방향 추정(Heading estimation)을 결합하여 보행자의 위치를 추정하는 기법이다. 사용자의 신체적 조건에 따라 결과가 상이하기 때문에 사용자의 키, 몸무게를 입력 받아 신체적 조건에 따른 오차를 최소화하는 기술도 정확도에 영향을 준다. 비교적 편차가 적은 기법이지만 오차가 누적되기 때문에 단독으로 사용되지 않고 다른 실내 측위 기술과 융합하여 사용된다.

SUNG KYUN KWAN UNIVERSITY

제3장 WLAN 기반 측위 방법

본 장에서는 WLAN의 RSSI를 활용한 측위 방법에 대해서 논한다. WLAN RSSI 핑거프린트 맵 구축 단계와 위치 추정 단계를 구분하여 알아보고 RSSI를 활용한 측위 방법의 단점에 대해 제시한다.

제1절 WLAN RSSI 신호 특성

RSSI 는 간단하게 적용할 수 있는 측위 방식 중 하나이다. RSS(Received Signal Strength)는 송수신 전력의 비로 정의되며 수신기에 수신되는 실제 신호 전력의 세기로, 단위는 데시벨-밀리 와트(dBm)으로 표현된다. RSSI 기반 접근법은 간단하고 효율적이지만 실내에서는 벽이나 큰 장애물 혹은 전파 방해로 인한 신호 감쇠 및 다중 경로 전파 현상으로 인해 심각한 RSS 변동이 일어난다. 다음과 같은 실험을 통해 이러한 RSS의 변동 특성을 알아보았다. 정지 상태에서 스마트 폰을 고정 시켜 두고 AP로부터 수신되는 신호세기를 100 번 샘플링 하였다. [그림 5] 는 100개의 RSSI 신호를 나타낸 것이다.

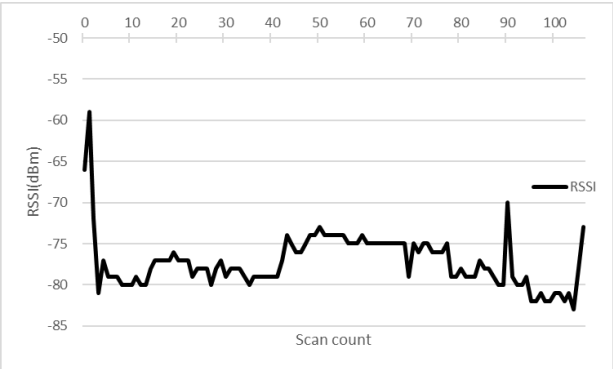

그림 5 고정 상태에서 WLAN RSS 변동

SUNG KYUN KWAN UNIVERSITY

위 결과에 따르면 정지되어 있는 스마트폰에 수신되는 RSSI는 최대 −59dBm 부터 최소 −83dBm까지 변동폭이 심한 것을 확인할 수 있다. 이러한 결과는 앞서 논한 바와 같이 실내에서 발생하는 다중경로 전파의 영향이 크다고 할 수 있다.

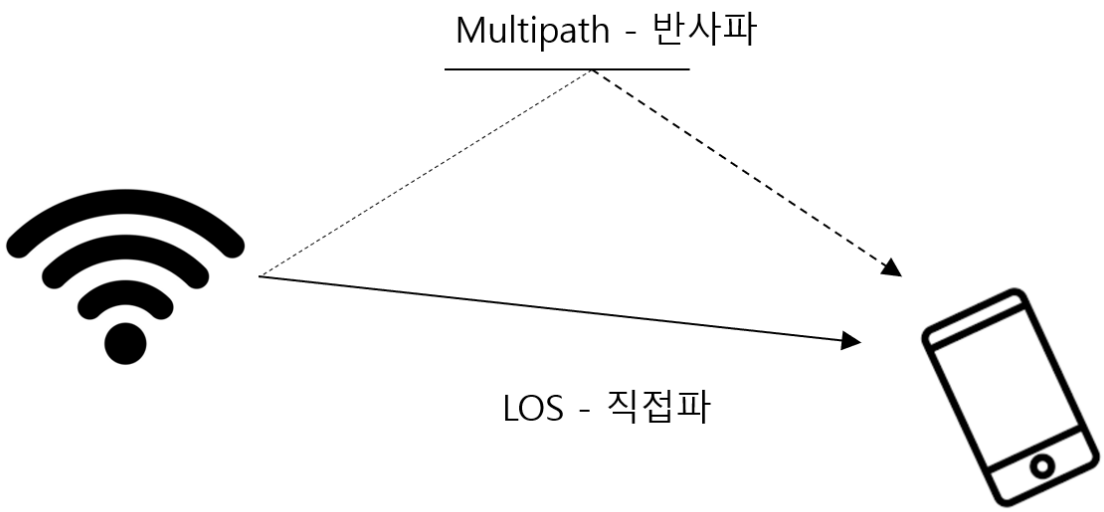

그림 6 실내에서의 다중경로 전파

이러한 특성으로 인해 일반적으로 위치 정확도는 높지 않으며 5m 내외의 오차가 허용되는 서비스에 주로 적용된다.

제2절 RSSI 신호 감쇠 모델

RSSI는 거리에 따라 지수적으로 감쇠하는 특성을 가지고 있다. 이러한 감쇠 특성이 적용된 신호세기와 거리 기반의 측위 방식에는 감쇠 특성을 반영한 다양한 모델이 사용된다. 식 (2) 은 대표적인 신호 감쇠 모델의 하나이다.

SUNGKYUNKWAN UNIVERSITY

$$RSSI = -(10n\log_{10} d + A) \quad (2)$$

WLAN의 RSSI가 거리에 따라 감쇠하는 특성을 분석하기 위해 일정하게 거리를 증가시키며. 스마트폰에 수신되는 RSSI를 측정해보았다. 아래의 표는 거리에 따른 RSSI 신호의 세기를 나타낸 것이다. RSSI는 거리가 멀어짐에 따라 감소하고 표준편차와 분산은 일부 구간을 제외하고 대부분의 구간에서 크게 나타났다.

표 1 거리 변화에 따른 RSSI 측정 결과

거리(m)	평균	표준편차	분산
0.00	-41.82	2.19	4.78
2.25	-46.16	2.51	6.30
4.50	-49.40	2.30	5.29
6.75	-54.27	2.64	6.97
9.00	-59.04	1.92	3.70
11.25	-62.04	2.49	6.20
13.50	-64.78	2.26	5.12
15.75	-69.31	2.71	7.37
18.00	-71.64	1.67	2.78
20.25	-71.42	2.65	7.01
22.50	-71.64	2.80	7.83

위 실험 결과에 따라 WLAN RSSI 신호는 거리 증가에 따라 감쇠가 발생하며 분산과 표준 편차가 큰 데이터인 것을 확인할 수 있다. [그림 7] 는 45cm 마다 RSSI를 샘플링한 결과 그래프이다. RSSI 감쇠 모델과 비교해보면 실내에서의 다중경로 전파 및 신호 간섭

SUNG KYUN KWAN UNIVERSITY

요인에 의해 차이가 발생한다. 이러한 오차로 인해 실제 위치 추정 시 측위 오차를 발생시킬 수 있다. 또한 10m 지점부터 −60dBm에서 −75dBm사이에 많은 샘플 위치가 수집되었음이 확인된다. 이 결과로 단일 AP의 RSSI로 거리 환산 모델은 오차가 커질 수 있다는 것을 알 수 있다.

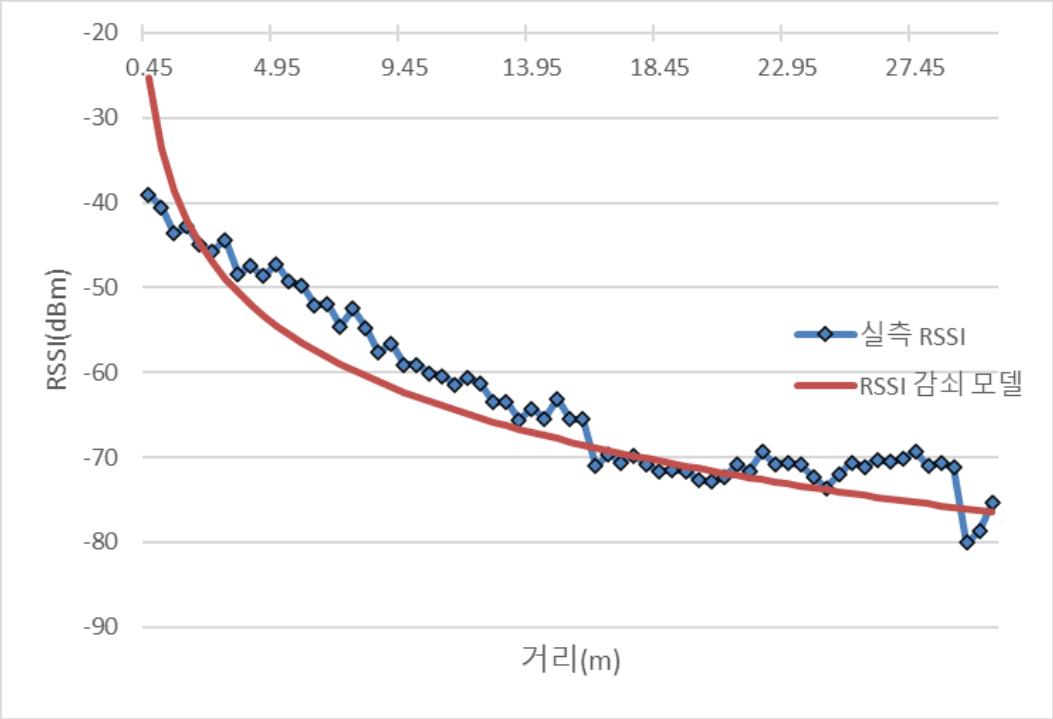

그림 7 RSSI 거리 환산모델 – 실측 RSSI 데이터 비교

제3절 RSSI 핑거프린팅 측위 방법

WLAN기반 RSSI를 활용한 핑거프린팅 측위 방법은 목표로 하는 지역을 임의의 표본 위치로 나누고 각 표본 위치마다 WLAN의 RSSI를 측정하여 핑거프린트 맵을 구축하는 오프라인 단계(Off−Line Phase)와 측위 정확도 향상을 위해 핑거프린트 맵을

SUNGKYUNKWAN UNIVERSITY

재구성하는 단계, 핑거프린트 맵을 기반으로 패턴 매칭 기법을 활용하여 위치를 추정하는 온라인 단계(On-Line Phase)로 나누어 진다. 본 절에서는 오프라인 단계와 핑거프린트 맵 재구성 단계, 온라인 단계로 나누어 논한다.

1. 핑거프린트 오프라인 단계

실내 환경에서 정확도 높은 측위를 달성하기 위해서는 정밀한 매핑 이 선행되어야 한다. 그림 2와 같이 핑거프린팅 방식은 사전에 목표로 하는 장소에서 WLAN의 RSSI를 수집하게 된다. 이 때, 장소를 목표로 하는 정밀도로 구획을 나누고 각 위치마다 순차적으로 데이터를 수집한다.

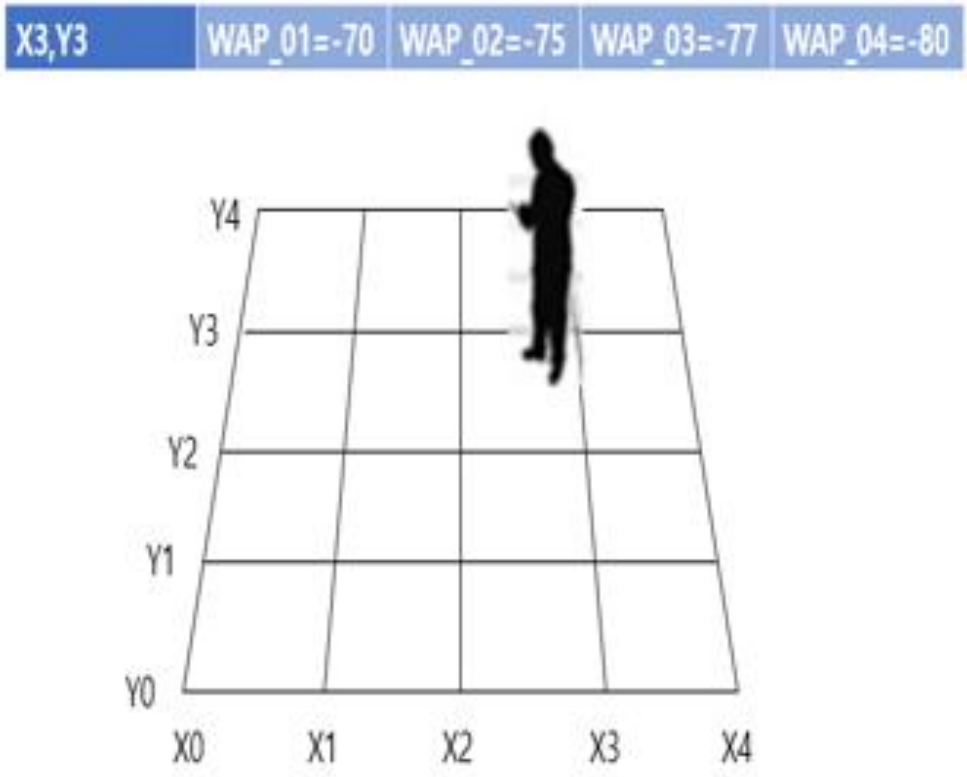

그림 8 오프라인 단계 데이터 수집 모습

SUNG KYUN KWAN UNIVERSITY

구획을 조밀하게 나누고 많은 데이터를 수집할수록 측위 정확도가 높아질 가능성이 커지기 때문에 데이터 수집하는 오프라인 단계에서 많은 시간 비용이 소모된다. 이러한 사전 조사 비용을 줄이기 위해 자동으로 라벨링된 RSSI 데이터를 취득하는 기술도 연구되었다.[6] 핑거프린팅 방식의 적용은 사전 조사 비용에 비례하게 높은 측위 정밀도를 얻을 수 있다는 점 때문에 WLAN RSSI data 뿐만 아니라 무선전파 및 자기장 세기 데이터의 매핑까지 확장성 있는 방법론이다. 표[2] 는 수집된 핑거프린트 맵의 예를 나타낸다.

표 2 WLAN RSSI 핑거프린트 맵 예시

좌표 (X,Y)	RSSI(dBm)		
	AP 01	AP 02	AP03
(X1,Y1)	−40	−55	−78
(X1,Y2)	−41	−55	−80
(X1,Y3)	−44	−57	−77
(X2,Y1)	−42	−50	−77
(X2,Y2)	−44	−58	−75
(X2,Y3)	−45	−58	−80
(X3,Y1)	−40	−55	−80
(X3,Y2)	−42	−55	−78
(X3,Y3)	−43	−55	−78

SUNGKYUNKWAN UNIVERSITY

2. 핑거프린트 맵 재구성 단계

WLAN 기반 RSSI를 활용한 실내 측위 연구분야에서는 각 샘플 위치의 이미지 패턴을 더욱 정교하게 하여 정확도를 높이고자 하였다. 앞선 연구에서 각 샘플 위치의 이미지 패턴을 더욱 깊게 하는 방법으로 RSSI의 입력을 시계열 입력으로 재구성하여 정확도 향상의 결과를 얻었다.[8] 입력 핑거프린트 맵의 재구성은 정확도 향상의 방법이 될 수 있다. 각 좌표에서 얻어진 WLAN AP의 RSSI는 위의 표와 같이 1차원 벡터로 구성된다. 모든 좌표가 누적되면 한 장의 2차원 핑거프린트 이미지 F^W 가 생성된다. F^W는 m개의 AP RSSI 와 n개의 좌표 $m \times n$형태로 저장된다.

$$F^W = \begin{bmatrix} RSSI_{11} & \cdots & RSSI_{1n} \\ \vdots & \ddots & \vdots \\ RSSI_{m1} & \cdots & RSSI_{mn} \end{bmatrix} \tag{3}$$

2차원 핑거프린트 이미지 F^W에서 이미지 맵을 추출하고 위치를 추정할 수 있으나 동일한 좌표에서 시계열 누적된 data를 수집하여 핑거프린트 이미지를 생성하면 더욱 향상된 정확도를 얻을 수 있다. 각 좌표에서 F^{Wt}와 같은 시계열 RSSI data를 수집하여 2차원 핑거프린트 이미지를 생성하면 3차원 핑거프린트 이미지 F를 구축하여 측위 모델에 더욱 고도화된 이미지로 측위 할 수 있다.

$$F^{Wt} = \begin{bmatrix} RSSI_{11} & \cdots & RSSI_{1t} \\ \vdots & \ddots & \vdots \\ RSSI_{m1} & \cdots & RSSI_{mt} \end{bmatrix} \tag{4}$$

$$F = \begin{bmatrix} F_1^{Wt} \\ \vdots \\ F_m^{Wt} \end{bmatrix} \tag{5}$$

정확도 향상을 위한 핑거프린트 맵 재구성 방법으로 맵 슬라이딩 방식이 있다. 맵 슬

SUNG KYUN KWAN UNIVERSITY

라이딩은 핑거프린트 맵에 대한 데이터 확장 기법의 적용을 의미한다. [그림 9]에서 맵 슬라이딩의 실시 예를 나타낸다. 앞서 논하였던 식[5] 와 같이 샘플 위치 한 점에서의 이미지 F가 아니라 X축으로는 X0에서 X5까지 Y축으로는 Y0에서 Y5까지 5×5 크기의 이미지 F_1을 만든다. 그리고 한 칸 슬라이딩 하여 이미지 F_2를 만들면 핑거프린트 이미지의 해상도를 높일 수 있고 측위 모델에 입력의 양도 늘릴 수 있다. 이 때, 각 실내 측위 시스템의 목표 정밀도에 알맞게 슬라이딩 길이를 정하고 이미지를 재구성할 수 있다.

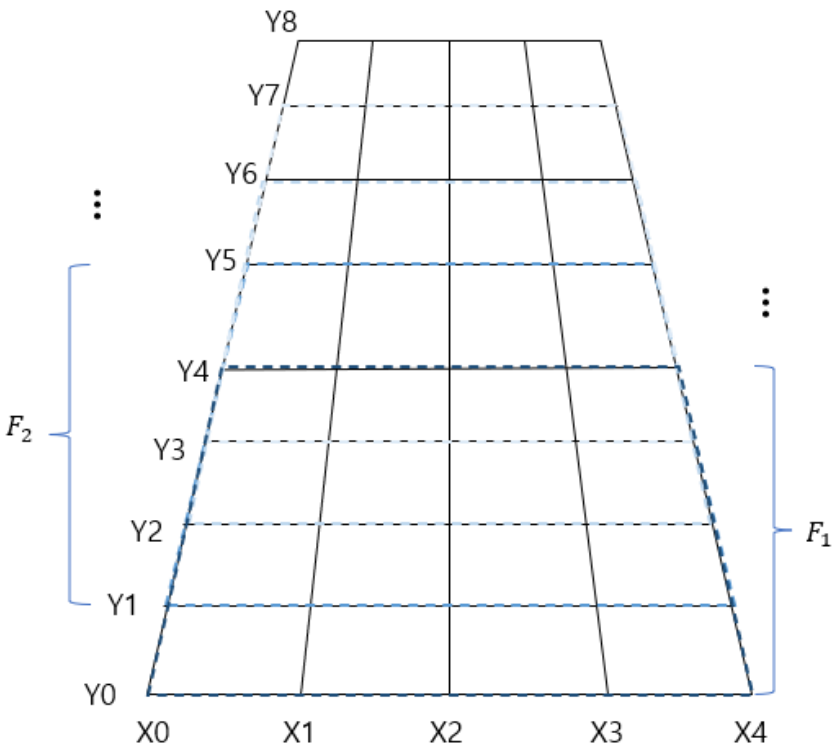

그림 9 맵 슬라이딩 실시 예

핑거프린트 맵 슬라이딩을 [그림 9] 와 같이 적용할 경우 좌표 정밀도는 줄어들지만 입력 데이터의 양이 4배 증가되는 효과를 볼 수 있다. WLAN RSSI, BLE 와 같이 단일

SUNGKYUNKWAN UNIVERSITY

기술로 낮은 정확도를 갖거나 환경영향을 받는 전파 기술의 경우 입력데이터의 정밀도를 줄이는 동시에 데이터 확장을 통해 정확도 향상 효과를 기대해 볼 수 있다. 이는 데이터 개수가 적을 때 더욱 효과적인 기법이 될 수 있다. [식 5]는 [식4]의 각 샘플 위치 별로 맵 슬라이딩 방식 적용된 핑거프린트 이미지 F의 재구성을 나타낸다.

$$F_1 = \begin{bmatrix} F_{X0Y0} \\ \vdots \\ F_{X4Y4} \end{bmatrix} \tag{5}$$

3. 핑거프린트 온라인 단계

온라인 단계에서는 구축된 RSSI 핑거프린트 맵을 기반으로 위치 분류를 목표로 하는 위치에서 수집된 RSSI 데이터를 패턴 매칭 기법 기반 분류기법으로 위치를 추정한다. 온라인 단계에서 위치를 추정하기 위해 k-최근접 이웃 분류기 (k-Nearest Neighbors, k-NN)가 자주 사용된다. k-최근접 이웃 분류기는 매우 적용이 간단하면서 효과적이어서 많이 이용된다.

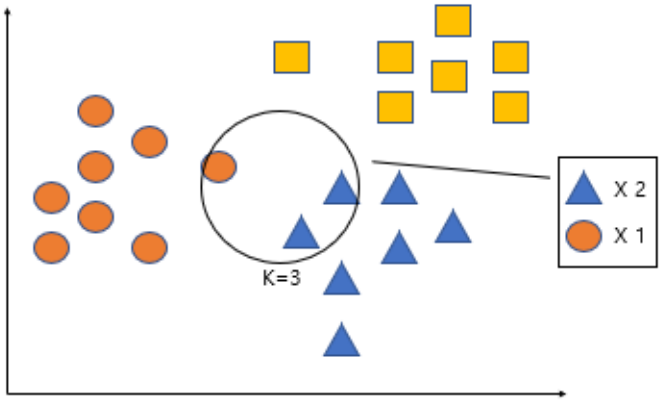

그림 10 k-최근접 이웃 분류기

SUNG KYUN KWAN UNIVERSITY

[그림 10] 에 표현된 k-최근접 이웃 분류기는 크게 3단계로 진행된다. 첫째, 숫자 k와 거리 측정 기준을 선택한다. 둘째, 분류하려는 샘플에서 k개의 최근접 이웃을 찾는다. 셋째, 다수결 투표를 통해 클래스 레이블을 할당한다. 이 단계에 따라 레이블이 할당된다. 이러한 학습 기반이 아닌 데이터 셋을 메모리에 저장하는 메모리 기반의 분류기는 빠르게 적용하여 결과를 볼 수 있다는 장점이 있는 반면 대규모 데이터에서 공간 복잡도가 증가하고 그에 따라 계산 복잡도도 커지는 문제점이 있다. 거리를 측정하는 기준은 2차원 좌표 공간에서 오차를 직관적으로 표현하는 [식 6] 의 유클리디안 거리가 사용된다.

$$\sqrt{(x_1 - x_2)^2 + (y_1 - y_2)^2} \tag{6}$$

또 다른 추정 기법으로 인공신경망(Artificial Neural Networks, ANN)이 많이 사용되고 있다. 일반적으로 여러가지 분류, 회귀 문제에 활용되는 ANN 은 측위를 위해 사용할 수 있다. 하나 이상의 은닉층이 있는 MLP(Multi-Layer Perceptron)은 측위를 위해 일반적으로 사용되는 ANN 이며 오프라인 단계에서 RSSI 측정을 기반으로 훈련되어야 한다. MLP 기반 측위에서 RSSI 입력 벡터는 훈련된 은닉층의 가중치와 곱해지고 편향이 더해져 사용자의 위치를 얻을 수 있다.

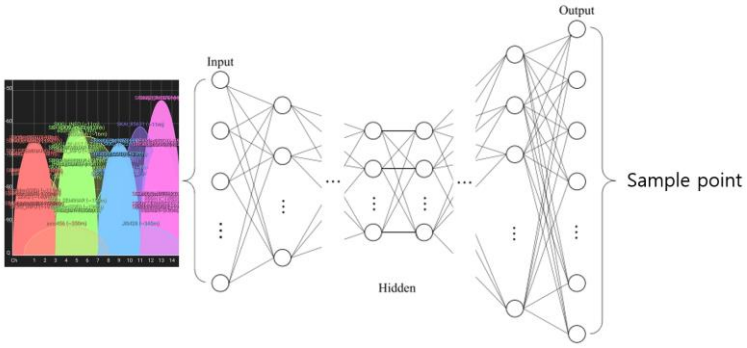

그림 11 WLAN RSSI 입력 신경망

SUNGKYUNKWAN UNIVERSITY

이미지 분류에 주로 사용되는 합성곱 신경망(Convolution Neural Networks , CNN)은 이미지의 특성을 찾는데 중요한 정보인 픽셀은 유지하고 불필요한 정보는 배제할 수 있기 때문에 정확도 성능을 향상시키는데 유리하여 핑거프린팅 기반 실내 측위 분야에서 많이 채택되고 있다. [그림 12]는 합성곱, 풀링, 활성화 함수, 완전 연결 계층을 포함하는 CNN 기반 모델을 나타낸다. CNN은 시계열 데이터 혹은 이미지를 학습하는데 특화된 신경망이다. 일반적으로 CNN은 한 개 이상의 합성곱 계층이 완전 연결 계층과 연결된다.

일반적으로 합성곱 계층은 3단계로 구성되는데 첫번째는 랜덤하게 초기화 된 합성곱 윈도우를 통해 더욱 고도화된 이미지를 생성하기 위해 입력 핑거프린트 이미지를 스캔하는 단계, 두번째는 생성된 이미지를 단순화 하는 풀링 단계, 마지막으로 ReLu 와 같은 비선형 활성화 함수로 구성된다. 그리고나서 완전 연결 계층을 거쳐 최종 출력을 얻을 수 있다.

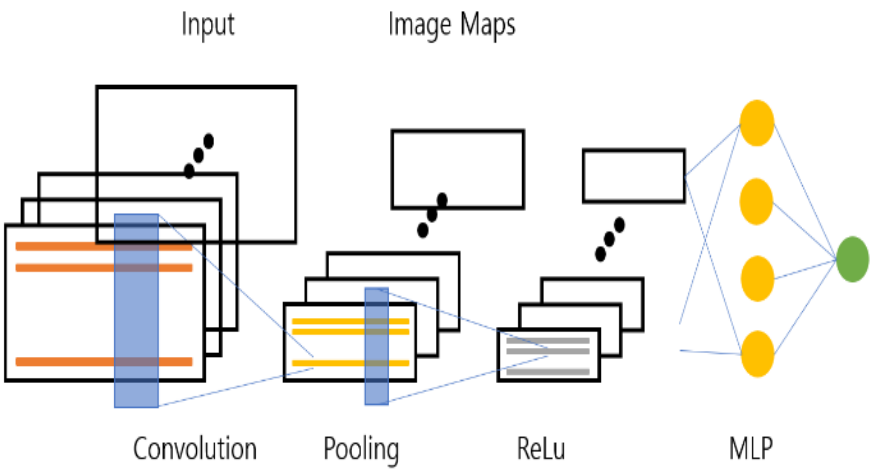

그림 12 합성곱 신경망

SUNGKYUNKWAN UNIVERSITY

제4장 지구자기장 기반 측위 방법

본 장에서는 자기장의 세기를 활용한 측위 방법에 대해서 논한다. 실내에서의 자기장의 분포 특성과 신호 특성에 대해 조사하고 자기장 기반 측위 방법에 대해 정의하고 그 문제점에 대해 정의한다.

제1절 자기장 신호 특성

지구상 어디에나 형성되는 자기장은 실내에서 철골 구조물이나 전자장비의 영향으로 왜곡되어 공간마다 고유한 패턴을 지닌다. 데이터에 공간을 나타낼 수 있는 특징이 있다는 것은 측위 모델을 통한 분류가 가능하다는 것을 의미한다.

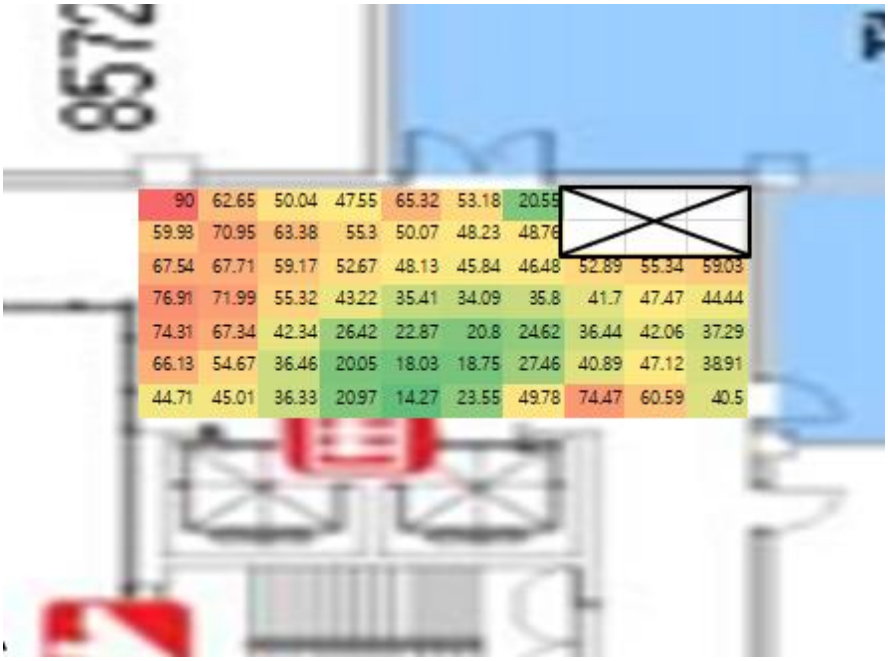

그림 13 실내에서의 자기장 분포

SUNG KYUN KWAN UNIVERSITY

[그림 13] 은 특정 공간의 자기장의 세기를 보여준다. 한 공간 내에서도 최저 14.27uT부터 최고 90uT까지 다양하게 분포한다. 특히 유독 큰 값이나 작은 값으로 측정되는 위치는 랜드마크로도 사용될 수 있다. 이러한 자기장 데이터는 스마트폰에 내장된 자기장 센서로 쉽게 얻을 수 있어 접근성이 좋을 뿐만 아니라 짧은 주기의 샘플링 시간으로 자기장 데이터를 얻을 수 있기 때문에 실시간 측위에 효과적이다. [그림 14] 는 스마트폰에 내장되어 있는 3축 자기장 센서의 축 정의와 10ms 단위로 수집된 자기장 데이터이다. 앞서 수집되었던 [그림 5] 의 WLAN의 RSSI와는 다르게 자기장 센서의 3축 출력이 모두 표준편차 0.4 정도로 정지 상태에서 편차가 작고 안정적인 신호를 출력한다. 하지만 자기장 센서의 3축은 스마트 폰의 자세에 영향을 받기 때문에 자세가 고정되어 있지 않은 환경에서는 [식 7]의 자기장의 크기 데이터를 활용한다.

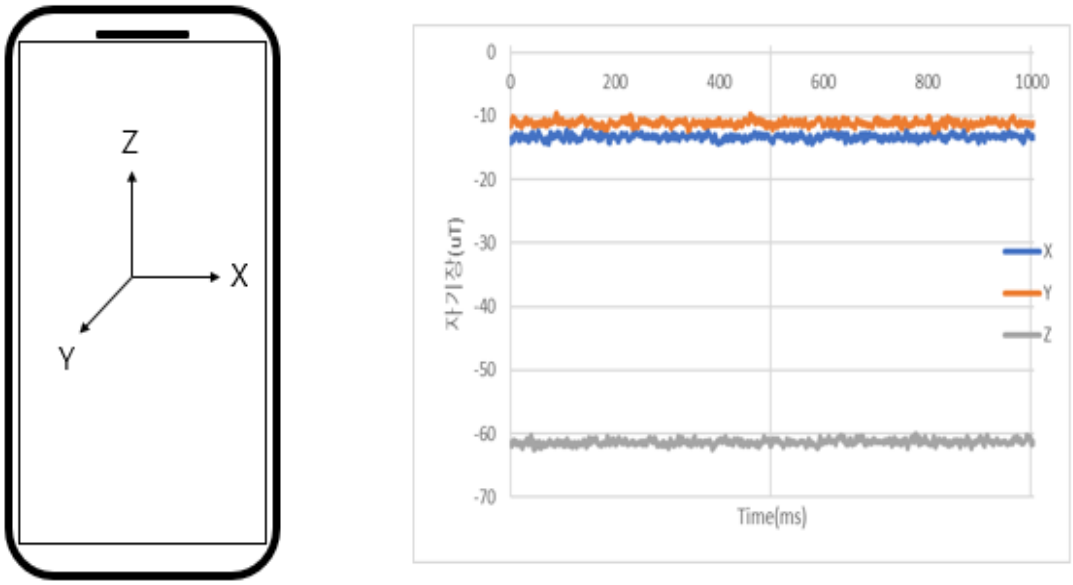

그림 14 고정 상태에서 자기장 세기 변동

SUNGKYUNKWAN UNIVERSITY

표 3 자기장 세기 수집 결과

축	평균	표준편차	분산
X	−13.30	0.40	0.16
Y	−11.10	0.43	0.18
Z	−61.37	0.40	0.16

$$Magnetic = \sqrt{(X_{mag})^2 + (Y_{mag})^2 + (Z_{mag})^2} \quad (7)$$

자기장 데이터는 정지상태에서 지속적이고 안정적인 신호를 얻을 수 있을 뿐 아니라 시간의 변화에도 안정적인 패턴을 유지하는 특성을 가진다. 앞서 논한바와 같이 실제 자기장 패턴은 건물의 철골 구조물이나 전자기기에 영향을 받기 때문에 전기공사와 같은 대규모 공사가 없으면 자기장 패턴에 영향을 미치지 않아 한번 수집한 핑거프린트 맵을 기반으로 장기간 측위 안정성을 보장한다.

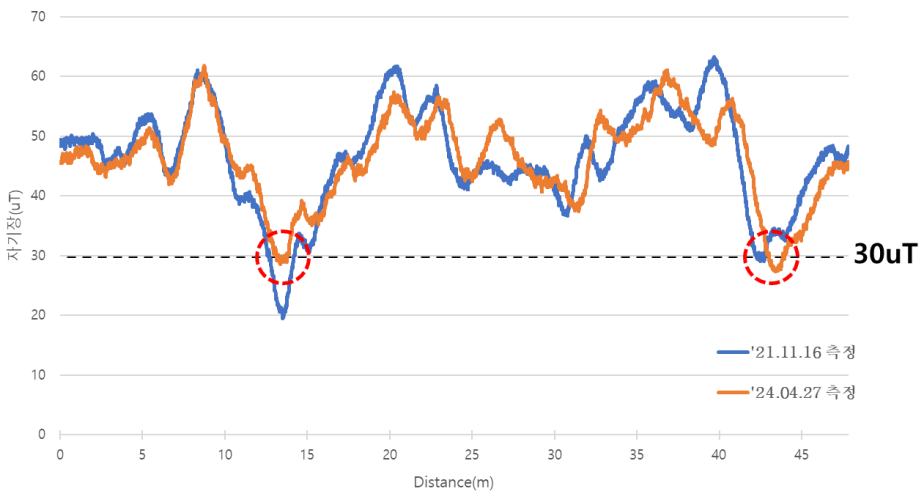

그림 15 시간 변화에 따른 자기장 분포 변화

SUNGKYUNKWAN UNIVERSITY

[그림 15] 은 같은 이동 경로에서 5개월간의 시간 간격을 두고 측정된 자기장의 세기를 나타낸다. 각 자기장 세기 그래프는 시간의 흐름과 관계없이 유사한 패턴을 보여 오랜 기간 측위 모델의 기반 데이터로 활용할 수 있음을 알 수 있다. 반면, 저차원의 데이터 이기 때문에 같은 크기의 자기장 데이터가 여러 위치에서 수집되기 때문에 바로 위치로 변환할 수 없다는 문제점이 있다. [그림 15] 에서 보이는 바와 같이 30uT 자기장 세기 데이터는 13m 위치와 42.5m 위치에서 모두 감지된다. 따라서 차원이 낮은 특성을 가지는 자기장 세기 데이터에 적합한 측위 방법이 필요하다.

제2절 자기장 세기 핑거프린팅 측위 방법

앞서 논한바와 같이 자기장 세기는 차원이 낮은 특성을 가지는 데이터이기 때문에 측위를 목표로 하는 공간의 특성을 잘 나타낼 수 있도록 변환할 필요가 있다. 그 목적을 달성하기 위해 수집된 자기장 세기 핑거프린트 맵을 기반으로 경로 데이터를 생성하고 실내에서 이동하는 사용자의 경로를 추적하는 측위 모델에 적용하는 연구가 활발히 진행되었다. [6]

자기장 세기 핑거프린트 맵이 없는 상태에서 측위 모델의 입력이 되는 경로데이터를 수집하는 일은 시간 비용이 많이 든다. 사용자의 이동경로는 정해져 있지 않고 무작위로 움직이기 때문에 측위를 목표로 하는 장소가 커짐에 따라 패턴 매칭을 위해 필요한 경로의 수는 기하급수적으로 늘어나게 된다. 자기장 세기 핑거프린트 맵 기반 실내 측위에서는 무작위로 경로를 생성해냄으로써 경로데이터를 실제로 수집하는데 드는 비용을 줄일 수 있다. 계획된 경로 계획에 따라 많은 양의 데이터를 비교적 간단하게 얻을 수 있다. [그림 16] 는 핑거프린트 맵의 경로 생성 예이다. 계획된 경로 Path1, Path2가 있고 경로에 따라 자기장 세기 시퀀스가 생성되었다. 생성된 2개의 경로 자기장 시퀀스 벡터는 위치를 나타내는 뚜렷한 패턴을 나타낼 수 있다. 자기장 벡터는 시퀀스가 길어질수록 현재 위치를 정확하게 식별할 수 있다.

SUNG KYUN KWAN UNIVERSITY

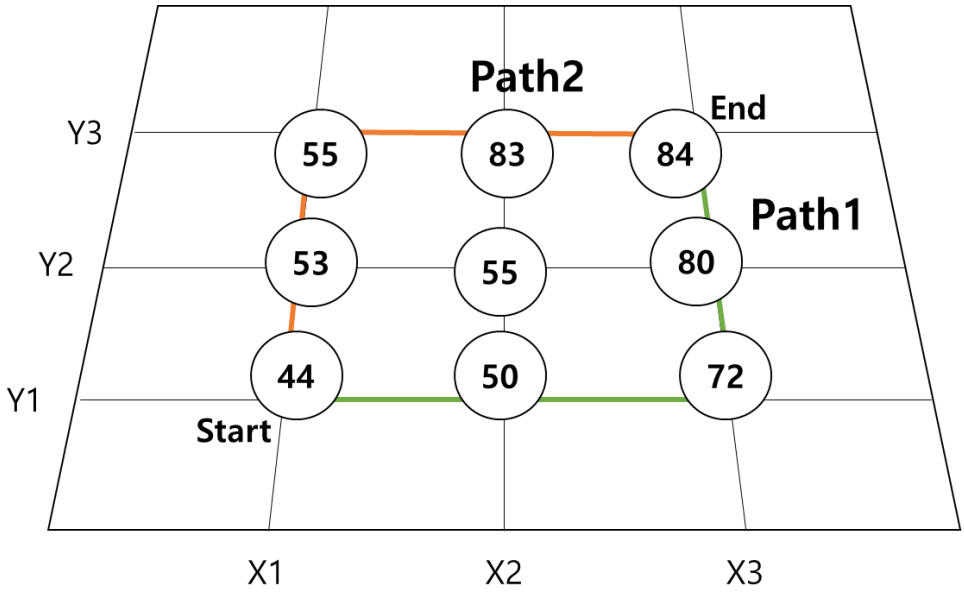

그림 16 핑거프린트 맵 기반 무작위 경로 생성 예시

표 4 생성된 경로 결과

	Step1	Step2	Step3	Step4	Step5
Path1	44	50	72	80	84
Path2	44	53	55	83	84

사용자의 다양한 연속적인 이동 경로에 따라 생성된 자기장 시계열 데이터의 유사도 측정에는 길이가 다른 시계열 입력에도 좋은 성능을 갖는 DTW(Dynamic Time Warping)와 RNN이 주로 사용된다. 특히 자기장 이동 패턴을 학습하는 인공신경망으로 시계열 시퀀스 데이터의 성질을 충분히 학습 가능한 순환 신경망이 측위 모델로 좋은 성능을 발휘한다. RNN의 특징은 순환하는 닫힌 경로가 있다는 것이다. 순환 경로를 따라 데이터가 끊임없이 순환 되기 때문에 현재 입력 데이터를 처리할 수 있을 뿐 아니라 과거의 시퀀스 정보를 기억하여 현재 입력데이터가 같더라도 과거의 시퀀스 입력이 다르면 구분할 수 있다.

SUNGKYUNKWAN UNIVERSITY

[그림 17] 와 같이 자기장 시퀀스 벡터는 순환경로를 갖는 RNN 셀의 입력이 되어 추정 위치 h1을 출력한다. 시계열 데이터 $(x_0,\ x_1,\ x_2, \cdots, x_t)$의 입력에 대응하여 $(h_0,\ h_1,\ h_2, \cdots, h_t)$ 가 출력된다. 각 입력 시점의 RNN 셀은 해당 셀로의 입력과 이전 셀의 출력을 받아 현 시점의 출력을 계산한다. 이 RNN 셀 출력은 [식 7]과 같다

$$h_t = \tanh(h_{t-1}W_h + x_tW_x + b) \tag{7}$$

[식 7] 은 기본 RNN 셀 출력으로 입력 x에 대한 가중치 W_x, 이전 RNN 셀의 출력 h에 대한 가중치 W_h 그리고 편향 b로 구성된다.

기본 RNN 셀로 구성된 인공신경만으로도 자기장 세기 시퀀스 벡터의 학습이 가능하고 측위 모델에 적용이 가능하지만 시퀀스가 길어질 경우 기울기 소실 혹은 기울기 폭발 현상이 발생하여 장기 기억을 제대로 처리하지 못하기 때문에 GRU, LSTM 같이 게이트가 추가된 RNN이 채택되기도 한다.

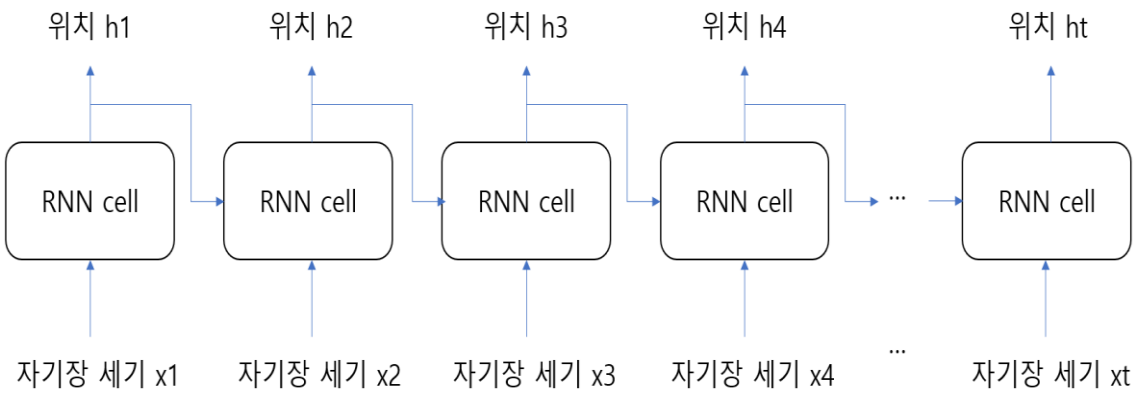

그림 17 자기장 세기 입력 순환 신경망

SUNG KYUN KWAN UNIVERSITY

제5장 실내 측위 시스템 설계

본 장에서는 자기장의 세기와 WLAN RSSI 기반의 핑거프린팅 측위 기법이 적용되는 실내 측위 시스템의 설계에 대하여 논한다. 오프라인 단계에서 보급률이 높은 안드로이드 OS 기반의 스마트 폰을 통해 핑거프린트 맵을 구축하기 위한 시스템 설계와 온라인 단계에서의 측위 모델 설계를 표현한다.

제1절 서버 클라이언트 측위 모델

본 절에서는 오프라인 단계에서의 핑거프린트 맵 구축을 위한 데이터 수집과 온라인 단계에서의 실내 측위를 위한 서버 클라이언트 모델을 제시한다. 먼저 측위 시스템의 요구사항에 따라 필요한 데이터를 정의한 후 클라이언트와 서버의 역할을 정의한다. 본 논문에서는 WLAN RSSI와 자기장 세기가 기반 데이터이며 엣지 디바이스인 스마트폰에서 측위 모델 학습 및 위치 추정을 하지 않고 서버에서 측위 연산하는 시스템 구조를 가진다. 따라서 서버에 위치 좌표마다 WLAN RSSI, 자기장 세기로 구성된 핑거프린트 맵 정보를 가진 데이터 베이스를 유지할 필요가 있다.

1. 서버 클라이언트 구조

대부분의 안드로이드 스마트폰에는 가속도 센서, 각속도 센서, 지자기 센서가 포함된 관성측정장치(Inertia Measurement Unit, IMU)와 Wi-Fi 모듈이 내장되어 있다. 또한 안드로이드 OS는 각 모듈데이터에 접근하고 데이터를 활용할 수 있도록 API(Application Programming Interface)를 제공한다. 클라이언트에서는 'WifiManager', 'SensorManager' 클래스를 통해 데이터를 수집한다. [그림 18] 와 같이 서버는 클라이언트로부터 각 좌표마다 RSSI, 자기장 세기, 걸음 수 정보를 수신

SUNG KYUN KWAN UNIVERSITY

받아 핑거프린트 맵 구축 목적으로 파싱 된다. 파싱된 데이터는 핑거프린트 맵 데이터베이스에 저장되며 오프라인 단계에서 측위 모델의 훈련 및 테스트에 활용된다. 온라인 단계에서는 Step 감지 모듈의 이벤트마다 클라이언트와 서버는 비동기적 데이터 패킷을 송수신하고 서버에서 위치 추정 단계를 거친다.

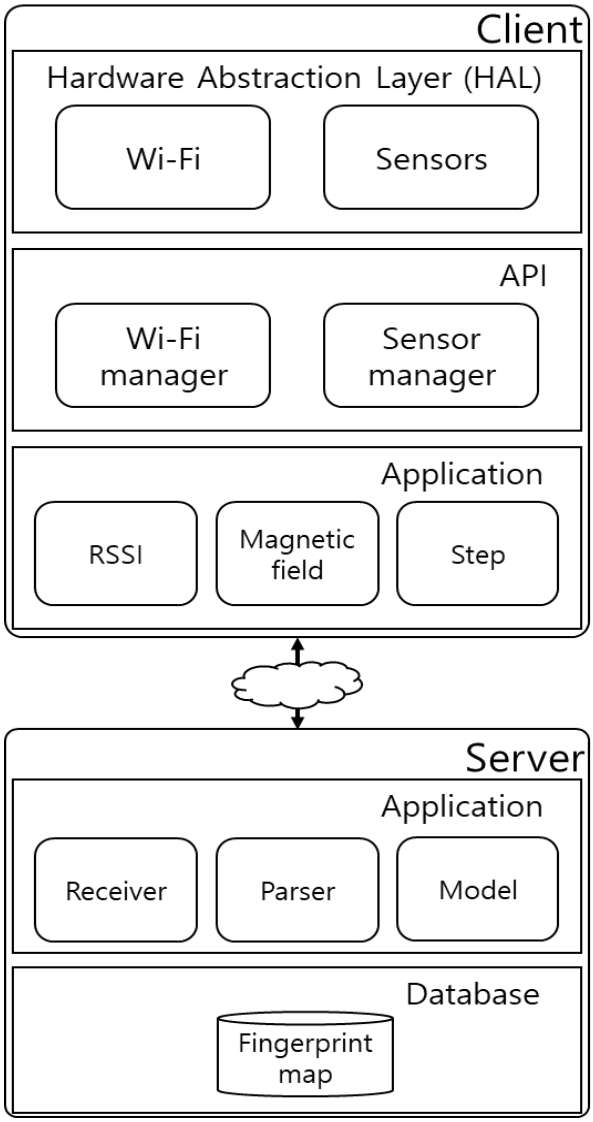

그림 18 측위모델 시스템 구조

SUNGKYUNKWAN UNIVERSITY

2. 데이터 프로토콜과 데이터베이스

'WifiManager'클래스의 메서드인 'startScan()' 호출로 AP 스캔을 진행하면 각 AP의 고유한 MAC(Media Access Control)주소 값인 BSSID(Basic Service Set Identifier)와 RSSI를 나타내는 level을 얻을 수 있다. 지자기 센서의 자기장 세기 X축, Y축, Z축의 결과는 'SensorManager' 객체를 통해 값 변화 시 마다 업데이트 된다. 클라이언트 어플리케이션에 업데이트 된 데이터는 [표 5] 과 같은 패킷 프로토콜로 서버로 송신된다. 송신 시각과 데이터 수집위치를 포함하여 자기장 세기, 수신된 모든 AP의 RSSI이 패킷으로 구성된다.

표 5 서버-클라이언트 프로토콜

Time	Pos. X	Pos. Y	Mag. X	Mag. Y	Mag. Z
2022-03-22 12:00:00 PM	100	100	-30	25	55
	BSSID 01	**RSSI 01**	…	**BSSID x**	**RSSI x**
	70:5d:cc:ae:8c:ee	-37	…	xx	xx

본 연구에서는 WLAN RSSI의 시계열 데이터 구축을 위해 하나의 샘플 위치에서 5번 스캔 수행하였다. 수신된 패킷 중 WLAN 데이터는 BSSID와 RSSI 속성으로 이미지를 구성하고 자기장 세기 데이터는 스마트폰의 자세 영향을 최소화하기 위해서 자기장 세기 값을 활용한다.

표 6 핑거프린트 맵 데이터 베이스

TIME	Pos. X	Pos. Y	Mag. X	Mag. Y	Mag. Z	Mag Vec	WAP 01	…	WAP 02
20:06.2	0	3	-28	-44.9	43.6	68.5636	-70	…	-55
20:10.2	0	3	-28.6	-45.4	41.5	67.8334	-72	…	-53
20:14.0	0	3	-28.5	-45.7	41.2	67.8099	-70	…	-54

SUNGKYUNKWAN UNIVERSITY

20:18.1	0	3	-28.9	-47.1	41.5	69.1077	100	…	100
20:21.9	0	3	-29.1	-47.2	42.1	69.6208	100	…	100
48:19.2	57	26	-7.4	20.3	-18.7	28.5752	100	…	100
48:22.9	57	26	-7.9	19.9	-18.8	28.4932	100	…	100
44626.6	57	26	-8.6	19.5	-18.7	28.3531	100	…	100
44626.6	57	26	-9.4	18.7	-18.7	28.0667	100	…	100
44626.6	57	26	-8.2	19.5	-18.9	28.3672	100	…	100

[표 6] 는 완성된 핑거프린트 이미지를 나타내며 서버의 데이터 베이스에 저장된다. 데이터 베이스를 기반으로 측위 모델의 훈련 및 테스트를 수행한다.

3. 측위 모델

시계열 WLAN RSSI 데이터 구축에 따른 시간 소요로 인해 실시간 추적에 적용하기 어려운 점과 자기장 세기 기반 추적 시스템의 초기에 높은 오차를 갖는 단점을 보완하기 위해 점진적 측위 모델을 제시한다. WLAN RSSI 기반 CNN 측위 모델과 자기장 세기 기반 RNN 측위 모델의 구조를 설명하고 통합된 구조를 논한다.

가. WLAN RSSI 를 활용한 CNN 측위 모델

[그림 19]은 CNN 기본 구조를 기반하여 모델링한 측위 모델을 도식화 하였다. 입력 이미지는 1 채널의 시계열 5 행과 감지된 933개의 AP 열로 구성된다. 실내 좌표 계획에 따라 나누어진 각 좌표에서 5번의 스캔 및 RSSI 수집이 진행되었고, 전 구간에 걸쳐 총 933 개의 AP가 감지된 결과이다.

입력 이미지는 합성곱 계층과 완전 연결 계층을 거쳐 최종 2축의 좌표를 output으로 얻는다. 이 CNN기반 측위 모델은 최종 output을 RSSI가 취득되었던 좌표 레벨의 정밀도를 목표로 한 모델이다.

SUNG KYUN KWAN UNIVERSITY

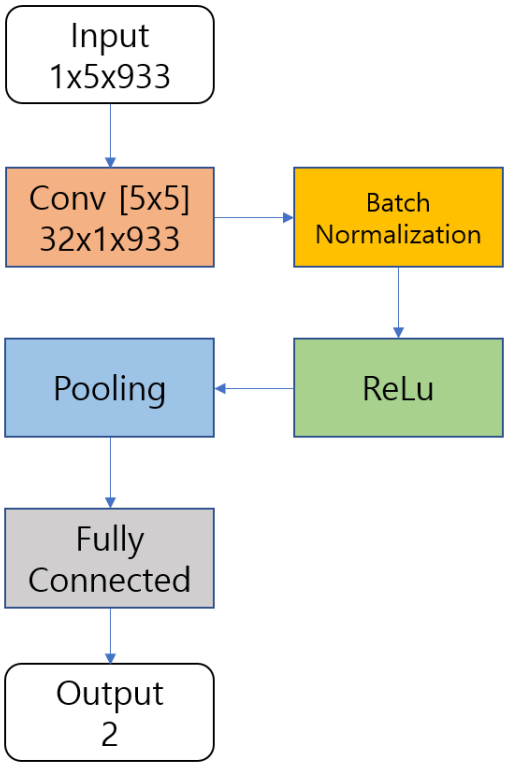

그림 19 CNN 기반 RSSI 입력 측위 모델

나. 자기장 세기를 활용한 RNN 측위 모델

사용자 위치를 추적하는 측위 모델로 시계열 시퀀스 학습에 뛰어난 성능을 보이는 RNN이 채택된다. 실시간 측위를 보장하기 위해 시퀀스 모델은 Synched Many to Many 구조를 갖고 긴 시퀀스에서도 과거의 입력이 잘 전달되는 LSTM 셀로 구성된다. RNN은 학습에 필요한 데이터를 시퀀스로 입력 받기 때문에 정해진 길이의 시퀀스가 필요하다. 실내 측위 모델에서는 시퀀스의 길이가 사용자의 걸음 수를 나타내며 50 걸음을 시퀀스 길이로 정의하였다. 전체 구조는 [그림 20] 와 같이 시퀀스 길이 50의 입력을 받아 3개 층을 갖는 RNN 계층과 완전 연결 계층을 거쳐 각 걸음마다 좌표 출력을 갖는다.

SUNG KYUN KWAN UNIVERSITY

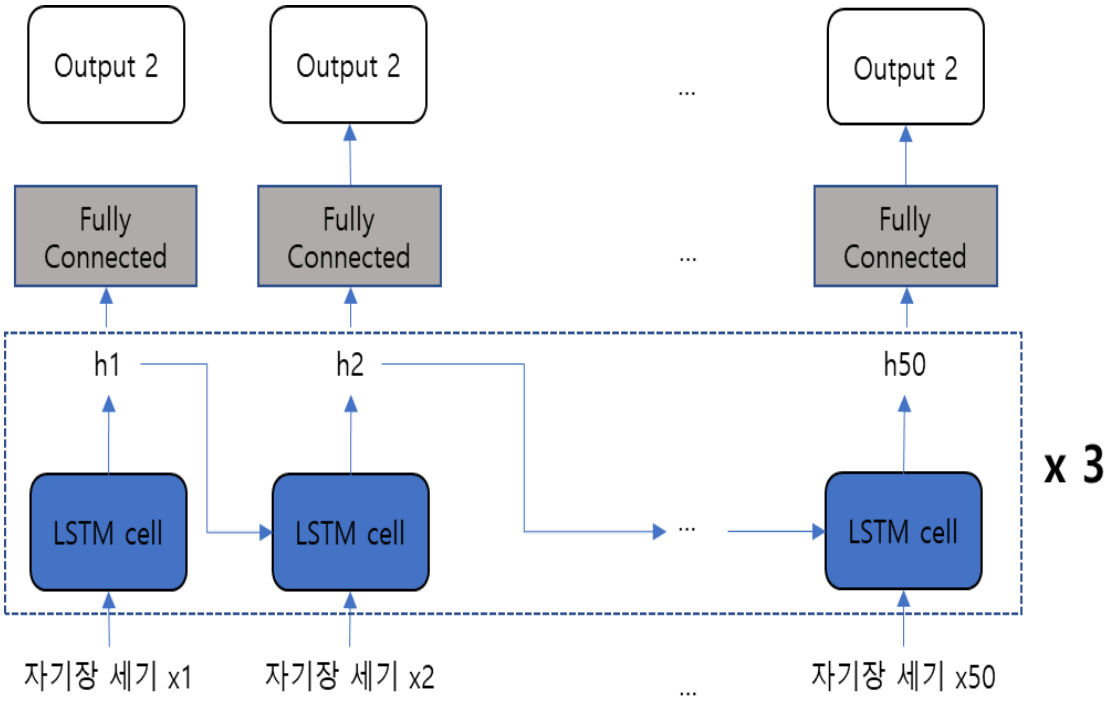

그림 20 RNN 기반 자기장 세기 입력 측위 모델

RNN 모델을 훈련시키기 위해 많은 수의 경로데이터가 필요하기 때문에 실제 사용자가 실내에서 경로를 이동하면서 경로데이터를 생성하는 것은 시간 비용이 많이 든다. 따라서 훈련에 사용되는 경로데이터는 수집된 자기장 세기 핑거프린트 맵 기반으로 무작위로 생성하며 그 과정은 다음과 같다. 첫째, 핑거프린트 맵에서 임의의 시작점을 선정한다. 둘째, 임의의 진행방향을 선정한다. 셋째, 임의의 걸음 수만큼 진행하면서 자기장 세기 시퀀스를 생성한다. 진행 도중에 벽에 도달할 경우 두번째 단계를 반복한다. 이 방법을 반복하여 목표 경로데이터 수만큼 생성하고 측위 모델 훈련에 활용한다.

SUNGKYUNKWAN UNIVERSITY

다. 통합 측위 모델

[그림 21] 은 WLAN RSSI 기반 CNN 측위 모델과 자기장 시퀀스 기반 RNN 측위 모델의 점진적 측위 모델을 도식화 하였다. 사용자의 걸음이 감지될 때마다 자기장 시퀀스 기반 RNN 측위 모델이 위치를 추정하며 WLAN RSSI 기반 CNN 측위 모델은 초기 위치 추정 오차를 최소화 하기 위해 영역을 추정하고 추정된 영역을 기반으로 RNN 측위 모델의 히든 입력을 생성하고 초기화 한다.

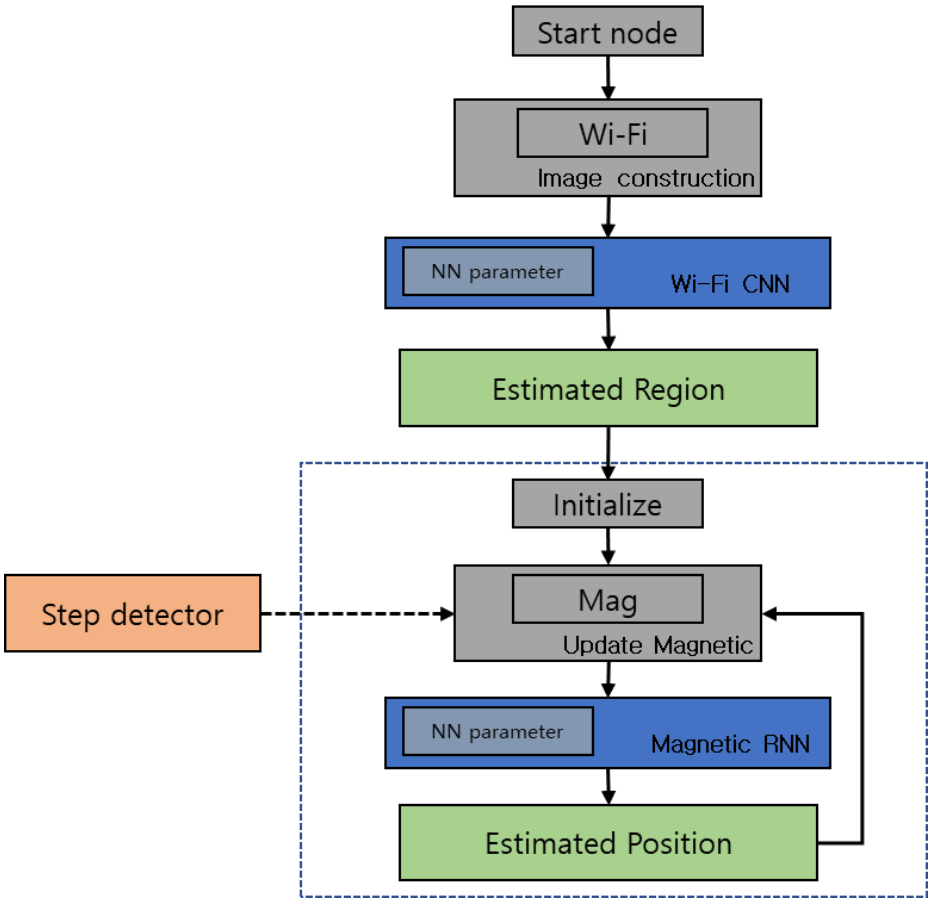

그림 21 점진적 측위 모델

SUNG KYUN KWAN UNIVERSITY

제6장 실내 측위 실험 결과

제1절 테스트 베드 환경

성균관대학교 자연과학 캠퍼스 산학협력센터 7층이 테스트베드로 선정되었다. 테스트베드에는 건물의 공용부분을 이루는 복도형 공간과 광장형 공간이 고루 분포되어 있어 실내 측위 시스템을 검증하기에 적절하다.

그림 22 광장 공간 포함 테스트 베드

그림 23 복도형 공간 포함 테스트 베드

SUNG KYUN KWAN UNIVERSITY

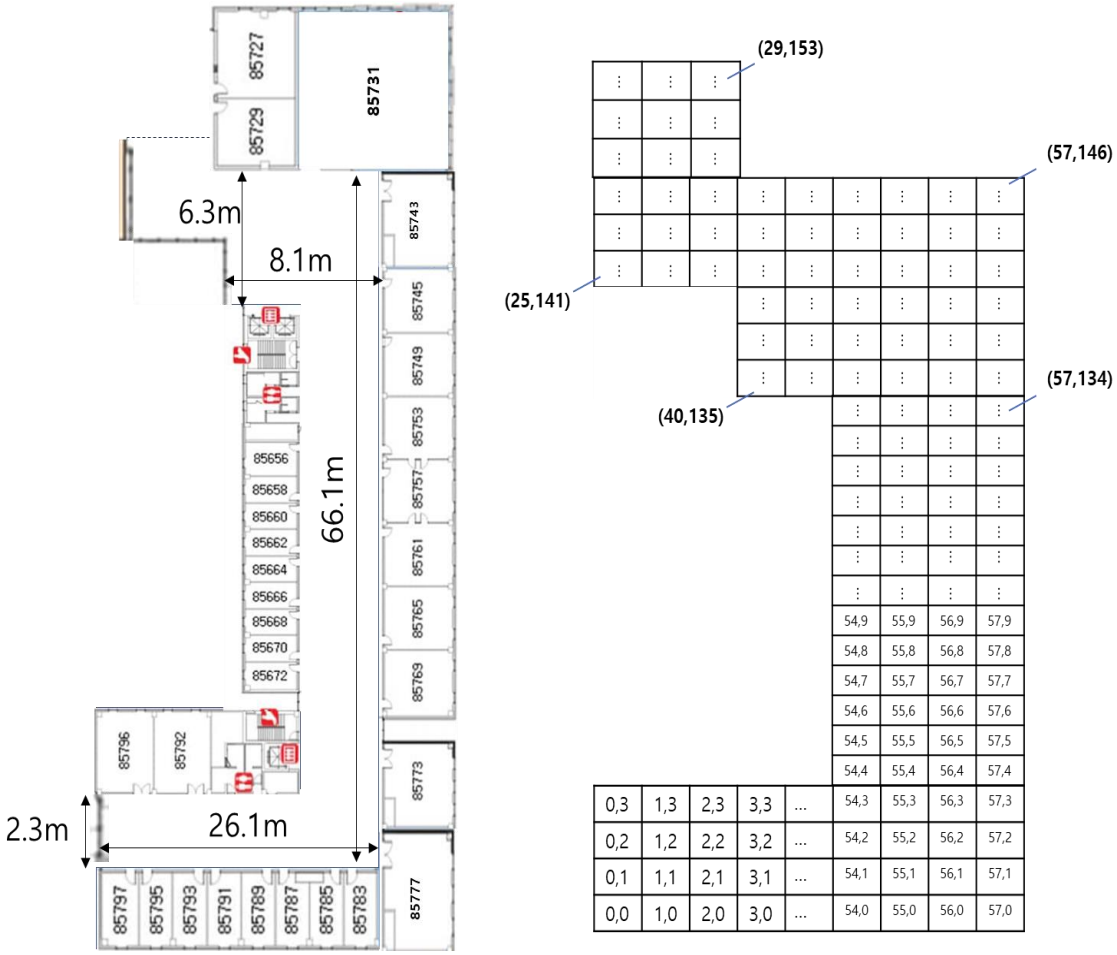

그림 24 테스트 베드 좌표 계획

테스트 베드인 산학협력센터 실내 공간에는 약 26m, 66m 길이의 2개의 긴 복도와 엘리베이터가 있는 6.3m x 8.1m 크기의 작은 광장 공간으로 이루어져 있다. 추가적인 인프라 설치 없이 핑거프린트 기반 측위를 구현하기 위해 오프라인 단계를 수행한다. 실내 공용공간을 바닥 정사각형 모양의 타일 크기인 45cm x 45cm 간격으로 1089개의 샘플 위치로 나누고 각 샘플 위치에서 WLAN의 RSSI 데이터를 수집한다. 데이터를 수집하기 위해 삼성 갤럭시 S7 스마트폰을 사용하였다. [그림 25] 는 테스트 베드에서의 자기장 맵이다.

SUNGKYUNKWAN UNIVERSITY

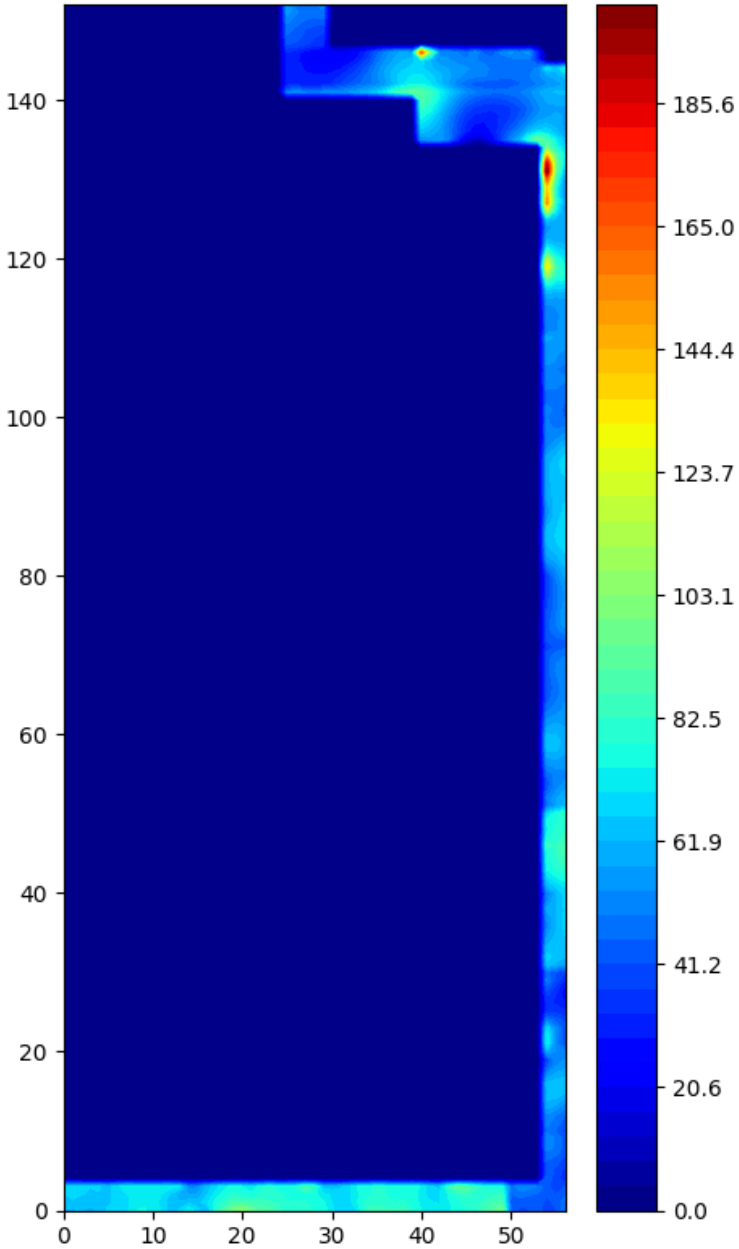

그림 25 실내 공간의 자기장 분포 결과

SUNG KYUN KWAN UNIVERSITY

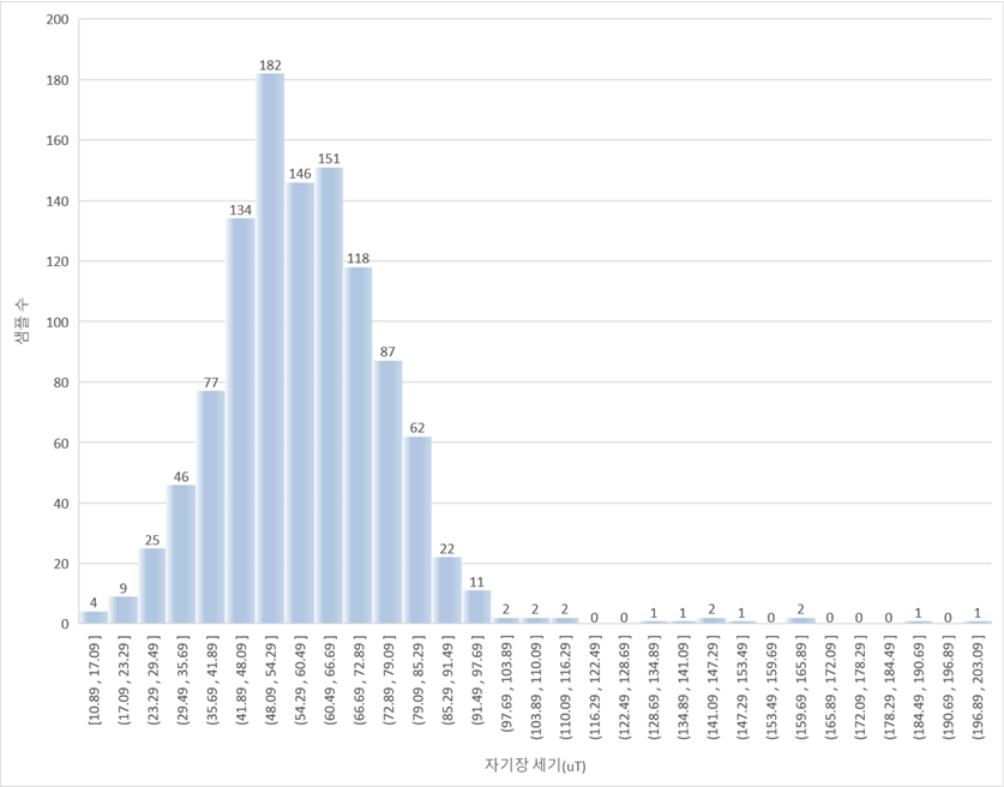

그림 26 자기장 세기에 따른 샘플 분포

테스트 베드에서의 자기장 세기는 50uT를 중심으로 분포되어 있는 것으로 나타난다. 극소수의 샘플 수로 수집된 특이 값은 랜드마크로 사용될 수 있다. WLAN RSSI 는 1089개의 샘플 위치에서 수집되었으며 933개의 AP가 감지되어 핑거프린트 맵을 구축하였다.

제2절 실험 결과

본 절에서는 CNN 기반 WLAN RSSI를 활용한 측위를 실험하고 테스트 베드의 자기장 세기 분포를 활용하여 경로 시퀀스 데이터를 학습하는 RNN 기반 측위 모델의

SUNG KYUN KWAN UNIVERSITY

성능을 실험한다. 점진적 측위 모델을 적용하여 RNN 측위 모델에 초기값을 변경하였을 때의 효과에 대해 정리하였다.

1. 실험 환경

표 7 실험 환경

사양	도구
CPU	Intel(R) Xeon(R) CPU @ 2.30GHz
GPU	Tesla P100
RAM	25.51GB
OS	Ubuntu 18.04.5 LTS
언어	Python 3.7.13
라이브러리	Pytorch 1.11.0 NVIDIA CUDA Version 11.2

표 8 합성곱 신경망 하이퍼파라미터 설정

하이퍼파라미터	값
합성곱 층 수	1, 2, 3
미니배치	10
학습률	0.001
손실 함수	Mean Square Error
최적화 함수	Adam
활성화 함수	Relu
에폭	700

SUNG KYUN KWAN UNIVERSITY

표 9 순환 신경망 하이퍼파라미터 설정

하이퍼파라미터	값
은닉 노드 수	300, 600
은닉층 수	1,3
미니배치	10
학습률	0.001
손실 함수	Mean Square Error
최적화 함수	Adam
활성화 함수	Relu
에폭	500
경로 길이	50

본 실험에서의 측위 모델의 훈련과 검증은 구글 코랩 플랫폼을 활용하였다. CUDA toolkit v11.2 와 함께 Tesla P100 GPU를 통해 훈련을 가속화 하였다. [표 7] 는 실험에 활용된 구글 코랩 플랫폼 환경을 나타낸다. [표 8] 는 CNN 측위 모델 훈련에 사용된 하이퍼 파라미터를 나타내며 [표 9] 는 RNN 측위 모델 훈련에 사용된 하이퍼 파라미터를 나타낸다.

2. CNN 측위 모델 학습 및 테스트 결과

[그림 27] 는 CNN 측위 모델의 훈련 결과를 보여준다. 모델은 합성곱 계층 수에 따라 700 에폭까지 훈련이 수행되었다. 합성곱 계층을 1에서 3으로 증가시키면서 훈련함에 따라 향상된 측위 결과를 얻을 수 있었다. 테스트 셋으로 훈련된 CNN 모델을 검증한 결과로 1.34m의 평균 오차와 7.51m의 최대오차, 0.08m의 최소오차를 얻을 수 있었다.

SUNGKYUNKWAN UNIVERSITY

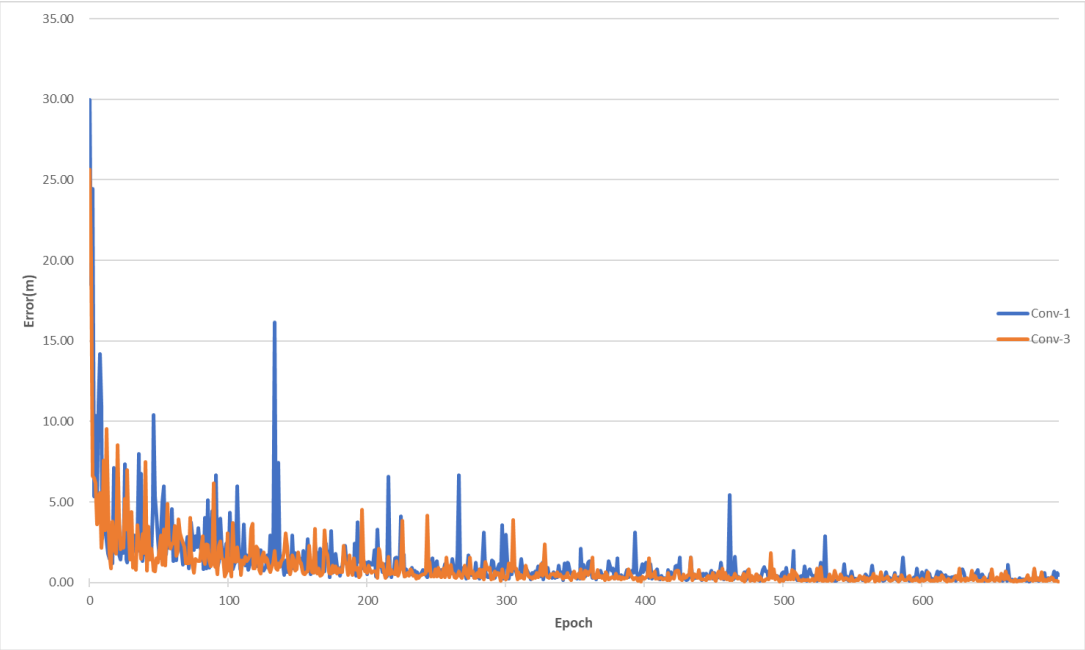

그림 27 합성곱 신경망 훈련 오차

표 10 합성곱 신경망 결과

합성곱 층	1 층	3 층
최대(m)	7.71m	7.51m
최소(m)	0.12m	0.08m
평균(m)	1.5m	1.34m

3. RNN 측위 모델 학습 및 테스트 결과

경로 시퀀스 길이가 50인 입력을 가지는 RNN 측위 모델은 은닉층을 1층과 3층으로 구분하고 은닉 노드의 수는 100과 300으로 구분하여 훈련 및 테스트 성능을 확인하였다. 무작위로 생성된 50000개 경로데이터로 훈련을 수행하였다. 은닉 층을 1층에서

SUNG KYUN KWAN UNIVERSITY

3층으로 변경하고 은닉 노드의 수를 100에서 300으로 증가 시킴으로써 더욱 향상된 정확도를 보였다. [그림 28]을 보면 은닉 층과 은닉 노드의 증가에 따른 훈련 오차의 감소를 확인할 수 있다. 가장 좋은 성능을 보인 3개의 은닉 층과 300개의 은닉 노드의 수가 적용된 측위 모델은 테스트 셋에 대해 2.18m의 평균 오차와 21.9m의 최대오차, 1.8m의 최소오차를 얻을 수 있었다.

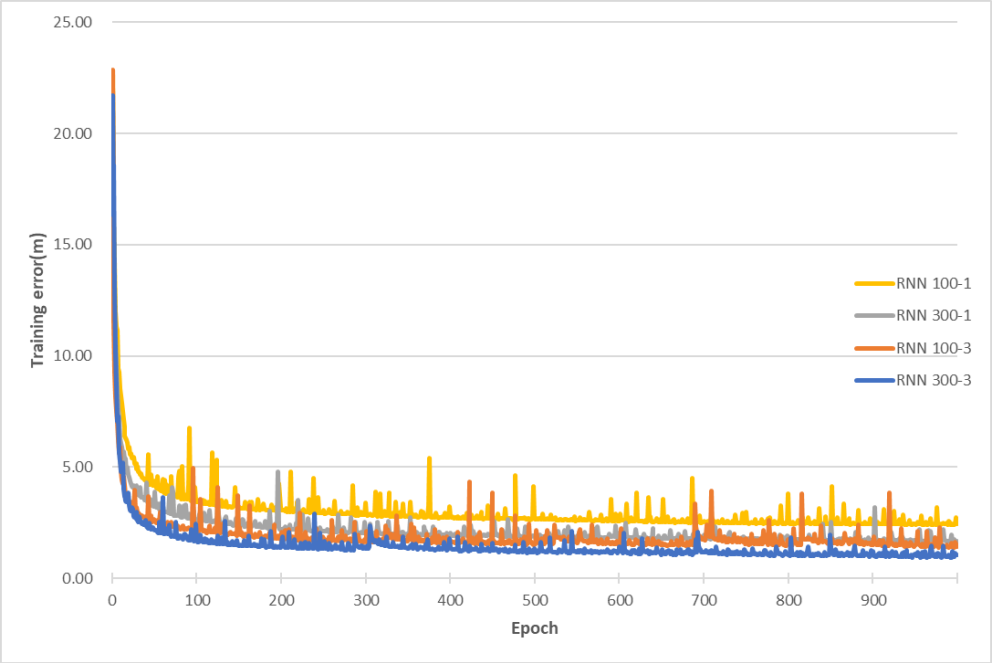

그림 28 순환 신경망 훈련 오차

표 11 순환 신경망 결과

은닉층	1 층		3 층	
은닉 노드 수	100	300	100	300
최대 (m)	22.95	20.19	23.03	21.90
최소 (m)	3.06	2.77	2.12	1.80
평균 (m)	3.54	3.09	2.50	2.18

SUNGKYUNKWAN UNIVERSITY

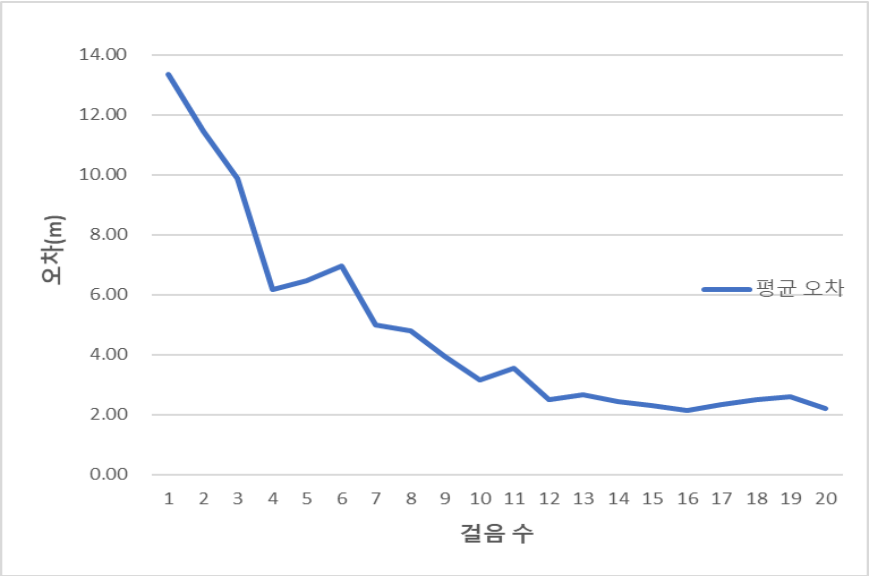

그림 29 300개 은닉 노드, 3개의 은닉 층 RNN 측위 모델의 걸음 수에 따른 평균 오차

[그림 29]은 실험을 통해 선정된 3개의 은닉 층과 300개의 은닉 노드를 가진 RNN 측위 모델의 50개의 경로에 대한 성능테스트 결과이다. 앞서 진행되었던 [표 11]의 실험 결과와 같이 평균오차가 2m에 수렴하지만 초기 10걸음에서 오차가 크게 발생하는 것을 확인할 수 있다.

4. 통합 측위 모델 테스트 결과

본 논문에서 제안하는 점진적 2단계 측위 모델의 성능을 검증하기 위해 실제 20걸음동안 측정된 하나의 경로에 대해 실험을 진행하였다. 검증 비교 대상은 DTW를 활용한 측위, 앞서 설계한 자기장 세기를 활용한 RNN 기반 측위 모델과 WLAN RSSI를 활용한 CNN 기반 측위 모델의 영역 추정 후 RNN 기반 측위 모델을 수행하였을 경우를 비교 검증하였다. 그 결과 초기 10걸음 오차는 1.79m로 감소되었고 평균 오차는 1.17m로 감소되었음이 확인되었다.

SUNGKYUNKWAN UNIVERSITY

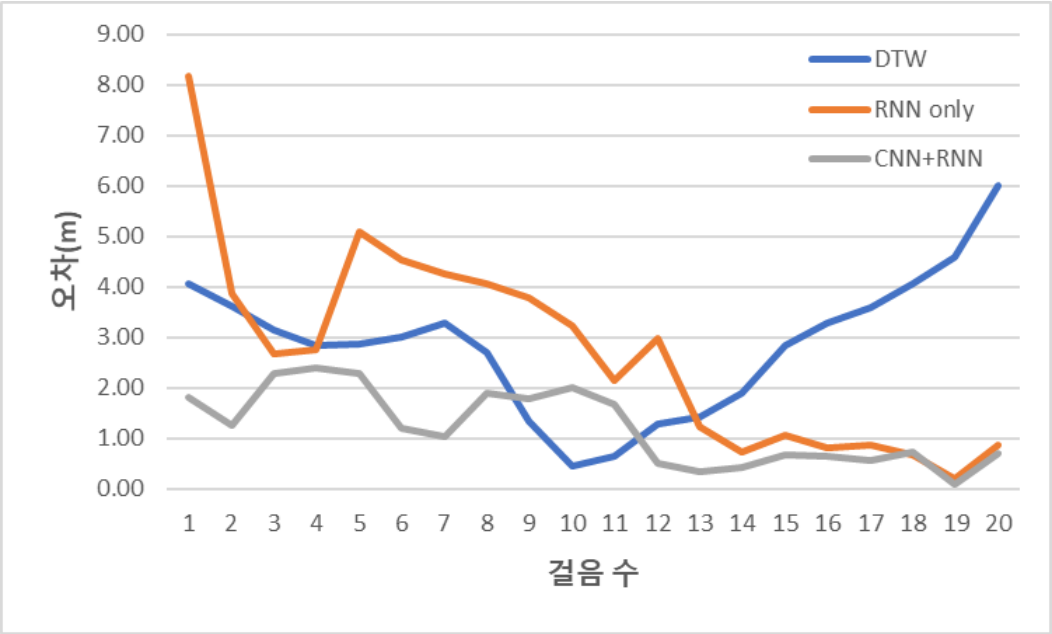

그림 30 측위 모델 성능 비교

표 12 개선된 측위 모델 성능 결과

	DTW 측위 모델	RNN 측위 모델	CNN+RNN 점진적 측위 모델
최대 (m)	6.81	8.18	2.39
최소 (m)	0.45	0.20	0.09
평균 (m)	3.04	2.60	1.17
초기 10 걸음 오차(m)	2.74	4.24	1.79

SUNGKYUNKWAN UNIVERSITY

제7장 결론

본 논문에서는 실내 위치 측위를 저비용으로 높은 정확도를 달성할 수 있는 요소 기술에 대한 이해를 기반으로 향상된 정확도를 제공하는 실내 측위 모델을 개발하고자 하였다. 테스트 베드를 효과적으로 측위하기 위해 사전 조사하고 구획을 나누어 좌표화 하였다. 각 좌표에서 WLAN RSSI의 변동성에 대한 영향을 최소화하기 위해 각 좌표에서 시계열 RSSI 데이터로 재구성되었고 자기장 세기는 벡터화 되어 측정 오차를 줄였다. 수집된 WLAN RSSI 데이터는 제안된 합성곱 신경망에서 700 에폭 동안 학습된 모델에서 합성곱 층 수에 따라 오차 개선 여부가 실험되었고, 합성곱 1층보다 3층으로 구성된 모델이 평균 오차 0.16m 개선된 1.34m의 평균 오차를 달성하였음을 확인하였다. 또한, 자기장 세기의 실내 분포 및 변화 패턴에 대해 사전 조사하였고, 무작위로 생성된 경로 시퀀스 데이터에 대해 은닉 층 수, 은닉 노드 수에 따라 테스트 오차 개선 여부를 확인하였다. 은닉 층 1층 대비 3층으로 모델을 구성하고 은닉 노드 수를 100 대비 300으로 증가하였을 때 더 나은 성능을 보여 평균 오차 21.8m를 달성하였다. 본 논문에서는 이질성이 있는 WLAN RSSI 데이터와 자기장 세기 데이터를 각각 측위 모델에 적용하고 점진적으로 실내 위치를 추정하는 모델을 제안하고 성능 평가를 수행하였다. 개선된 모델은 RNN만 적용된 모델 대비 초기 10 걸음 오차가 42% 수준으로 감소시키는 성능을 보였다.

향후 연구에서 실제 서비스에 접목시키기 위해 실내에서의 보행자 항법시스템 혹은 모바일 로봇의 주행정보 트레킹과 융합 모델 개발이 필요하다. 이동체의 추적 모델은 관성센서와 위치센서의 누적으로 초기 추정이 가능하다. 이동체 추적 모델은 본 연구의 단점인 초기 데이터 수집에 소요되는 비용이 크다는 문제를 해결하기 위해 데이터 수집 단계에서 실시간 수집에 적용될 수 있다. 또한 이동체 추적 모델의 누적에 따른 오차는 본 연구의 측위 모델과의 융합 모델을 통해 더욱 향상된 측위 결과를 보일 것으로 기대된다.

SUNG KYUN KWAN UNIVERSITY

참 고 문 헌

[1] Joaquín Torres-Sospedra, Raúl Montoliu, Adolfo Martínez-Usó, Tomar J. Arnau, Joan P. Avariento, Mauri Benedito-Bordonau, et al., "UJIIndoorLoc: A New Multi-building and Multi-floor Database for WLAN Fingerprint-based Indoor Localization Problems", *Proceedings of the Fifth International Conference on Indoor Positioning and Indoor Navigation*, 2014.

[2] J. Torres-Sospedra, R. Montoliu, S. Trilles, Ó. Belmonte and J. Huerta, "Comprehensive analysis of distance and similarity measures for Wi-Fi fingerprinting indoor positioning systems", *Expert Syst. Appl.*, vol. 42, no. 23, pp. 9263-9278, 2015.

[3] P. Pascacio, S. Casteleyn, J. Torres-Sospedra, et al., "Collaborative Indoor Positioning Systems: A Systematic Review," Sensors, vol. 21, no. 3, p. 1002, 2021.

[4] J. Kunhoth, A. Karkar, S. Al-Maadeed and A. Al-Ali, "Indoor positioning and wayfinding systems: a survey", *Human-centric Comput. Inf. Sci.*, vol. 10, no. 1, pp. 18, 2020.

[5] T. T. Dinh, N. Duong, and K. Sandrasegaran, "Smartphone-based indoor positioning using ble ibeacon and reliable lightweight fingerprint map," IEEE Sens. J., vol. 20, no. 17, pp. 10 283-10 294, Sep 2020.

[6] 최린. "딥러닝 기반 실내 지구자기장 이용 초정밀 실내 측위 기술." , 한국통신학회 논문지, Vol.37 No.12, 2020

[7] K. S. Kim et al., "A Scalable Deep Neural Network Architecture for Multi-Building and Multi-Floor Indoor Localization Based on Wi-Fi

SUNGKYUNKWAN UNIVERSITY

Fingerprinting", *ArXiv preprint*, 2017.

[8] M. Ibrahim, M. Torki and M. ElNainay, "CNN based indoor localization using RSS time-series", *Proc. IEEE Symp. Comput. Commun. (ISCC)*, pp. 1044-1049, 2018.

[9] W. Shao, H. Luo, F. Zhao, Y. Ma, Z. Zhao and A. Crivello, "Indoor positioning based on fingerprint-image and deep learning", *IEEE Access*, vol. 6, pp. 74699-74712, 2018.

[10] A. Belmonte-Hernandez, G. Hernandez-Penaloza, D. Martin Gutierrez and F. Alvarez, "SWiBluX: Multi-sensor deep learning fingerprint for precise real-time indoor tracking", *IEEE Sensors J.*, vol. 19, no. 9, pp. 3473-3486, May 2019.

[11] 배한준, 최린, 박병준. “순환신경망을 이용한 자기장 기반 실내측위 시스템.”, 한국차세대컴퓨팅학회 논문지, 6, 2018

[12] 사이토 고키, “밑바닥부터 시작하는 딥러닝”, 한빛미디어, 2017

[13] 아즈마 유키나가, "핵심 딥러닝 입문", 책만, 2020

[14] Yuanchao Shu, Cheng Bo, Guobin Shen, Chunshui Zhao, Liqun Li, Feng Zhao, "Magicol: Indoor Localization Using Pervasive Magnetic Field and Opportunistic WiFi Sensing", IEEE Journal on Selected Areas in Communications, vol.33, no. 6, p0. 1443 – 1457, 2015

[15] Alberto Belmonte-Hernández, Gustavo Hernández-Peñaloza, David Martín Gutiérrez, Federico Álvarez, "Recurrent Model for Wireless Indoor Tracking and Positioning Recovering Using Generative Networks", *IEEE Sensors J.*, vol. 20, no. 6, pp. 3356-3365, May 2020.

SUNGKYUNKWAN UNIVERSITY

[16] 이택진, "위치, 콘텐츠와 결합하다.", 융합연구리뷰, vol.6 May 2020

SUNG KYUN KWAN UNIVERSITY

ABSTRACT

Deep learning-based indoor positioning using Wi-Fi and geomagnetic field

Kim Sang Woo
Department of Digital Media and Communications Engineering
Sungkyunkwan University

An indoor positioning system (IPS) is a system that measures and provides the location of a smart device such as a smart phone or tag. Indoor positioning systems are closely related to location accuracy, which is an important performance in location-based services. The precise location estimation of the indoor positioning system is of great help in the scalability of location-based services.

In this paper, we study a deep learning model that builds Wi-Fi and geomagnetic fingerprint maps in offline mode and estimates the user's location based on the fingerprint map in online positioning mode. Since Wi-Fi and geomagnetism do not require additional infrastructure construction, high location estimation effects can be obtained at low cost. In this paper, problems are presented by analyzing the characteristics of the selected technology, and a two-stage indoor positioning model is proposed according to the characteristics. First, the area is estimated in the CNN positioning model with

SUNGKYUNKWAN UNIVERSITY

WLAN RSSI features measured at a specific indoor location as input. Second, based on the area estimated in the first step, the user's movement path is estimated in a recurrent neural network (RNN) that uses a unique sequence generated according to the user's movement as an input. As a result, we present the improvement result of the initial localization error due to the pre-region estimation.

For the evaluation of the proposed deep learning-based indoor positioning system, the 7th floor of the Industry-University Cooperation Center located in the Natural Sciences Campus of Sungkyunkwan University was selected as a test bed. The test bed includes a long hallway and a small square in front of the elevator. An average error of 1.34 m was obtained in the CNN positioning model using WLAN RSSI feature as input, and an error result of 2.18 m was obtained in the RNN positioning model based on magnetic field strength. The improved model proposed in this paper showed the performance to reduce the initial 10-step error to 42% compared to the model to which only RNN was applied.

Keywords: Finger printing, Tracking, Wi-Fi, Geomagnetic, Indoor positioning system

SUNGKYUNKWAN UNIVERSITY

碩士學位請求論文

딥러닝기반 WiFi와 지구자기장을 이용한 실내측위

2022

金相佑

SUNG KYUN KWAN UNIVERSITY