creative commons

COMMONS DEED

저작자표시-비영리-변경금지 2.0 대한민국

이용자는 아래의 조건을 따르는 경우에 한하여 자유롭게

- 이 저작물을 복제, 배포, 전송, 전시, 공연 및 방송할 수 있습니다.

다음과 같은 조건을 따라야 합니다:

저작자표시. 귀하는 원저작자를 표시하여야 합니다.

비영리. 귀하는 이 저작물을 영리 목적으로 이용할 수 없습니다.

변경금지. 귀하는 이 저작물을 개작, 변형 또는 가공할 수 없습니다.

- 귀하는, 이 저작물의 재이용이나 배포의 경우, 이 저작물에 적용된 이용허락조건을 명확하게 나타내어야 합니다.
- 저작권자로부터 별도의 허가를 받으면 이러한 조건들은 적용되지 않습니다.

저작권법에 따른 이용자의 권리는 위의 내용에 의하여 영향을 받지 않습니다.

이것은 이용허락규약(Legal Code)을 이해하기 쉽게 요약한 것입니다.

Disclaimer

dCollection

석사학위 논문

스마트폰 내장 센서만을 이용한 딥러닝 기반 3D 위치 초기화 및 다층 실내 측위 기법

Deep Learning-Based 3D Location Initialization and Multi-Floor Indoor Localization Using Smartphone Built-in Sensors Only

2025년 6월

숭실대학교 대학원

정보통신공학과

김 진 우

석사학위 논문

스마트폰 내장 센서만을 이용한 딥러닝 기반 3D 위치 초기화 및 다층 실내 측위 기법

Deep Learning-Based 3D Location Initialization and Multi-Floor Indoor Localization Using Smartphone Built-in Sensors Only

2025년 6월

숭실대학교 대학원

정보통신공학과

김 진 우

석사학위 논문

스마트폰 내장 센서만을 이용한 딥러닝 기반 3D 위치 초기화 및 다층 실내 측위 기법

지도교수 신 요 안

이 논문을 석사학위 논문으로 제출함

2025년 6월

숭실대학교 대학원

정보통신공학과

김 진 우

김 진 우의 석사학위 논문을 인준함

심 사 위 원 장 신 오 순 (인)

심 사 위 원 신 요 안 (인)

심 사 위 원 권 민 혜 (인)

2025년 6월

숭실대학교 대학원

목 차

국문초록 ····· v
영문초록 ····· vii

제 1 장 서론 ····· 1
1.1 연구 배경 및 내용 ····· 1
1.2 논문의 구성 ····· 4

제 2 장 센서 기반 다층 실내 측위 기법의 한계 ····· 5
2.1 초기 층 탐지 문제 ····· 5
2.2 초기 위치 추정 문제 ····· 6
2.3 PDR 기법의 드리프트 문제 ····· 8

제 3 장 자기장 맵 및 딥러닝 기반 다층 실내 측위 기법 ····· 12
3.1 3차원 위치 초기화 ····· 13
3.1.1 초기 층 탐지 ····· 13
3.1.2 초기 위치 추정 ····· 19
3.2 3차원 위치 추적 방법 ····· 20
3.2.1 층 이동 감지 기법 ····· 20
3.2.2 자기장 데이터 기반 보정 노드 활용 방안 ····· 23

제 4 장 실험 결과 ····· 26
4.1 초기 층 탐지 실험 ····· 26
4.2 초기 위치 추정 실험 ····· 28

4.3 인프라 제한 환경에서 다층 실내 측위 실험 ····· 30

제 5 장 결론 ····· 34

참고문헌 ····· 36

표 목 차

[표 3-1] LSTM 모델 학습에 사용된 하이퍼파라미터 ····· 18
[표 3-2] Seq2Seq 모델 학습에 사용된 하이퍼파라미터 ····· 22
[표 4-1] 초기 층 탐지 정확도 ····· 26
[표 4-2] 형남공학관 초기 층 탐지 혼동 행렬 ····· 27
[표 4-3] 조만식 기념관 초기 층 탐지 혼동 행렬 ····· 27
[표 4-4] AR 및 RMSE 평가 결과 ····· 31

그 림 목 차

[그림 1-1] 제안 기법의 구조 ····· 3
[그림 3-1] 제안 기법의 흐름도 ····· 12
[그림 3-2] 각 층의 자기장 데이터 시퀀스 ····· 14
[그림 3-3] 자기장 데이터 수집 경로 ····· 15
[그림 3-4] LSTM 모델 개요 ····· 18
[그림 3-5] 각 층의 보정 노드 ····· 24
[그림 4-1] 형남공학관의 3차원 위치 초기화 실험 결과 ····· 28
[그림 4-2] 조만식 기념관의 3차원 위치 초기화 실험 결과 ····· 29
[그림 4-3] 층 이동 감지 실험 결과 ····· 30
[그림 4-4] 제안 기법 실험 결과와 기존 측위 기법 실험 결과 비교 ····· 31

국문초록

스마트폰 내장 센서만을 이용한 딥러닝 기반 3D 위치 초기화 및 다층 실내 측위 기법

김 진 우
정보통신공학과
숭실대학교 대학원

보행자 추측 항법 (Pedestrian Dead Reckoning; PDR)은 스마트폰의 관성 측정 장치 (Inertial Measurement Unit; IMU)를 활용하여 별도의 인프라 없이 실내 위치를 추정할 수 있는 대표적인 실내 측위 기술이다. PDR은 사용자의 이전 위치로부터 변화량을 누적하여 현재 위치를 추정하기 때문에, 초기 위치 설정의 정확성이 전체 위치 추정 성능에 큰 영향을 미친다. 특히 다층 실내 환경에서는 초기 위치뿐만 아니라 정확한 층수 정보의 확보가 필수적이다. 기존 PDR 기반 실내 측위 기술은 초기 위치를 설정하기 위해 무선 통신 인프라에 의존하거나, 사용자가 직접 초기 위치를 지정해야 하는 한계가 있었다. 또한, 방향 추정에 사용되는 자이로스코프의 특성상 시간이 지남에 따라 센서 노이즈가 누적되는 드리프트 현상으로 인해 측위 정확도가 점차 저하되는 문제가 존재한다.

이러한 한계를 해결하기 위해 본 연구에서는 외부 인프라 없이 스마트

폰 내장 센서만을 활용하여 다층 건물 내에서 초기 3차원 위치를 추정하고, PDR의 누적 오차를 보정할 수 있는 딥러닝 및 머신러닝 기반의 다층 실내 위치 추정 기법을 제안한다. 제안하는 기법은 스마트폰의 지자기 센서를 이용하여 초기 3차원 위치 (층수 및 2차원 좌표)를 추정하고, 이후 발생하는 드리프트 오차를 보정하여 기존 PDR 방식의 한계를 극복한다. 제안 방식은 사용자의 초기 10걸음 동안의 자기장 시퀀스를 딥러닝 모델에 입력하여 초기 층수를 추론한 뒤, k-최근접 이웃 (k-Nearest Neighbor; k-NN) 알고리즘을 통해 10번째 걸음의 자기장 데이터와 추론된 층의 사전 구축된 자기장 맵을 비교함으로써 초기 2차원 위치를 추정한다. 이후, 기압계 기반의 층 이동 추정 기술과 PDR 기술을 결합하여 다층 실내 위치 추정을 수행하며, 자기장 데이터를 활용한 가상의 보정 노드 (Calibration Node; CN)를 적용하여 PDR의 드리프트 문제를 효과적으로 보완한다.

실험 결과, 다층 건물 내에서 제안 기법은 기존 PDR, 상보 필터, 칼만 필터 기반 기법 대비 경로 유사도 및 위치 정확도 측면에서 우수한 성능을 보였으며, 특히 2미터 이내의 정확도에서 최대 99.8%의 정확도와 평균 64cm의 위치 오차를 달성하여 실내 위치 추정의 정확성과 실용성을 입증하였다.

ABSTRACT

Deep Learning-Based 3D Location Initialization and Multi-Floor Indoor Localization Using Smartphone Built-in Sensors Only

KIM, JIN-WOO
Department of Information & Telecommunication Eng.
Graduate School of Soongsil University

Pedestrian Dead Reckoning (PDR) is a representative indoor localization technology that estimates a user's location without the need for external infrastructure, leveraging the smartphone's Inertial Measurement Unit (IMU) sensors. Since PDR estimates the current location by accumulating changes from the previous position, the accuracy of the initial position setting is critical to the overall localization performance. In particular, in multi-floor indoor environments, it is essential to obtain not only the initial position but also accurate floor information. However, conventional PDR-based indoor localization techniques have limitations in that they rely on

wireless communication infrastructure for initial position estimation or require users to manually specify their initial positions. Furthermore, due to the characteristics of gyroscopes used for heading estimation, drift, caused by the accumulation of sensor noise over time, leads to a gradual degradation of localization accuracy.

To address these limitations, this study proposes a deep learning and machine learning-based multi-floor indoor localization method that estimates the initial 3D position (floor and 2D coordinates) and corrects PDR drift errors using only smartphone sensors, without any external infrastructure. The proposed method first estimates the initial 3D position by utilizing magnetic field sensor data from the smartphone and then compensates for the drift errors that occur during PDR. Specifically, a deep learning model is trained to infer the initial floor based on the magnetic field sequence from the user's first ten steps. Afterward, a k-nearest neighbors (k-NN) algorithm is employed to estimate the initial 2D position by comparing the magnetic field data from the user's 10th step to a pre-constructed magnetic field map corresponding to the inferred floor. Following the initial position estimation, a combination of barometer-based floor transition detection and PDR is used for continuous multi-floor indoor localization. In addition, virtual Calibration Nodes (CN), utilizing magnetic field data, are applied to effectively compensate for PDR drift errors.

Experimental results conducted in a multi-floor building demonstrate that the proposed method outperforms conventional PDR,

complementary filter, and Kalman filter-based methods in terms of trajectory similarity and localization accuracy. Notably, the proposed method achieved a localization accuracy of up to 99.8% within 2 meters and an average error of 64 cm, thereby verifying its high accuracy and practical feasibility for indoor localization applications.

제 1 장 서 론

1.1 연구 배경 및 내용

최근 스마트폰을 활용한 위치 기반 서비스 (Location Based Services; LBS)가 주목을 받고 있다. 위치 추정 기술은 실외 및 실내 측위로 크게 구분할 수 있으며, 실외 환경에서는 위성 신호를 이용한 글로벌 내비게이션 위성 시스템 (Global Navigation Satellite System; GNSS)이 널리 사용된다. 그러나 GNSS 신호는 실내 환경에서 심각한 신호 감쇠 현상에 의해 신뢰성이 크게 저하되며, 이로 인해 실내 환경에서는 GNSS를 사용할 수 없는 경우가 많다. 이러한 한계로 인해, GNSS를 대체할 수 있는 다양한 실내 위치 추정 기술에 대한 연구가 활발히 진행되고 있다.

실내 위치 추정 기술은 크게 외부 인프라에 의존하는 방식과 외부 인프라에 의존하지 않는 방식으로 구분된다[1]. 인프라 기반 방식은 Wi-Fi AP (Access Point) 또는 BLE (Bluetooth Low Energy) Beacon과 같은 무선 통신 시스템의 신호 세기를 이용해 사용자의 위치를 추정한다[2]-[4]. 그러나 이러한 방식은 경로 손실 (Path Loss), 섀도잉 (Shadowing), 페이딩 (Fading) 등 환경적 요인에 의해 정확도가 저하되며[5], [6], 설치 및 유지보수 비용이 높다는 한계가 있다. 또한, 재난 환경과 같은 비상 상황에서는 무선 인프라가 손상되거나 사용할 수 없어 적용이 불가능하다는 문제점이 있다. 이에 따라, 외부 인프라 없이도 정확한 실내 위치를 추정할 수 있는 기술에 대한 수요가 지속적으로 증가하고 있다[7], [8].

외부 인프라 비의존 방식은 스마트폰에 내장된 센서만을 이용해 사용자의 위치를 추정한다는 점에서 설치 용이성과 높은 비용 효율성의 장점이

있어 주목받고 있다[9]. 이러한 방식 중에서도 보행자 추측 항법 (Pedestrian Dead Reckoning; PDR)은 가장 활발히 연구되고 있는 기술 중 하나로, 미세 전자 기계 시스템 (Micro-Electro-Mechanical Systems; MEMS) 기반의 관성 측정 장치 (Inertial Measurement Unit; IMU)에 포함된 가속도 센서 (Accelerometer), 자이로스코프 (Gyroscope) 센서, 지자기 센서 (Magnetometer)를 활용한다. PDR 기술은 가속도 센서를 이용하여 보행자의 걸음을 탐지하고 보폭을 계산하며, 방향 계산은 가속도 센서와 지자기 센서를 결합하거나 자이로스코프 단독으로 수행할 수 있다. 또한, 필요에 따라 이 두 방향 추정 결과를 융합해 사용하는 경우도 있다. 이렇게 추정된 보폭과 방향 정보를 통해 이전 위치에서 변화된 현재 위치를 계산한다[10]. 그러나 PDR을 다층 건물 내 측위에 적용할 때는 세 가지 주요 한계가 존재한다.

첫째, 건물 내 초기 층수 추정 문제이다. 일반적으로 실내 층수는 스마트폰의 기압 센서 (Barometer)를 이용해 층간 기압 차이를 기반으로 추정한다[11], [12]. 그러나 기압 센서는 날씨, 기온 등 대기 조건의 변화에 매우 민감하게 반응하기 때문에, 동일한 위치에서도 시간이나 기상 조건에 따라 측정되는 절대값이 달라지는 문제가 있다. 이러한 민감성은 층간 이동 탐지에는 유리하지만, 초기 층수 식별에는 한계가 있다. 따라서 기압계 기반 다층 실내 위치 추정의 성능을 높이기 위해서는 초기 층수의 정확한 추정이 반드시 필요하다[13].

둘째, 건물 내 초기 2차원 위치 추정 문제이다. PDR은 상대적인 위치 추정 방식이기 때문에 초기 위치의 정확성이 전체 측위 성능에 큰 영향을 미친다. 기존 PDR 기반 실내 측위 기술은 Wi-Fi, BLE 등 무선 통신 신호를 활용해 초기 위치를 추정하거나, 사용자가 직접 초기 위치를 지정한 후 PDR을 수행하는 방식을 사용해왔다. 그러나 이러한 방식은 무

선 인프라가 제한된 환경에서는 적용이 불가능하며, 실제 사용 시에도 한계가 있다.

셋째, 자이로스코프의 누적 오차 문제이다. PDR은 장시간 사용 시 자이로스코프 센서의 오차가 누적되는 드리프트 (Drift) 현상으로 인해 정확도가 점차 저하되는 치명적인 한계를 가진다. 드리프트는 자이로스코프에서 측정된 각속도를 적분하는 과정에서 발생하는 오차로, 실내 위치 추정 정확도를 저하시킨다. 이를 완화하기 위해 칼만 필터 (Kalman Filter; KF) 및 상보 필터 (Complementary Filter; CF) 등 다양한 노이즈 완화 기법이 사용되고 있지만[14], [15], 여전히 드리프트 문제를 근본적으로 해결하지는 못하는 한계가 존재한다.

본 연구에서는 이러한 문제를 해결하기 위해 다음과 같은 세 가지 목표를 설정하였다. 첫째, 자기장 맵과 딥러닝 (Deep Learning; DL)을 활용하여 사용자의 초기 층수를 정확히 식별하고, 이를 통해 기압계 기반 층 이동 탐지의 요구사항을 충족한다. 둘째, 초기 층수 추론 후, 해당 층의 자기장 맵과 비교하여 2차원 위치를 추정함으로써 PDR의 핵심 요구사항인 초기 위치 정보를 제공한다. 셋째, 자기장 맵 기반 가상 보정 노드 (Calibration Node; CN)를 적용하여 PDR의 드리프트 문제를 보완한다.

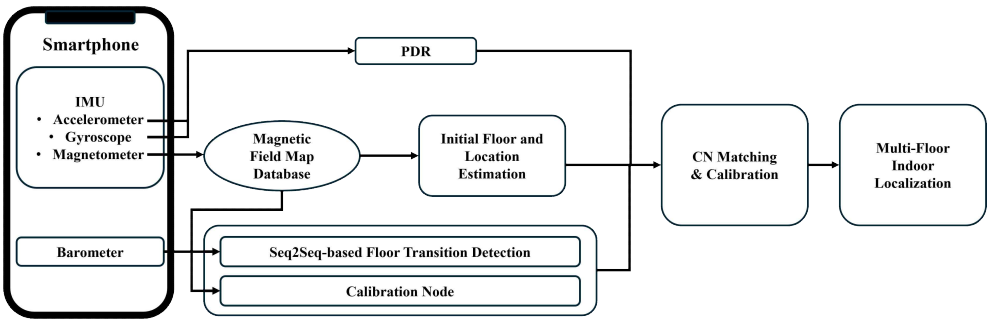

[그림 1-1] 제안 기법의 구조

이를 달성하기 위해, 본 연구는 IMU 센서와 자기장 맵을 딥러닝 및 머신러닝 (Machine Learning; ML) 알고리즘으로 통합한 외부 인프라 비의존 다층 실내 위치 추정 방법을 제안한다[16]. 제안 기법의 개요는 [그림 1-1]에 나타나 있다.

본 연구에서는 스마트폰의 지자기 센서를 활용하여 자기장 맵을 구축하고, 이를 딥러닝 모델의 학습 데이터로 활용한다. 초기 층수 탐지는 사용자의 이동 중 수집된 10스텝 길이의 자기장 데이터를 입력으로 LSTM (Long Short-Term Memory) 네트워크를 통해 수행하며, 탐지된 층의 자기장 맵과 비교하기 위해 k-최근접 이웃 (k-Nearest Neighbor; k-NN) 알고리즘을 적용하여 초기 2차원 위치를 추정한다. 이를 통해 결정된 초기 층수와 2차원 위치 정보를 결합하여 초기 3차원 위치를 산출하며, 이는 이후 위치 추정 과정의 기준점으로 사용된다. 이후, 스마트폰의 기압 센서 데이터를 입력으로 사용하는 Seq2Seq (Sequence-to-Sequence) 딥러닝 모델을 통해 스텝 간 기압 변화 패턴을 분석하여 정확한 층 이동 탐지를 수행한다. 특히, 층 전이 신호가 감지될 경우 가상의 보정 노드를 활용하여 PDR의 누적 오차를 실시간으로 보정함으로써, 드리프트 문제를 최소화하고 보다 안정적이고 정확한 다층 실내 위치 추정을 실현한다.

1.2 논문의 구성

본 논문의 구성은 다음과 같다. 2장에서는 스마트폰을 활용한 외부 인프라 비의존 다층 실내 측위 시스템의 주요 문제를 설명하며, 3장에서는 이러한 문제를 해결하기 위한 제안 방법을 기술한다. 4장에서는 제안 기법의 성능을 평가하기 위한 실험 방법과 결과를 제시하며, 마지막으로 5장에서 본 논문의 결론을 맺는다.

제 2 장 센서 기반 다층 실내 측위 기법의 한계

본 장에서는 외부 인프라 없이 스마트폰을 이용한 다층 실내 위치 추정 방식의 전반적인 개요를 설명한다. 또한, 기존 방식에서 발생하는 초기 층수 추정 문제, 초기 위치 추정 문제, 그리고 드리프트 문제를 중심으로 기존 연구의 한계점을 살펴본다.

2.1 초기 층 탐지 문제

스마트폰 기반 다층 실내 위치 추정 시스템에서는 일반적으로 무선 통신 신호 세기를 활용하여 층수를 탐지한다. Wi-Fi 및 Beacon 신호와 같은 무선 신호는 실내에 설치된 AP에서 송출되며, 사용자 위치에 따라 고유한 신호 세기 값을 가진다. 이러한 특성을 활용한 핑거프린팅 (Fingerprinting) 기법은 각 층과 위치별 신호 세기 정보를 데이터베이스에 저장한 후, 실시간으로 수신되는 신호 데이터를 이 데이터베이스와 비교하여 사용자의 층수를 추정한다[17], [18]. 그러나 외부 인프라가 없는 환경에서는 무선 통신 신호를 사용할 수 없어 이러한 방식의 적용이 어렵다.

이에 대한 대안으로, 스마트폰에 내장된 기압 센서를 이용한 층수 탐지 방법이 주로 사용된다. 스마트폰 기압 센서는 사용자의 위치에서 대기압을 측정하여 고도를 추정할 수 있으며, 특히 계단이나 엘리베이터를 통한 층 이동 감지에 유용하다. 기압 변화 데이터를 분석하면 사용자가 이동한 층의 수를 계산할 수 있으며, 딥러닝 모델과 결합할 경우 층 탐지 정확도를 더욱 향상시킬 수 있다. 딥러닝 모델은 계단 올라감 (Up), 계단 내려감 (Down), 평지 (Flat) 등 층 이동 과정에서 나타나는 기압

변화 패턴을 학습하며, 학습된 모델은 실시간 기압 데이터를 기반으로 층 이동을 감지한다. 이후, 감지된 층 이동 정보는 사전에 구축된 기압 맵과 비교되어 사용자의 층수를 최종적으로 추정한다[19]. 이러한 방식은 외부 인프라 없이 다양한 환경에서 활용이 가능하다는 장점을 가진다.

그러나 기존의 기압 센서 기반 층수 탐지 방식은 여러 한계를 가진다. 기압 센서는 날씨, 기온 등 외부 환경 요인에 매우 민감하여 동일한 위치에서도 시간대나 기상 조건에 따라 대기압 측정값이 달라질 수 있다. 이러한 민감성으로 인해 초기 층수를 정확히 판단하기 어렵고, 이로 인해 기압 센서 기반 다층 위치 추정 시스템은 초기 층수 정보를 반드시 사전에 설정해야 하는 의존성을 갖는다. 초기 층수 설정이 잘못되면 이후의 모든 층 탐지 결과에 오류가 누적되며, 이는 시스템의 신뢰성과 정확성을 저하시킨다[20], [21].

따라서, 외부 인프라에 의존하지 않으면서도 보다 정밀한 초기 층수 탐지 및 기압 데이터 보정 기법이 필요하다. 이러한 개선은 다양한 환경에서 다층 실내 위치 추정 시스템의 정확성과 견고성을 높이는 데 필수적이다.

2.2 초기 위치 추정 문제

스마트폰 내장 IMU 센서만을 사용하는 PDR 기술은 외부 인프라가 제한된 환경에서 실내 위치 추정의 핵심 기술로 활용된다. PDR은 사용자의 이전 위치를 기준으로 현재 위치를 계산하는 상대적인 위치 추적 방식으로, 추가적인 인프라 없이도 연속적인 위치 추정이 가능하다는 장점을 가진다. PDR의 기본 처리 과정은 크게 보폭 계산, 방향 추정, 그리고 위치 계산 단계로 구성된다.

첫째, 보폭 계산 단계에서는 사용자의 보행 중 발생하는 주기적인 가속도 센서 데이터를 분석하여 스텝 이벤트를 감지하고, 이를 기반으로 보폭을 계산한다. 개인별 보폭은 신장, 체중, 보행 습관 등 다양한 요인에 따라 달라지기 때문에, 사용자별 보행 패턴에 적응하는 동적 보폭 추정 알고리즘이 필요하다[22].

둘째, 방향 추정 단계에서는 자이로스코프로부터 측정된 각속도 변화를 적분하여 회전 정보를 추출하고, 이를 통해 사용자의 진행 방향을 산출한다. 하지만 자이로스코프는 특성상 시간이 지남에 따라 오차가 누적되는 드리프트 현상이 발생하며, 외부 자기장 간섭, 센서 노이즈 등 다양한 오류 요인이 위치 추정 정확도에 영향을 미친다. 이를 보완하기 위해 자이로스코프 데이터는 지자기 센서의 데이터를 융합하여 보정하는 방식이 사용된다[23].

셋째, 현재 위치 계산 단계에서는 이전 위치 P_{k-1}, 보폭 λ_k 그리고 방향각 θ_k 를 이용하여 사용자의 현재 위치 P_k를 다음과 같이 계산한다.

$$P_k = P_{k-1} + \lambda_k [\sin\theta_k \cos\theta_k]^T. \tag{1}$$

이 식은 PDR이 이전 위치를 기반으로 한 상대 위치 추정 방식임을 명확히 보여준다. 즉, PDR은 현재 위치를 추정하기 위해 반드시 이전 위치 정보를 입력으로 사용하며, 이로 인해 시스템 전체의 정확도는 초기 위치 설정의 정확성에 크게 의존한다. 초기 위치 정보가 부정확할 경우, 이후 계산되는 위치 추정 값은 매 스텝마다 오차가 누적되며, 이는 전체 경로의 왜곡과 측위 정확도의 저하로 이어질 수 있다.

기존의 인프라 기반 실내 위치 추정 시스템은 이러한 초기 위치 문제를 해결하기 위해 무선 통신 신호를 활용하거나, 사용자가 초기 위치를 수동으로 지정하는 방식으로 보완해왔다[24], [25]. 그러나 이러한 방식은

추가적인 인프라 설치 및 유지보수가 필요하며, 재난 상황이나 인프라가 구축되지 않은 환경에서는 사용이 불가능하다는 한계가 있다.

한편, 스마트폰 내장 지자기 센서를 활용한 실내 위치 추정은 이러한 한계를 극복할 수 있는 대안으로 주목받고 있다. 지구 자기장은 건물 구조물, 금속, 전자기기 등에 의해 왜곡되어 각 실내 환경마다 고유한 공간적 패턴을 형성하며, 이를 활용하면 초기 위치 추정에 필요한 위치 식별 정보를 제공할 수 있다. 특히, 자기장은 무선 통신 신호와 달리 별도의 인프라를 필요로 하지 않으며, 이미 실내 공간에 자연적으로 존재하는 특성을 그대로 활용할 수 있다는 점에서 초기 위치 추정을 위한 대체 기술로서의 잠재력을 가진다[26]-[29].

따라서, 외부 인프라 없이도 초기 위치를 정확하게 추정할 수 있는 기술의 개발은 PDR 시스템의 성능을 결정짓는 핵심 요소로, 이를 해결하지 않고는 인프라 비의존 실내 위치 추정 시스템의 실질적인 활용이 어렵다. 특히, 초기 위치 추정 문제는 단순히 첫 위치의 정확성에 국한되지 않으며, 이후 모든 위치 추정의 정확성 및 안정성에 중대한 영향을 미친다는 점에서 그 중요성이 강조된다.

2.3 PDR 기법의 드리프트 문제

IMU의 자이로스코프는 방향 계산에 필수적인 역할을 수행하는 핵심 센서로, 코리올리 효과 (Coriolis Effect)를 이용하여 축에 대한 각속도를 측정한다. 오일러 각 (Euler Angle)의 변화율은 각 바디 축 간의 상대적인 각속도에 따라 결정되며, 관성 좌표계에서의 각속도 변화율 계산은 다음과 같은 변환 과정을 통해 이루어진다[30], [31].

$$F_c = -2m(\omega \times v), \tag{2}$$

$$[\dot{\phi}\dot{\theta}\dot{\psi}]^T = \begin{bmatrix} 1 & \sin\phi\tan\theta & \cos\phi\tan\theta \\ 0 & \cos\phi & -\sin\phi \\ 0 & \sin\phi\cos\theta & \cos\phi\cos\theta \end{bmatrix} [\omega_x \omega_y \omega_z]^T. \quad (3)$$

식 (2)는 코리올리 효과를 나타내며, 이는 질량 m을 가진 물체가 속도 v로 이동할 때, 회전 좌표계의 각속도 ω에 의해 회전축과 속도 모두에 수직인 방향으로 작용하는 힘 F_C이다. 힘은 자이로스코프 내부에서 측정되며, 이를 통해 각속도를 추정한다. 식 (3)은 자이로스코프에서 측정된 바디 프레임 기준의 각속도 $\omega_x \omega_y \omega_z$를 입력으로 받아 오일러 각의 변화율을 계산한다.

또한, 오일러 각은 자이로스코프의 각속도 데이터를 시간에 따라 적분함으로써 다음과 같이 얻을 수 있다.

$$[\phi\theta\psi]^T = \int_0^t [\dot{\phi}\dot{\theta}\dot{\psi}]^T dt + [\phi_0 \theta_0 \psi_0]^T. \quad (4)$$

여기서 ϕ_0, θ_0, ψ_0는 측정 시작 시점의 초기 롤 (Roll), 피치 (Pitch), 요 (Yaw) 각도를 의미한다. 그러나 오일러 각 방식은 특정 각도에서 발생하는 짐벌락 (Gimbal Lock) 현상의 영향을 받기 쉽다. 짐벌락은 세 개의 회전축 중 두 축이 특정 각도에서 일치하게 되어 회전 자유도가 감소하거나 상실되는 현상으로, 주로 Pitch 각도가 90도에 근접할 때 발생한다. 이 경우, Yaw와 Roll 회전의 구분이 불가능해지며, 센서가 정확한 방향을 추정하는 데 한계가 발생한다[32], [33].

이러한 문제를 해결하기 위해 회전 표현 방식으로 쿼터니언 (Quaternion)이 사용된다. 쿼터니언은 3차원 공간의 회전을 4차원 공간의 단위 벡터로 나타내며, 오일러 각에서 발생하는 짐벌락 문제를 완전히 회피할 수 있다. 또한, 쿼터니언은 모든 방향에서 연속적이고 특이점 없는 회전 표현이 가능하며, 회전축의 중첩 없이 회전을 안정적으로 표현할 수 있다. 특히, 쿼터니언은 회전의 각도와 축 정보를 하나의 데이터

구조로 통합하여 표현하므로, 오일러 각이나 회전 행렬보다 연산 효율과 수치적 안정성이 우수하다. 회전축과 회전 순서를 명시적으로 정의할 필요가 없다는 점 또한 중요한 장점으로, 다축 회전이 빈번한 환경에서도 높은 신뢰성을 제공한다. 쿼터니언을 이용한 각도 계산 과정은 다음과 같이 수행된다[34]-[36].

$$\omega = [0\,\omega_x\,\omega_y\,\omega_z], \tag{5}$$

$$\dot{q} = \frac{1}{2} q \otimes \omega, \tag{6}$$

$$\dot{q} = \frac{1}{2} q_{t-1} \otimes \omega_t, \tag{7}$$

$$q_{t+\Delta} = q_{t-1} + \dot{q}\Delta t. \tag{8}$$

식 (5)에서 ω는 자이로스코프 센서 프레임의 X, Y, Z 축 각속도를 포함하는 쿼터니언 형태의 각속도 벡터이다. 식 (6)에서 $\dot{q}$는 센서 프레임에 대한 지구 프레임의 쿼터니언 변화율이며, q는 센서 프레임에서 지구 프레임으로의 회전을 나타내는 쿼터니언이다. 기호 $\otimes$는 쿼터니언 곱을 나타낸다. 식 (7)에서 $\dot{q}_t$는 시점 t에서의 쿼터니언 변화율이며, q_{t-1}은 이전 시점의 쿼터니언 값이다. 식 (8)에서는 샘플링 주기 Δt를 기준으로 쿼터니언 변화율 $\dot{q}_t$을 적분하여 q_{t-1}에서 $q_{t+\Delta t}$로 업데이트한다. 이 과정을 통해 센서 프레임에서 지구 프레임으로의 연속적인 방향 추정이 가능해진다.

그러나 자이로스코프 기반 방향 추정 기법은 각속도 적분 과정에서 발생하는 드리프트 현상으로 인해, 시간이 지남에 따라 정확도가 점차 저하되는 한계가 있다[37]. 이러한 자이로스코프 드리프트는 실내 위치 추정 및 다양한 센서 융합 기반 시스템에서 심각한 문제를 야기하며, 특히 PDR 기술에서는 사용자 이동 방향의 부정확성이 최종 위치 추정 결과

에 큰 영향을 미치는 주요 원인이 된다. 이러한 드리프트 문제를 보완하기 위해 다양한 보정 기법이 제안되었다.

첫째, 지자기 센서를 통한 절대 방향 정보와 가속도계를 통한 자세 추정 정보를 결합하여 자이로스코프 데이터를 보정하는 방법이 있다. 이때, 칼만 필터 또는 상보 필터와 같은 알고리즘을 적용하여 센서 데이터를 융합함으로써 드리프트를 보정한다[15].

둘째, 특정 조건에서 주기적으로 자이로스코프 값을 초기화하여 드리프트 누적을 줄이는 방법이 있다[38].

셋째, 건물 내 특정 위치에 소프트웨어 보정 노드를 설정하여 주기적으로 위치와 방향 정보를 재보정하는 방법이 있다[19].

그러나 이러한 보정 기법들도 자이로스코프의 근본적인 하드웨어 한계를 완전히 극복할 수는 없다. 특히 실내 환경에서는 건물 내 강철 구조물로 인한 자기장 왜곡, 전자기기에서 발생하는 전자파 간섭 등의 문제로 인해 정확한 절대 방향 측정이 어려운 한계가 존재한다. 따라서 드리프트 문제를 해결하기 위해서는 새로운 알고리즘의 개발뿐만 아니라, 기존 보정 기법의 한계를 극복할 수 있는 추가적인 접근법이 필요하다.

제 3 장 자기장 맵 및 딥러닝 기반 다층 실내 측위 기법

제안하는 실내 위치 추정 기법은 [그림 3-1]에 나타낸 바와 같이 동작하며, 2장에서 설명한 외부 인프라 비의존 다층 실내 위치 추정 기법의 기존 문제를 해결하도록 설계되었다. 본 장에서는 먼저 3차원 위치 초기화 기법에 대해 설명하고, 이어서 위치 추정 과정에서 발생할 수 있는 드리프트 문제를 효과적으로 보정하는 방법을 제시한다.

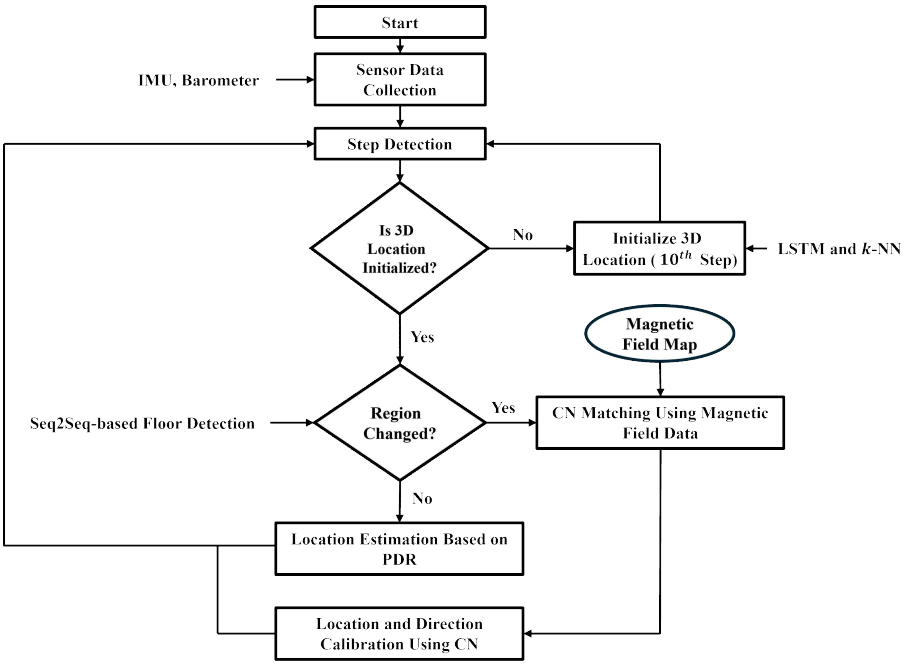

[그림 3-1] 제안 기법의 흐름도

3.1 3차원 위치 초기화

본 절에서는 3차원 위치 초기화를 위해 수행되는 층수 탐지 및 초기 위치 추정 절차를 상세히 설명한다. 이러한 절차는 2.1 및 2.2절에 기술한 다층 실내 위치 추정의 주요 도전 과제를 해결하는 것을 목표로 한다. 또한, 본 절의 결과는 PDR 기반 및 기압계 보조 다층 실내 위치 추정 기법의 효과적인 동작을 위한 필수 조건을 충족시킨다.

3.1.1 초기 층 탐지

스마트폰에 내장된 IMU 센서 중 하나인 지자기 센서는 주변 환경의 자기장 세기와 방향을 측정하며, 지구 자기장을 기반으로 동작해 지구의 자기 북극을 가리키는 나침반 역할을 수행한다[39]. 그러나 실내 환경에서는 건물의 강철 구조물이나 전자기기 등의 외부 요인으로 인해 지자기 센서의 측정값이 왜곡되며, 이러한 왜곡으로 인해 지자기 센서는 단독으로 방향을 추정하는 데 충분한 정확성을 제공하지 못한다. 따라서 지자기 센서는 주로 보조 센서로 활용된다.

본 연구에서는 기압계 기반 층수 탐지 기법의 한계를 보완하기 위해, 지구 자기장을 기반으로 수집된 실내 자기장 데이터를 활용한 초기 층수 탐지 기법을 제안한다[40]. 건물의 강철 구조물 및 외부 요인으로 인해 각 층의 자기장 시퀀스는 고유한 패턴을 형성하며, 이러한 패턴은 [그림 3-2]에 나타나 있다. 본 연구에서는 이러한 고유한 자기장 패턴을 분석하여 초기 층수 정보를 탐지하는 데 활용하였다.

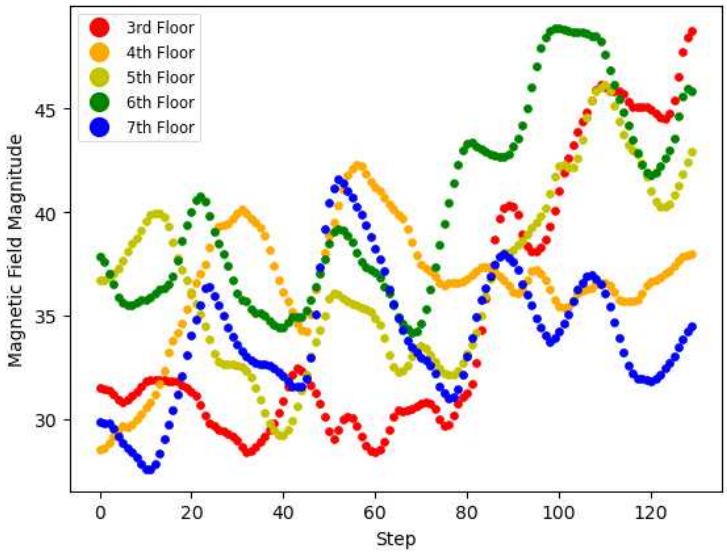

[그림 3-2] 각 층의 자기장 데이터 시퀀스

이를 입증하기 위해, 본 연구에서는 숭실대학교 형남공학관 및 조만식기념관의 3층부터 7층까지의 자기장 데이터를 Samsung Galaxy Note 10+ 스마트폰을 사용하여 수집하였다. 데이터는 사용자가 이동 중 각 스텝 이벤트에서 트리거되는 자체 개발한 Android 애플리케이션을 통해 수집되었다. 데이터 수집 경로는 데이터는 [그림 3-3]과 같이 한 방향으로 보행하면서 수집되었으며, 실험 중 스마트폰은 사용자의 손에 들려 화면이 위를 향하도록 유지하였다. 형남공학관과 조만식기념관은 모든 층에서 동일한 구조를 가지고 있으며, 스텝이 발생할 때마다 센서 데이터가 기록되었고, 각 층에서의 총 보행 스텝 수는 130으로 동일하게 설정되었다.

스텝 탐지는 IMU의 가속도 센서를 이용하여 수행되었으며, 가속도 센서 기반 스텝 탐지 과정은 아래와 같다[41].

$$a_t^G = R_t a_t^L. \tag{9}$$

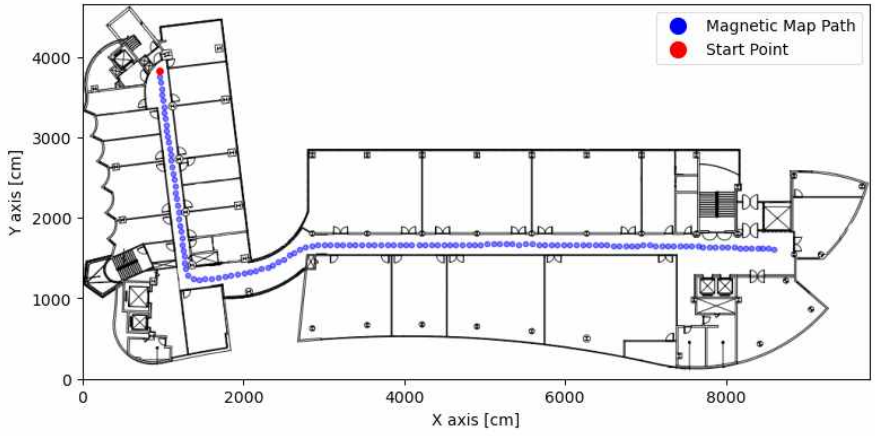

[그림 3-3] 자기장 데이터 수집 경로

여기서 α_t^G는 글로벌 좌표계 (Global Coordinate System; GCS)로 변환된 가속도 벡터를, α_t^L는 로컬 좌표계 (Local Coordinate System; LCS)에서의 가속도 벡터를 나타낸다. 또한, R_t는 회전 행렬 (Rotation Matrix)로서, 이는 가속도계와 지자기 센서의 값을 기반으로 Android의 SensorManager.getRotationMatrix() 메서드를 사용하여 계산된다. 걸음 감지 조건은 다음과 같다:

$$\alpha_{\mathrm{t}}^z > acc^{upper}, \alpha_{t+\Delta t}^z < acc^{lower}, 0 < \Delta < 1. \quad (10)$$

여기서 α_t^z는 수직 가속도를, acc^{upper}와 acc^{lower}는 스텝 탐지를 위한 임계값을, Δt는 최대 가속도와 최소 가속도 사이의 시간 간격을 나타낸다.

지자기 센서의 측정값은 3차원 벡터로 표현되며, 이는 스마트폰의 방향에 따라 변화한다. 따라서 동일한 위치에서도 스마트폰의 방향에 따라 측정값이 달라질 수 있으며, 이러한 방향 의존성은 자기장 맵 생성 과정에서 오류를 유발할 수 있다. 이로 인해 각 위치의 고유 자기장 특성을 정확하게 반영하지 못하는 문제가 발생할 수 있다.

본 연구에서는 이러한 문제를 해결하기 위해, 자기장 맵을 구축하기

전에 수집된 모든 자기장 벡터를 기준 방향에 정렬하는 방식을 적용하였다. 기준 방향은 [그림 3-3]에 나타낸 바와 같이 지도상의 북쪽 (0도)으로 설정하였다. 실험에서는 모든 자기장 벡터를 이 기준 방향에 정렬하여, 스마트폰의 방향에 관계없이 각 위치의 고유 자기장 특성을 정확하게 식별할 수 있도록 하였다. 자기장 벡터의 회전 변환은 다음과 같은 과정을 통해 수행되었다.

$$V_{mag} = [v_x v_y v_z]^T, \tag{11}$$

$$R_z(\theta) = \begin{bmatrix} \cos\theta & -\sin\theta & 0 \\ \sin\theta & \cos\theta & 0 \\ 0 & 0 & 1 \end{bmatrix} \tag{12}$$

$$\begin{aligned} V'_{mag} &= R(\theta)\, V_{mag} \\ &= \begin{bmatrix} \cos\theta & -\sin\theta & 0 \\ \sin\theta & \cos\theta & 0 \\ 0 & 0 & 1 \end{bmatrix} [v_x v_y v_z]^T \\ &= \begin{bmatrix} \cos\theta \cdot v_x - \sin\theta \cdot v_y \\ \sin\theta \cdot v_x + \cos\theta \cdot v_y \\ v_z \end{bmatrix}. \end{aligned} \tag{13}$$

여기서 V_{mag}는 자기장 벡터를 나타내며, v_x, v_y, v_z는 그 성분이다. 스마트폰의 현재 기준 방향으로부터의 회전 각도는 θ로 나타내며, 이는 내장된 자이로스코프 센서를 통해 계산된다. 축 회전을 위한 회전 행렬은 R로 나타내며, 회전된 자기장 벡터 V'_{mag}는 (11)과 (12)에서 얻은 자기장 벡터와 회전 행렬을 이용하여 식 (13)의 관계식에 따라 계산된다.

데이터 증강 (Data Augmentation) 기법은 모델의 일반화 성능을 향상하거나 학습 데이터가 부족한 경우 과적합 (Overfitting)을 방지하기 위해 자주 사용된다. 본 연구에서는 각 층별로 130스텝에 대한 자기장 시퀀스 데이터를 수집하였다. 추가적인 데이터 수집 없이 데이터 다양성을 확보하기 위해, 각 층의 자기장 시퀀스에 회전 변환을 적용하는 방식으로 데이터 증강을 수행하였다. 각 층의 자기장 시퀀스 데이터에는 ±10

도 범위의 임의의 회전 각도를 적용하여 60개의 자기장 시퀀스를 생성하였다. 이 중 30개의 시퀀스는 원본 데이터를 역방향으로 처리하여 생성한 것으로, 딥러닝 모델이 역방향 경로의 자기장 패턴도 학습할 수 있도록 하였다. 이러한 데이터 증강 과정은 각 층별 자기장 데이터의 다양성을 높이고, 학습 데이터셋을 확장하며, 모델의 일반화 성능을 향상시키고 과적합을 방지하는 데 기여하였다.

슬라이딩 윈도우 (Sliding Window) 기법은 시계열 데이터를 처리하는 데 유용한 방법으로, 본 연구에서는 데이터 증강이 완료된 자기장 시퀀스에 이 기법을 적용하였다. 슬라이딩 윈도우 기법은 고정된 크기의 윈도우를 데이터 위에서 일정 간격으로 이동시키며, 각 윈도우 내의 데이터를 모델 학습에 활용하는 방식이다[42]. 본 연구에서는 윈도우 크기를 10으로 설정하여, 원본 데이터셋 (650, 3) 형태의 자기장 시퀀스를 데이터 증강 및 슬라이딩 윈도우 기법을 통해 (36,300, 10, 3) 형태의 데이터셋으로 변환하였다. 변환된 데이터셋은 학습용, 검증용, 테스트용 데이터로 8:1:1의 비율로 분할하였으며, 각각 29,040개, 3,630개, 3,630개의 샘플로 구성되었다.

[그림 3-4]는 제안하는 LSTM 모델의 개요를 보여준다. LSTM 네트워크는 시계열 데이터를 처리하고 시간적 패턴을 학습하는 데 효과적이며, 특히 실내 위치 추정과 같은 문제에서 뛰어난 성능을 보인다[43]. 제안된 LSTM 모델은 전처리된 3축 자기장 데이터를 입력으로 사용하며, 각 데이터에 대응하는 층수 정보를 레이블로 하여 오프라인으로 학습되었다. 이후 온라인 단계에서는 동일한 형태의 3축 자기장 데이터가 모델 입력으로 주어지며, 실시간으로 사용자의 층수를 예측한다.

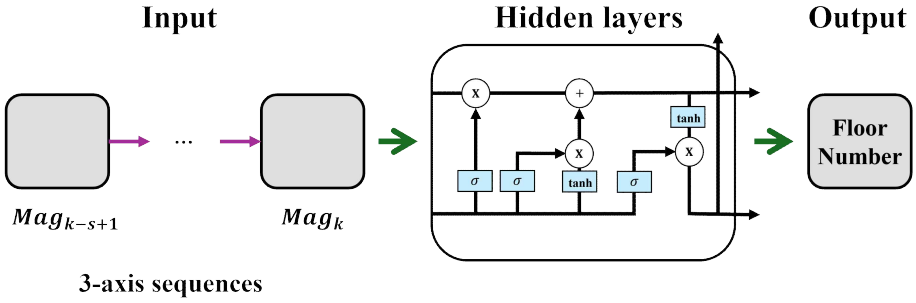

[그림 3-4] LSTM 모델 개요

[표 3-1] LSTM 모델 학습에 사용된 하이퍼파라미터

Model parameters	Values
Number of LSTM layers	2
Parameters in LSTM layers	116,992
Number of trainable parameters	119,237
Activation function of hidden layers	ReLU
Activation function of output layer	Softmax
Initializer	Xavier uniform
Loss function	Categorical cross entropy
Optimizer	Adam
Learning rate	0.001
Number of epochs	30

주요 학습 하이퍼파라미터는 [표 3-1]에 요약되어 있다. 은닉층(Hidden Layers)에서는 기울기 소실 (Vanishing Gradient) 문제를 완화하고 학습 속도를 향상시키기 위해 ReLU (Rectified Linear Unit) 활성화 함수를 사용하였다. 출력 계층에서는 다중 클래스 분류를 수행하기 위해 Softmax 활성화 함수를 적용하였다. 손실 함수로는 예측 확률과 실제 층수 레이블 간의 차이를 최소화하기 위해 Categorical Cross-Entropy를 사용하였으며, 학습의 안정적 수렴과 효율성을 위해 Adam Optimizer를 적용하였다.

3.1.2 초기 위치 추정

3.1.1절에서 소개한 초기 층수 탐지 과정을 통해 층수 정보가 확보되면, 2D 초기 위치 정보만 추가되면 인프라 제약 환경에서의 다층 실내 위치 추정 기법 구현을 위한 조건이 충족된다. 이를 위해 본 연구에서는 사전에 구축된 자기장 맵에 k-NN 알고리즘을 적용하여 사용자의 초기 위치를 추정한다[44].

k-NN 알고리즘은 머신러닝 분야에서 분류 (Classification) 및 회귀 (Regression) 문제에 널리 사용되는 단순하고 직관적인 알고리즘으로, 새로운 데이터 포인트에 대해 기존 데이터 중 k개의 최근접 이웃을 찾아 이들의 정보를 바탕으로 예측값을 산출한다[45]. 이웃 간의 거리를 계산하기 위해 일반적으로 유클리드 거리 (Euclidean Distance)를 사용하지만, 맨해튼 거리 (Manhattan Distance)나 코사인 유사도 (Cosine Similarity) 등의 다른 거리 측정 방법도 적용할 수 있다. 본 연구에서는 자기장 데이터 간의 유사도를 측정하기 위해 유클리드 거리를 선택하였다. 두 n차원 데이터 포인트 x와 y 사이의 유클리드 거리는 다음과 같이 계산된다.

$$Distance(x, y) = \sqrt{\sum_{i=1}^{n} (x_i - y_i)^2}\,. \tag{14}$$

이 거리를 기준으로 k-NN 알고리즘은 새로운 데이터 포인트의 k개의 최근접 이웃을 선택한다. 분류 문제의 경우, 선택된 이웃 중 가장 빈도가 높은 클래스를 새로운 데이터 포인트에 할당하며, 회귀 문제의 경우에는 k개의 이웃 값의 평균을 예측값으로 계산한다.

본 연구에서는 문제를 회귀 문제로 접근하여 k-NN 알고리즘을 적용하였다. 구체적으로, 건물 내 각 층의 사전에 구축된 자기장 맵을 데이터베이스로 사용하고, 스마트폰의 지자기 센서를 통해 수집된 3축 지구 자

기장 값을 입력 데이터로 사용한다. 자기장 데이터는 3D 벡터 형태로 표현되며, 레이블 데이터는 건물 평면도 상의 위치 좌표로 구성된다. 알고리즘은 초기 층수 정보가 결정된 이후 동작한다. 사용자가 애플리케이션을 실행하고 10스텝을 이동하면, 이 10스텝의 자기장 시퀀스 데이터셋이 생성된다. 이 데이터는 초기 층수 탐지에 활용되며, 이후 10번째 스텝에서의 자기장 데이터는 탐지된 층의 자기장 맵과 비교된다. k-NN 알고리즘은 이 데이터를 바탕으로 사용자의 2D 위치를 예측한다.

이 과정을 통해 사용자는 실내 어디에서든 첫 10스텝 이후 3D 위치를 추정할 수 있다[46]. 본 방식은 기압계 기반 층수 탐지 및 IMU 센서를 활용한 PDR 기법의 한계를 효과적으로 극복할 수 있는 접근법이다.

3.2 3차원 위치 추적 방법

본 절에서는 2.3절에서 논의한 스마트폰 IMU 센서를 활용한 PDR 기법의 드리프트 현상을 완화하기 위한 방법으로, 보정 노드를 적용하는 기법을 소개한다. 사용자의 3D 위치가 초기화된 이후, 제안된 방법은 기압 센서를 활용하여 층 이동 (Floor Transition)을 감지하고, 드리프트 현상을 보완하기 위해 보정 노드를 적용함으로써 위치 추정 정확도를 향상시킨다.

3.2.1 층 이동 감지 기법

기압 센서는 대기압을 측정하는 센서로, 고도 변화를 감지하기 위해 스마트폰을 포함한 다양한 기기에 널리 사용된다. 대기압은 고도에 따라 변하기 때문에, 기압계 데이터를 활용하면 스마트폰 사용자의 상대 고도를 추정할 수 있다. 이는 인프라 제약 환경에서 다층 실내 위치 추정 기

법을 구현하는 데 필수적인 정보를 제공한다.

본 연구에서는 기압 센서 데이터를 딥러닝 모델과 결합하여, 층 이동을 정확하게 탐지할 수 있는 다층 실내 위치 추정 기법을 개발하였다 [12], [19]. 이를 위해 숭실대학교 형남공학관에서 평면 및 계단 구간에서 발생하는 층 이동 데이터를 수집하였다. 기압 센서 데이터는 스텝 이벤트가 감지될 때만 스마트폰 데이터베이스에 저장되었다. 수집된 기압 데이터는 평균 중심화 (Mean Centering)를 적용하여 평균값을 제거한 후 전처리하였으며, 딥러닝 모델이 시간적 패턴을 효과적으로 학습할 수 있도록 슬라이딩 윈도우 기법을 적용하였다. 슬라이딩 윈도우의 크기는 15로 설정하였다.

본 연구에서는 시계열 기압 센서 데이터를 처리하기 위해 Seq2Seq 딥러닝 모델을 사용하였다. Seq2Seq 모델은 일반적으로 LSTM 기반의 인코더 (Encoder)와 디코더 (Decoder)로 구성되며[47], 인코더는 입력 시퀀스를 고정된 크기의 벡터로 압축하고, 디코더는 이 벡터를 기반으로 출력 시퀀스를 생성한다. Seq2Seq 모델은 입력과 출력 시퀀스의 길이가 다른 경우에도 유연하게 대응할 수 있으며, 시계열 패턴 학습에 효과적이다.

[표 3-2]는 Seq2Seq 모델 학습에 사용된 주요 하이퍼파라미터를 나타낸다. 본 연구에서는 문제를 단일 출력 분류 문제로 정의하였으며, Seq2Seq 모델은 각 데이터 포인트를 0 (Down), 1 (Flat), 2 (Up) 중 하나로 분류한다. 모델의 입력은 15개의 연속적인 기압 변화 값이며, 출력은 사용자의 현재 스텝 상태를 예측한다. 사용자가 애플리케이션을 실행하면, 각 스텝에서의 기압 변화값이 길이 15의 큐 (Queue)에 저장된다. 작은 기압 변화는 평지로, 큰 변화는 상승 또는 하강으로 분류된다.

[표 3-2] Seq2Seq 모델 학습에 사용된 하이퍼파라미터

Model parameters	Values
Model type	Seq2Seq (Encoder - Decoder)
LSTM units (Encoder/Decoder)	16 (1,152 params)
Number of trainable parameters	2,355
Activation function of hidden layers	tanh
Activation function of output layer	Softmax
Initializer	Xavier uniform
Loss function	Sparse categorical cross entropy
Optimizer	Adam
Learning rate	0.001
Number of epochs	30

엘리베이터 기반 층 이동은 기압 변화 임계값을 기준으로 감지하였다. 기압계는 밀리바 (mbar) 단위로 기압을 측정하며, 1개 층 이동에 대한 경험적 임계값은 0.3 mbar로 설정하였다. 모델이 Up 또는 Down 상태를 예측하고, 연속된 스텝 간 기압 차이가 0.3 mbar를 초과하면 사용자가 엘리베이터를 사용한 것으로 판단하였다. 예측된 스텝 상태는 사전에 구축된 상대 기압 맵 (Relative Pressure Map)과 결합되어 층 이동 탐지 및 보정에 활용된다.

본 연구에서는 전체 건물의 상대 기압 맵을 구축하여 층 이동 과정에서 정확한 층수 식별이 가능하도록 하였다. 상대 기압 맵은 다음과 같은 단계로 구축되었다.

1. **기압 데이터 수집:** 각 층에서 기압계 센서를 사용해 대기압 데이터를 수집하고, 각 층의 평균 기압값을 계산하였다.
2. **기압-고도 변환:** 대기압 데이터를 미터 단위의 고도 값으로 변환하여 층별 높이를 계산하였다. 변환 과정은 다음 식 (15)에 따라 이루어진다[48].

$$h_i = 44330 \times (1 - \sqrt[5.255]{\frac{p_i}{p_0}}). \quad (15)$$

여기서 h_i는 상대 고도, p_i는 기압계 측정값, p_0는 해수면 기준 대기압을 의미한다.

3. **상대 고도 계산:** 변환된 고도 데이터를 기반으로 층 간 높이 차이를 계산하고, 이를 정규화하여 상대 층 고도를 결정하였다.
4. **상대 기압 맵 구축:** 각 층의 고도 값은 딕셔너리 형태로 저장되며, 이 맵은 사용자의 현재 층수를 고도 변화에 따라 가장 가까운 층수로 매핑하여 층수를 추정한다.

상대 기압 맵은 다층 실내 환경에서 정확한 층 이동 탐지를 지원하며, 사용자의 현재 층을 실시간으로 확인할 수 있는 기능을 제공한다.

3.2.2 자기장 데이터 기반 보정 노드 활용 방안

PDR 기법은 사용자의 이동 중 위치와 방향을 추정하는 데 유용한 방법이다. 그러나 앞서 언급한 바와 같이, PDR 기반 시스템은 시간이 지남에 따라 누적 오차가 발생하여 위치 추정 정확도가 점차 저하되는 문제가 있다. 본 연구에서는 이러한 드리프트 문제를 완화하기 위해, 자기장 데이터를 활용한 보정 노드를 적용하는 방법을 제안한다[49].

기존의 보정 노드는 주로 기압 변화에 기반하여 가장 가까운 노드를 선택하는 방식으로 구현되었으나[12], [19], 본 연구에서는 비균일한 자기장 분포를 활용한 새로운 접근법을 도입하여 보다 정밀한 위치 보정이 가능하도록 하였다. 또한, 본 연구에서의 보정 노드는 소프트웨어 기반으로 구현되어, 별도의 하드웨어 설치 없이 적용이 가능하다.

이를 위해, 각 층의 계단 및 엘리베이터 등 수직 이동 구간 주변에서 사전에 자기장 데이터를 수집하였다. [그림 3-5]는 구축된 보정 노드 목

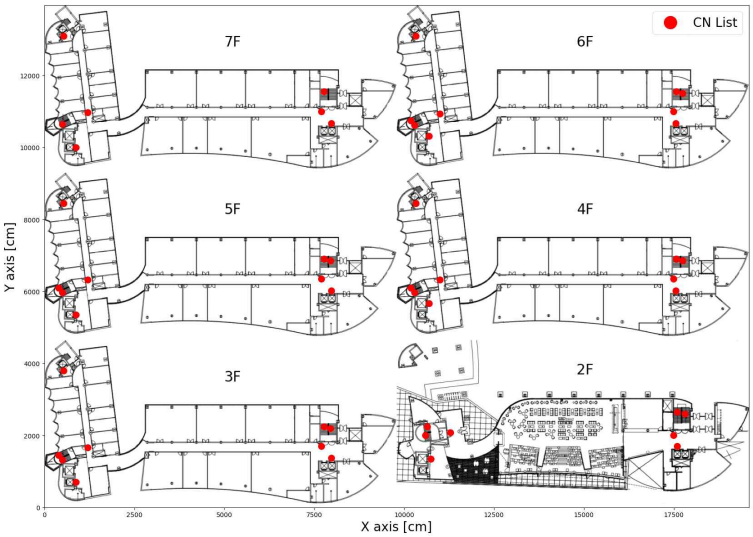

[그림 3-5] 각 층의 보정 노드

록을 나타낸다. 제안된 보정 노드는 기존 방식과 달리, 자기장 데이터뿐만 아니라 방향 정보, 위치 정보, 층수 정보, 그리고 수직 이동 메커니즘 정보를 통합하여 사용자의 위치 및 방향을 실시간으로 정밀하게 보정할 수 있도록 설계되었다. 보정 노드의 동작 과정은 다음과 같다.

1. **보정 노드 탐색 및 매칭:** 사용자의 경로 상에서 층 이동 탐지 모델이 층 이동을 식별하면, 현재 위치의 자기장 데이터와 해당 층에 사전 구축된 보정 노드 목록의 자기장 데이터를 비교하여 가장 유사한 보정 노드을 검색하고 매칭한다.
2. **유사도 계산:** 보정 노드와 사용자의 자기장 데이터 간의 유사도는 3축 자기장 데이터 유클리드 거리를 사용하여 계산한다. 유사도 거리가 가장 작은 보정 노드가 선택되며, 이를 통해 보정 과정의 신뢰성을 향상시킨다.
3. **보정 과정:** 선택된 보정 노드가 제공하는 정밀한 위치 및 방향 정보를 기반으로 사용자의 추정 위치와 방향을 업데이트한다. 이를 통

해 PDR 기법에서 발생하는 드리프트 문제를 효과적으로 완화하며, 장거리 이동 중에도 높은 위치 정확도를 유지할 수 있다.

보정 노드 기반의 위치 및 방향 업데이트는 PDR 기법과 상호 보완적으로 동작한다. 층 이동이 탐지되지 않는 경우에는 사용자의 위치를 보폭 및 방향 변화에 따라 추정하며, 반대로 층 이동이 탐지되고 보정 노드 기반 보정이 적용되는 경우에는 보정 노드가 제공하는 정보를 바탕으로 사용자의 위치와 방향을 갱신한다.

본 연구에서는 층 이동 탐지 모델의 출력 결과를 기반으로 보정 과정을 반복적으로 적용하여, PDR 시스템의 누적 오차를 효과적으로 제거하였다.

제 4 장 실험 결과

본 장에서는 딥러닝 및 센서 융합 기반 다층 실내 위치 추정 기법의 실험 및 결과를 제시한다. 모든 실험은 데이터 수집에 사용된 동일한 기기인 Samsung Galaxy Note 10+를 사용하여 수행되었다. 본 장의 구성은 다음과 같다. 먼저, 스마트폰 사용자를 대상으로 수행한 초기 층수 탐지 실험 및 그 결과를 제시한다. 이어서, 층수 정보가 주어진 상태에서의 초기 위치 추정 실험 및 결과를 설명하며, 마지막으로 3D 위치 초기화 후 보정 노드를 이용한 드리프트 완화 실험 및 결과를 포함한다.

4.1 초기 층 탐지 실험

본 연구에서는 숭실대학교 형남공학관과 조만식기념관의 3층부터 7층까지를 대상으로 초기 층수 탐지 실험을 수행하였다. 제안 기법의 타당성을 검증하기 위해, 데이터 수집은 자기장 맵 구축에 사용된 경로와 반대 방향의 경로에서 진행하였다. 수집된 자기장 데이터는 학습 데이터 전처리 과정과 동일하게 슬라이딩 윈도우 기법을 적용하여 처리하였으며, 윈도우 크기는 10으로 설정하였다. 이를 통해 데이터는 (121, 10, 3) 형태로 변환되어 모델의 입력으로 사용되었다.

[표 4-1] 초기 층 탐지 정확도

Accuracy	3rd	4th	5th	6th	7th	Average
Hyeongnam	95%	86.8%	94.2%	95%	89.3%	**92.06%**
Cho Man-Sik	95%	94.2%	97.5%	90.9%	90.9%	**93.7%**

[표 4-2] 형남공학관 초기 층 탐지 혼동 행렬

	Predicted Class					
		3rd	4th	5th	6th	7th
Ground truth	3rd	**95.0%**	1.7%	0%	2.5%	0.8%
	4th	1.7%	**86.8%**	5.8%	2.5%	3.2%
	5th	1.7%	0%	**94.2%**	2.5%	1.6%
	6th	0%	1.7%	2.5%	**95.0%**	0.8%
	7th	0.8%	6.5%	1.7%	1.7%	**89.3%**

[표 4-3] 조만식 기념관 초기 층 탐지 혼동 행렬

	Predicted Class					
		3rd	4th	5th	6th	7th
Ground truth	3rd	**95.0%**	0%	0%	4.1%	0.8%
	4th	0.8%	**94.3%**	4.1%	0%	0.8%
	5th	0.8%	0.8%	**97.6%**	0%	0.8%
	6th	0.8%	0%	1.7%	**90.9%**	6.6%
	7th	0.8%	0.8%	2.5%	5.0%	**90.9%**

[표 4-1]부터 [표 4-3]에 나타난 바와 같이, 제안한 자기장 맵 기반 딥러닝 모델은 다양한 테스트 환경에서 높은 층수 탐지 성능을 보였다. [표 4-1]의 층수 탐지 정확도는 자기장 시퀀스에 크기 10의 슬라이딩 윈도우를 적용한 후 계산되었으며, 각 윈도우에 대해 모델이 예측한 층수 레이블이 실제 층수와 일치하면 올바른 예측으로 간주하였다. 최종 정확도는 전체 윈도우 중 정확히 예측된 윈도우의 비율로 산출되었다.

[표 4-1]은 형남공학관과 조만식기념관 각각의 전체 층수 탐지 정확도를 나타내며, 평균 정확도는 조만식기념관에서 93.7%, 형남공학관에서 92.06%를 기록하였다. 이는 서로 다른 건물 환경에서도 높은 일반화 성능을 입증한 결과이다. [표 4-2]와 [표 4-3]은 모델이 각 층을 어떻게 분류했는지를 보여주는 상세한 혼동 행렬 (Confusion Matrix)이다.

이러한 결과는 모델이 각 층별 고유한 자기장 패턴을 효과적으로 학습했음을 검증하며, 사용자 이동 초기 10스텝 이내에 외부 인프라 없이 초기 층수를 탐지할 수 있는 요구사항을 충족함을 확인하였다.

4.2 초기 위치 추정 실험

위의 과정을 통해 사용자의 층수 정보가 결정되면, 2D 위치 정보가 추가로 제공되어 PDR 기법을 적용할 수 있다. 본 연구에서는 2D 위치를 추정하기 위해 k-NN 알고리즘을 사용하였으며, k 값은 실험적으로 3으로 설정하였다.

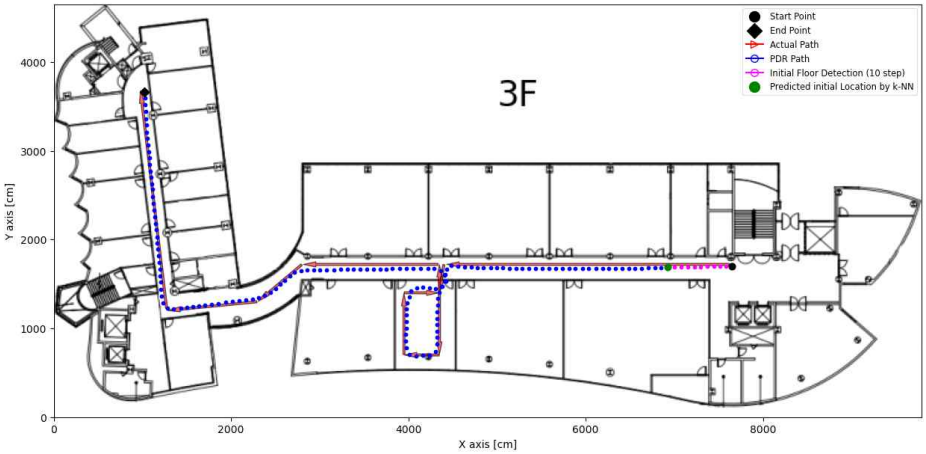

[그림 4-1] 형남공학관의 3차원 위치 초기화 실험 결과

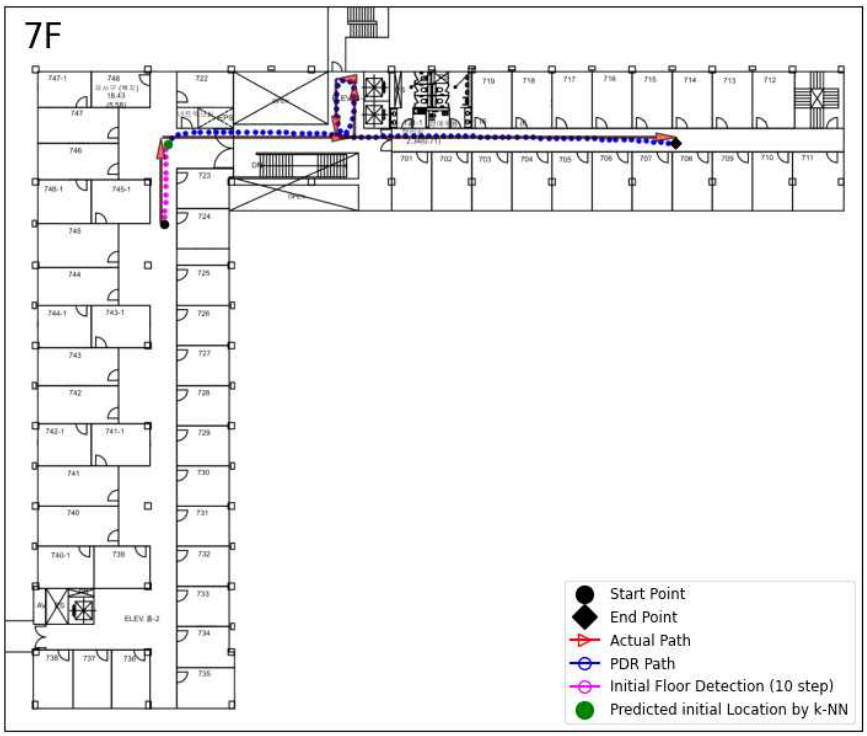

[그림 4-2] 조만식 기념관의 3차원 위치 초기화 실험 결과

[그림 4-1]은 숭실대학교 형남공학관 3층에서 수행한 초기 층수 탐지 및 2D 위치 추정 결합 실험의 결과를 나타낸다. [그림 4-1]에서 확인할 수 있듯이, 초기 10스텝의 자기장 데이터를 통해 층수 정보가 결정되었으며, 이후 사용자의 현재 위치는 해당 층의 자기장 맵과 스마트폰의 지자기 센서 데이터를 비교하여 k-NN 알고리즘을 통해 추정되었다. 초기 층수 및 위치 정보가 결정됨으로써 PDR과 기압계 기반 층 이동 탐지 기법을 적용하기 위한 조건이 충족되었다. 이후 파란색 궤적으로 나타난 PDR 기반 경로는 실제 경로와 유사하게 나타났으며, 일관되고 높은 정확도의 위치 추정 성능을 확인할 수 있었다.

제안 기법의 효과를 추가적으로 검증하기 위해, 동일한 절차를 조만식

기념관에서도 수행하였으며, 그 결과는 [그림 4-2]에 제시하였다.

4.3 인프라 제한 환경에서 다층 실내 측위 실험

스마트폰을 이용해 사용자의 3차원 위치를 추정한 후, 다층 실내 위치 추정 실험을 수행하였다. 실험은 숭실대학교 형남공학관의 7층, 4층, 3층, 2층에서 진행되었으며, 각 층의 구조는 7층, 4층, 3층은 복도 형태, 2층은 대형 강의실 형태였다. 실험 동안의 총 보행 거리는 약 600m였다.

층 이동 실험의 예시는 [그림 4-3]에 나타나 있다. 보행자는 7층에서 실험을 시작하여 계단을 이용해 4층으로 이동한 후, 4층에서 일정 거리를 이동하고 엘리베이터를 통해 2층으로 내려갔다. 이후 2층에서 이동한 후 다시 계단을 이용해 3층으로 올라가 짧은 거리를 이동한 후 실험을 종료하였다.

실험 결과, 오르막과 내리막, 계단 및 엘리베이터를 통한 층 이동 등 다양한 상황에서의 층 이동이 정확히 탐지됨을 확인하였다.

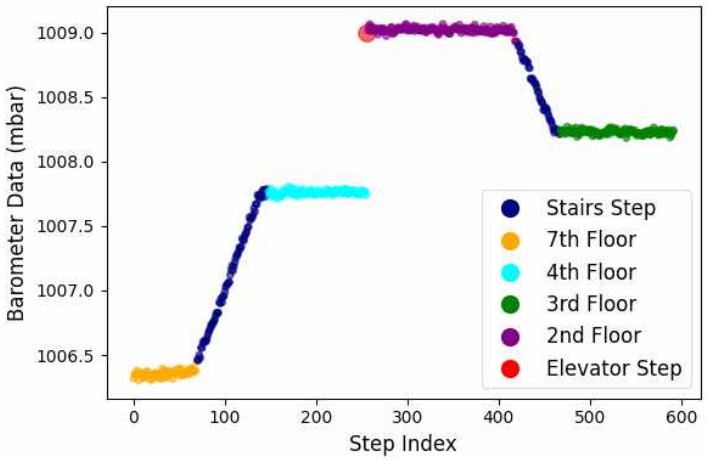

[그림 4-3] 층 이동 감지 실험 결과

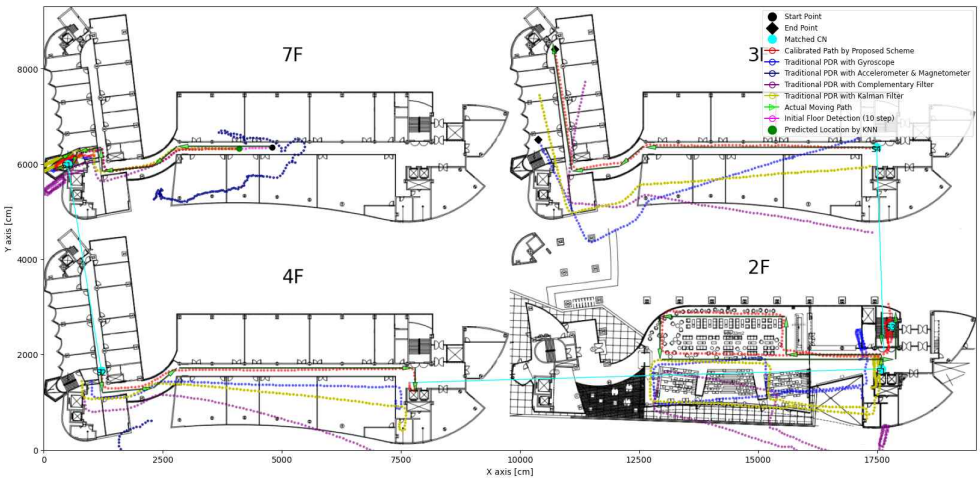

[그림 4-4] 제안 기법 실험 결과와 기존 측위 기법 실험 결과 비교

[표 4-4] AR 및 RMSE 평가 결과

	AR $\epsilon = 0.5$	AR $\epsilon = 1.0$	AR $\epsilon = 1.5$	AR $\epsilon = 2.0$	RMSE [m]
Proposed scheme	48.9%	93.42%	98.65%	99.83%	0.64
PDR with Gyroscope	6.57%	11.8%	19.73%	26.3%	4.96
PDR with Acc&Mag	0.17%	0.17%	0.34%	0.34%	66.38
PDR with CF	0.34%	3.04%	6.58%	7.59%	8.4
PDR with KF	0.34%	3.04%	8.6%	10.79%	6.12

[그림 4-4]는 실험 경로를 따라 측정된 위치 추정 결과를 나타낸다. 7층의 검은색 점은 실험의 시작점을, 분홍색 점은 초기 10스텝의 데이터로 초기 층수 탐지에 사용된 구간을 나타낸다. 초기 층수 탐지 후, 추정된 초기 위치는 녹색 점으로 표시되며, 매칭된 보정 노드는 연한 파란색

점으로 나타난다.

예를 들어, S1은 7층에서 4층으로 계단을 내려가는 동작을 나타내며, 이는 층 이동 탐지 모델에 의해 정확히 탐지되고 매칭된 결과이다. S2는 4층 계단 진입 동작을, E1은 4층에서 2층으로 엘리베이터를 이용한 동작을 나타낸다. S3 및 S4 또한 스텝 상태 변화 탐지를 통해 식별된 매칭된 보정 노드이다.

실제 경로는 녹색 화살표로 표시되었으며, 제안 기법의 위치 추정 결과는 빨간색으로 나타냈다. 기존 PDR 기법의 결과는 파란색 (자이로스코프 단독), 네이비 (가속도 센서 및 지자기 센서 조합), 보라색 (상보 필터), 노란색 (칼만 필터)으로 각각 표시되었다.

다층 실내 위치 추정 기법의 정확도를 평가하기 위해 RMSE (Root Mean Square Error)와 AR (Accuracy Rate)을 성능 지표로 사용하였다. 계산된 성능 지표는 [표 4-4]에 제시되었으며, RMSE와 AR은 다음의 과정으로 계산되었다[50].

$$RMSE(P_k, \hat{P}_k) = \sqrt{\frac{\sum_{k=1}^{N}(P_k - \hat{P}_k)^2}{N}}, \tag{16}$$

$$\delta_k = \sqrt{(P_k - \widehat{P_k})^2}, \ \ 0 < k \leq N, \tag{17}$$

$$AR = \frac{\#\ \{\delta_{\mathrm{k}} \mid \delta_{\mathrm{k}} \leq \epsilon\}}{N} \cdot 100\%. \tag{18}$$

여기서 $RMSE(P_k, \hat{P}_k)$는 실제 위치 P_k 와 예측된 위치 $\hat{P}_k$간의 평균 제곱근 오차를 의미하며, AR은 사전에 정의된 오차 허용 범위 ϵ 내에 포함된 예측 위치의 비율을 백분율로 나타낸다.

실험 결과, 기존의 다층 실내 위치 추정 기법은 초기 위치 추정을 위해 인프라에 의존해야 하며, 드리프트로 인한 정확도 저하의 한계를 지님을 확인하였다. 반면, 제안 기법은 인프라 없이도 초기 위치를 정확하

게 추정할 수 있었으며, 실제 위치와 매우 유사한 예측 결과를 제공하였다. 또한, 보정 노드를 활용함으로써 층 이동 과정에서 발생하는 드리프트로 인한 위치 오차를 효과적으로 줄일 수 있었다. 이러한 결과는 제안 기법이 실제 경로와 유사한, 안정적이고 높은 정확도의 위치 추정 성능을 제공함을 입증한다.

제 5 장 결론

본 논문에서는 스마트폰에 내장된 센서만을 활용하여 3차원 위치 초기화 문제와 PDR에서 발생하는 누적 오차, 즉 드리프트 문제를 동시에 해결할 수 있는 새로운 실내 위치 추정 프레임워크를 제안하였다. 제안된 기법은 스마트폰의 지자기 센서를 이용하여 구축한 실내 자기장 맵과 딥러닝 기반의 위치 추정 모델을 결합하여, 외부 인프라에 의존하지 않고도 사용자의 초기 10스텝만으로 정확한 3차원 위치 초기화를 실현할 수 있다. 또한, 자기장 데이터를 활용한 보정 노드를 도입하여 기존의 PDR 방식에서 나타나는 누적 오차 문제를 효과적으로 완화하는 새로운 보정 방법을 제시하였다. 특히, 기압계 센서를 활용하여 층간 이동을 정밀하게 감지함으로써, 다층 구조의 실내 환경에서도 수직 방향의 위치 정확도를 크게 향상시켰다.

실험 결과, 제안된 방법은 다양한 이동 경로 및 건물 구조 환경에서 높은 정확도를 나타냈으며, 기존의 전통적인 PDR 기반 기법들 대비 측위 오차가 현저히 감소하였음을 확인하였다. 이러한 결과는 스마트폰 내장 센서만으로도 실시간이며 고정밀이고, 외부 인프라에 의존하지 않는 다층 실내 위치 추정이 충분히 가능함을 실증한 것이며, 디지털 트윈, 스마트 빌딩 관리, 재난 대응과 같은 다양한 응용 분야에의 활용 가능성을 제시한다. 본 연구의 주요 기여는 다음과 같다:

(1) 자기장 시퀀스를 입력으로 활용하여 3차원 초기 위치를 정밀하게 추정하는 딥러닝 기반의 위치 초기화 모델을 개발하였다. 이는 사용자의 초기 10걸음만으로 정확한 위치 추정을 가능하게 하여 기존 위치 초기화 기법의 한계를 극복하였다.

(2) 외부 인프라 없이 실내 자기장 데이터와 보정 노드를 결합하여

PDR의 드리프트 문제를 효과적으로 보정하는 경량화된 기법을 제안하였다. 이 기법은 기존 방식보다 효율적이고 실시간 구현에 적합하다.

참고문헌

[1] A. K. Panja, K. Sasidhar, M. Roy, and C. Chowdhury, “A survey on crowd behavior analysis through indoor localization,” *J. Location Based Services,* pp. 1 – 40, 2025.

[2] T. D. Vy, T. L. N. Nguyen, and Y. Shin, “Pedestrian indoor localization and tracking using hybrid Wi-Fi/PDR for iPhones,” in *Proc. IEEE 93rd Veh. Technol. Conf. (VTC-Spring)*, Apr. 2021, pp. 1 – 7.

[3] T. L. N. Nguyen, T. D. Vy, K.-S. Kim, C. Lin, and Y. Shin, “SmartphoneBased Indoor Tracking in Multiple-Floor Scenarios,” *IEEE Access*, vol. 9, pp. 141048-141063, Oct. 2021.

[4] Z. Jin, Y. Li, Z. Yang, Y. Zhang, and Z. Cheng, "Real-time indoor positioning based on BLE beacons and pedestrian dead reckoning for smartphones," *Appl. Sci.*, vol. 13, no. 7, p. 4415, Mar. 2023.

[5] R. S. Naser, M. C. Lam, F. Qamar, and B. B. Zaidan, "Smartphone-based indoor localization systems: A systematic literature review," *Electronics,* vol. 12, no. 8, p. 1814, Apr. 2023.

[6] K. Naheem and M. S. Kim, “A robust indoor pedestrian localization approach against human body shadowing for UWB-enabled smartphones,” *IEEE Trans. Instrum. Meas.*, vol. 73, pp. 1 – 13, 2024.

[7] Winter, S.; Tomko, M.; Vasardani, M.; Richter, K.; Khoshelham, K.; Kalantari, M. “Infrastructure-Independent Indoor Localization and Navigation,” *ACM Comput. Surv.*, 2019, 52, 1 – 24.

[8] K.-S. Kim and Y. Shin, “Deep learning-based PDR scheme that fuses smartphone sensors and GPS location changes,” *IEEE Access*, vol.9, no. 1, pp. 158616-158631, Dec. 2021.

[9] J. Liu, Z. Yang, S. Zlatanova, S. Li, and B. Yu, “Indoor localization methods for smartphones with multi-source sensors fusion: Tasks, challenges, strategies, and perspectives,” *Sensors,* vol. 25, no. 6, p. 1806, 2025.

[10] A. Poulose, O. S. Eyobu, and D. S. Han, “An indoor position-estimation algorithm using smartphone IMU sensor data,” *IEEE Access*, vol. 7, pp. 11165 - 11177, 2019.

[11] C. Yi, W. Choi, Y. Jeon, and L. Liu, “Pressure-pair-based floor localization system using barometric sensors on smartphones,” *Sensors,* vol. 19, no. 16, pp. 3622-3640, Aug. 2019.

[12] C. Lin and Y. Shin, “Deep learning-based multifloor indoor tracking scheme using smartphone sensors,” *IEEE Access*, vol. 10, pp. 63049- 63062, June 2022.

[13] S. Mostafa, K. Harras, and M. Youssef, “A Survey of indoor localization systems in multi-floor environments,” *TechRxiv,* 2022.

[14] J. Geng, X. Yu, C. Wu, and G. Zhang, “Research on pedestrian indoor positioning based on two-step robust adaptive cubature Kalman filter with smartphone MEMS sensors,” *Micromachines,* vol. 14, p. 1252, 2023.

[15] Y. T. Shi, Y. B. Zhang, Z. H. Li, S. W. Yuan, and S. H. Zhu, “IMU/UWB fusion method using a complementary filter and a

Kalman filter for hybrid upper limb motion estimation," *Sensors,* vol. 23, p. 6700, 2023.

[16] J.-W. Kim and Y. Shin, "Deep Learning-Based Multi-Floor Indoor Localization Using Smartphone IMU Sensors with 3D Location Initialization," *IEEE Access*, vol. 13, pp. 101532-101544, June 2025.

[17] N. Singh, S. Choe, and R. Punmiya, "Machine learning based indoor localization using Wi-Fi RSSI fingerprints: An overview," *IEEE Access*, vol. 9, pp. 127150 - 127174, 2021.

[18] Y. Shu, Y. Huang, J. Zhang, P. Coué, P. Cheng, J. Chen, and K. G. Shin, "Gradient-based fingerprinting for indoor localization and tracking," *IEEE Trans. Ind. Electron.*, vol. 63, no. 4, pp. 2424 - 2433, Apr. 2016.

[19] C. Lin and Y. Shin, "Multi-floor indoor localization scheme using a Seq2Seq-basedfloor detection and particle filter with clustering," *IEEE Access*, vol. 11, no. 1, pp. 66094-66112, Jun. 2023.

[20] H. Wang, H. Lenz, A. Szabo, U. D. Hanebeck, and J. Bamberger, "Fusion of barometric sensors, wlan signals and building information for 3-d indoor/campus localization," in *Proceedings of the International Conference on Multisensor Fusion and Integration for Intelligent Systems (MFI 2006)*, Heidelberg, Germany, vol. 36, 2006.

[21] H. Ye, T. Gu, X. Tao, and J. Lu, "B-Loc: Scalable floor localization using barometer on smartphone," in *Proc. IEEE 11th Int. Conf. Mobile Ad Hoc Sensor Syst. (MASS)*, Philadelphia,

USA, Jan. 2014, pp. 127-135.

[22] L. E. Diez, A. Bahillo, J. Otegui, and T. Otim, “Step length estimation methods based on inertial sensors: A review,” *IEEE Sensors J.*, vol. 18, no. 17, pp. 6908 - 6926, Sep. 2018.

[23] M. L. Hoang and A. Pietrosanto, “Yaw/heading optimization by drift elimination on MEMS gyroscope,” *Sens. Actuators Phys.*, vol. 325, 2021, Art. no. 112691.

[24] G. T. Lee, S. B. Seo, and W. S. Jeon, “Indoor localization by Kalman filter based combining of UWB-positioning and PDR,” in *Proc. IEEE 18th Annu. Consum. Commun. Netw. Conf. (CCNC)*, 2021, pp. 1 - 6.

[25] V. Thio, J. Aparicio, K. B. Anonsen, J. K. Bekkeng, and W. Booij, “Fusing of a continuous output PDR algorithm with an ultrasonic positioning system,” *IEEE Sensors J.*, vol. 22, no. 3, pp. 2464 - 2474, Feb. 2022.

[26] G. Ouyang and K. Abed-Meraim, “A survey of magnetic-field-based indoor localization,” *Electronics*, vol. 11, no. 6, p. 864, Mar. 2022.

[27] G. Ouyang and K. Abed-Meraim, “Analysis of magnetic field measurements for indoor positioning,” *Sensors,* vol. 22, no. 11, p. 4014, May 2022.

[28] W. Son and L. Choi, “Magnetic vector calibration for real-time indoor positioning,” in *Proc. IEEE Int. Conf. Commun. (ICC)*, Jun. 2020, pp. 1 - 7.

[29] H. J. Jang, J. M. Shin, and L. Choi, “Geomagnetic field based indoor localization using recurrent neural networks,” in *Proc.*

IEEE Global Commun. Conf. (GLOBECOM), Dec. 2017, pp. 1 – 6.

[30] V. Marotto, A. Serra, D. Carbouni, M. Sole, T. Dessi, and A. Manchinu, "Orientation analysis through a gyroscope sensor for indoor navigation systems," in *Proc. IFSA Sensordevice,* Barcelona, Spain, Aug. 2013, pp. 85 – 90.

[31] H. Zhang, Y. Li, and Z. Li, "6-D spatial localization of wireless magnetically actuated capsule endoscopes based on the fusion of hall sensor array and IMU," *IEEE Sensors J.*, vol. 22, no. 13, pp. 13424 – 13433, Jul. 2022.

[32] G. Evan Hemingway and M. O. Oliver, "Reilly, "Perspectives on euler angle singularities, gimbal lock, and the orthogonality of applied forces and applied moments," *Multibody Syst. Dyn.*, vol. 44, no. 1, pp. 31 – 56, Sep. 2018.

[33] V. Mansur, S. Reddy, S. R and R. Sujatha, "Deploying Complementary filter to avert gimbal lock in drones using Quaternion angles," *2020 IEEE International Conference on Computing, Power and Communication Technologies (GUCON),* pp. 751-756, Oct. 2020.

[34] A. Kim and M. F. Golnaraghi, "A quaternion-based orientation estimation algorithm using an inertial measurement unit," in *Proc. Position Location Navigat. Symp.*, Apr. 2004, pp. 268 – 272.

[35] M. Shu, G. Chen, Z. Zhang, and L. Xu, "Accurate indoor 3D location based on MEMS/vision by using a smartphone," in *Proc. IEEE 12th Int. Conf. Indoor Positioning Indoor Navigat. (IPIN)*, Sep. 2022, pp. 1 – 8.

[36] S. O. H. Madgwick, A. J. L. Harrison, and R. Vaidyanathan, “Estimation of IMU and MARG orientation using a gradient descent algorithm,” in *Proc. IEEE Int. Conf. Rehabil. Robot.*, Jun. 2011, pp. 1 – 7.

[37] Z. Diao, H. Quan, L. Lan, and Y. Han, “Analysis and compensation of MEMS gyroscope drift,” in *Proc. 7th Int. Conf. Sens. Technol. (ICST)*, Dec. 2013, pp. 592 – 596.

[38] Y. T. Chuang, C. T. Shen, Y. L. Hsu, and S. W. Shih, “New Drift Reset Method for Pedestrian Tracking with a Low-Cost IMU,” *Appl. Mech. Mater.*, vol. 284 – 287, pp. 2176 – 2180, Jan. 2013.

[39] J. W. Lee, *Android Sensor Story*. Los Angeles, CA, USA: Freelec, 2014, chs. 4 – 6.

[40] J.-W. Kim and Y. Shin, “Indoor floor detection using magnetic field map and deep learning model,” *Proc. Int'l Conf. ICT Convergence (ICTC 2024)*, Jeju, Korea, October 2024.

[41] W. Kang and Y. Han, “SmartPDR: smartphone-based pedestrian dead reckoning for indoor Localization,” *IEEE Sensors J.*, vol. 15, no. 5, pp. 2906-2916, May 2015.

[42] M. Datar, A. Gionis, P. Indyk, and R. Motwani, “Maintaining stream statistics over sliding windows,” *SIAM J. Comput.*, vol. 31, no. 6, pp. 1794 – 1813, Jan. 2002.

[43] S. Hochreiter and J. Schmidhuber, “Long short-term memory,” *Neural Comput.*, vol. 9, no. 8, pp. 1735-1780, 1997.

[44] 김진우, 이재승, 신요안, “실내 측위에서 스마트폰 지자기 센서를 이

용한 *k*-NN 기반 초기 위치 추정," *2024년도 한국통신학회 하계종합학술발표회 논문집*, 84-85.

[45] Y. Song, J. Liang, J. Lu, and X. Zhao, "An efficient instance selection algorithm for k nearest neighbor regression," *Neurocomputing,* vol. 251, pp. 26 - 34, Aug. 2017.

[46] 김진우, 신요안, "자기장 맵과 딥러닝 모델을 결합한 위치 보정 기반의 실내 다층 측위," *한국통신학회논문지,* 제49권, 제10호, pp. 1354-1357, 2024년 10월.

[47] I. Sutskever, O. Vinyals, and QV. Le, "Sequence to sequence learning with neural networks," 2014, *arXiv:1409.3215.*

[48] T. Willemsen, F. Keller, and H. Sternberg, "Concept for building a MEMS based indoor localization system," in *Proc. Int. Conf. Indoor Pos. & Indoor Nav.*, Busan, Korea, Oct. 2014, pp. 1-10.

[49] 김진우, 조상훈, 신요안, "다층 실내 측위에서 자기장 맵과 딥러닝 모델을 사용한 스마트폰 사용자 위치 초기화," *한국통신학회논문지*, 제49권, 제12호, pp. 1698-1701, 2024년 12월.

[50] T. D. Vy, T. L. N. Nguyen, and Y. Shin, "A precise tracking algorithm using PDR and Wi-Fi/iBeacon corrections for smartphones," *IEEE Access,* vol. 9, pp. 49522-49536, Mar. 2021.